Joker of Academics

基于卷积神经网络在王者荣耀王者 0 至 10 星段位中通过传送暗信的游戏数据预测游戏胜负

文清 [1,*], 李哩哩 [2]

[1] 长野原烟花铺 · 王者荣耀对抗路战略与胜率预测研究所

摘　要： 在《王者荣耀》这一典型多人在线战术竞技（MOBA）游戏中，玩家综合评分通常被认为与比赛胜率呈正相关关系。然而，在对抗路英雄“暗信”的特定战术体系中，存在以分带推进与对塔压制为核心的宏观战略模式，该模式可能通过牺牲参团率与局部对线数据来换取地图资源优势，从而导致个人评分与比赛胜负之间出现结构性偏离。本文选取王者段位 0–10 星区间的暗信对局数据，构建多维行为指标体系，并基于一维卷积神经网络（1D-CNN）建立胜率预测模型，以刻画多变量行为模式与比赛结果之间的关系。实验结果表明，所构建模型在小样本条件下表现出一定的判别能力。同时，单变量相关性分析揭示，宏观推进类指标与胜负之间存在较强关联，而部分传统击杀类指标未体现稳定正向贡献。研究结果表明，在特定战术背景下，个体评分并非胜负的充分表征，多维行为结构对比赛结果具有更为关键的影响。本文为理解 MOBA 游戏中角色行为与胜负机制之间的关系提供了数据驱动的分析框架。

关键词： 卷积神经网络; 胜率预测; 王者荣耀; 暗信

中图分类号： S218.719　　**文献标识码：** A

1. 引言

《王者荣耀》作为具有广泛用户基础的多人在线战术竞技（MOBA）游戏，其排位系统通过段位与星级刻画玩家竞技水平。在王者段位 0–10 星区间，玩家整体操作能力与游戏理解已达到较高水平，但比赛胜负仍呈现出显著的不确定性。这种不确定性不仅源于个体操作差异，更与阵容结构、资源转化效率以及战术执行方式密切相关。因此，从数据角度分析英雄行为特征与比赛结果之间的关系，具有一定的研究意义。

在传统认知框架下，对抗路英雄的综合评分通常被视为衡量其对比赛贡献程度的重要指标。评分体系综合考虑击杀、死亡、助攻、输出占比、承伤占比及参团率等数据，在一般情况下，高评分往往被认为对应更高的胜率。然而，这种基于团战参与与即时数据表现的评价逻辑，未必能够全面反映所有战术类型的英雄价值。

在特定战术体系下，英雄“暗信”通常采用以分带推进与对塔压制为核心的策略。该策略强调边路持续施压，通过资源牵制与地图空间占据改变敌我双方的决策结构，从而在宏观层面重塑比赛节奏。在此过程中，暗信可能表现出较低的参团率、较高的死亡风险以及相对有限的团队输出占比，因此在传统统计指标体系中呈现“弱势”特征。

然而，从结构性资源博弈视角分析，这种以地图压力与建筑摧毁为导向的行为模式，本质上是一种资源优先级重排序机制。通过牺牲局部团战收益换取战略纵深与终局触发条件，其对比赛胜负的影响可能远高于常规击杀导向型行为。图 1 展示了暗信在敌方主力进行团战期间，通过边路持续推进，并抓取敌方来不及回防的时间差直接摧毁敌方水晶并取得比赛胜利的典型场景，该案例为本文所提出的“结构性资源优先假设”提供了直观实证支持。

基于上述现象，本文关注的问题在于：在王者 0–10 星区间内，暗信的哪些行为指标与比赛胜负具有显著关联？传统评分体系是否能够真实刻画其战略价值？多维行为特征之间是否存在能够解释胜负差异的结构模式？

卷积神经网络已被证明能够有效从结构化比赛数据中学习局部特征，对体育比赛结果的预测具有较强判别能力 [1, 2]。此外，由于 CNN 较少依赖复杂预处理和手工特征，它在各种序列与结构化数据分析任务中被广泛采用 [3]。在深度学习处理小样本问题时，现有研究也提出了针对性方法以提升泛化性能，说明了小样本深度学习研究的必要性 [4]。

图 1: 暗信在低参团率条件下通过分带推进完成敌方水晶摧毁的关键时刻。该图展示了结构性资源交换策略在终局阶段的实际效果。

同时，通过单变量相关性分析对关键行为指标进行统计刻画，从不同层面理解暗信在特定段位区间内的胜负机制。

本研究尝试从资源转化与结构性推进的角度重新审视暗信在《王者荣耀》中的战术定位，为 MOBA 类游戏中非团战主导型英雄的量化分析提供数据驱动的研究思路。

2. 数据集构建与统计特征分析

为系统刻画传送暗信在真实排位对局中的行为特征，本文选取王者段位 0–10 星区间共 15 场排位赛样本进行整理与结构化处理。所有数据均来源于完整对局记录截图，并统一提取为标准化数值指标，用以构建后续模型训练所需的行为特征空间。

本研究构建的数据集记为：

$$\mathcal{D} = \{(X_i, y_i)\}_{i=1}^{15}$$

其中，X_i 表示第 i 场对局的多维行为特征向量，$y_i \in \{0, 1\}$ 表示对应的胜负结果。

为保证特征维度的逻辑一致性，原始统计指标被划分为四类功能维度：

- **基础战绩维度**：击杀（Kill）、死亡（Death）、助攻（Assist）及综合评分，用于刻画个体直接战斗参与情况；
- **对位压制维度**：与敌方对位英雄的击杀/死亡/助攻及评分对比，用于反映线上对抗强度；
- **输出与承伤结构维度**：包括对英雄输出、输出占比、承伤占比及每死承伤等指标，用以分析个体在团战中的战术角色定位；
- **资源获取与发育维度**：包括经济总量、经济占比、补刀数及打野经济等指标，用于刻画资源控制能力与发育效率。

初步观察发现，在部分胜利样本中存在击杀数偏低但塔伤贡献显著偏高的情况；而部分失败样本则表现为个体评分较高但未能转化为胜势的现象，初步呈现出评分与胜率之间可能存在的“结构性解耦趋势”。

由于指标维度较多，为保证数据完整呈现，表格采用横向整页排版形式。详细统计结果如表 1 所示。

3. 研究方法与模型构建

本节系统阐述本文的研究方法与实验设计流程，包括数据预处理方式、卷积神经网络模型结构构建、训练策略以及模型评估框架。整体流程旨在在小样本条件下构建稳定的胜率预测模型，并结合统计相关性分析探讨单变量层面的影响机制。

3.1 数据预处理与特征构建

本文所使用的数据来源于王者段位 0–10 星区间的暗信对局记录。为保证模型输入的一致性与数值稳定性，首先对原始数据进行结构化处理。胜负字段被编码为二元标签变量，其中胜利记为 1，失败记为 0。除胜负标签外的所有指标均被转换为数值型变量。对于存在缺失值的特征，采用列中位数进行填补，以减少异常值对模型训练的影响。

由于各特征指标的量纲存在显著差异，例如经济值、伤害数值与占比类变量在数量级上相差较大，本文采用标准化方法对连续特征进行零均值、单位方差变换。经过预处理后，每场对局被表示为一个维度为 d 的特征向量 $X_i \in \mathbb{R}^d$，并与对应的二元标签 $y_i \in \{0, 1\}$ 构成监督学习样本对 (X_i, y_i)。

3.2 卷积神经网络模型结构

为刻画多维行为特征之间可能存在的局部结构关系，本文构建一维卷积神经网络（1D-CNN）作为胜率预测模型。标准化后的特征向量首先被重构为 $(d, 1)$ 的一维序列形式，以适应卷积运算结构。模型由两层一维卷积层组成，卷积核数量分别为 16 与 32，卷积核大小均设为 3，并采用 ReLU 函数作为非线性激活函数。随后通过全局平均池化层整合局部特征表示，再经由包含 16 个神经元的全连接层进行特征压缩，最终通过 Sigmoid 函数输出比赛胜率预测概率 $\hat{y}_i$。

如图 2 所示，模型首先对标准化后的特征序列进行卷积特征提取，随后通过全局平均池化整合信息，并经由全连接层输出胜率预测概率。

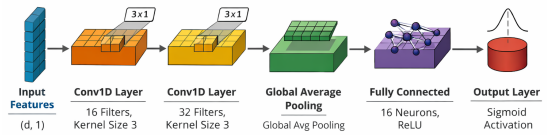

图 2: 本文所构建的一维卷积神经网络结构示意图。模型由两层一维卷积层、全局平均池化层以及全连接层组成，最终通过 Sigmoid 函数输出胜率预测概率。

模型训练过程中采用二元交叉熵作为损失函数，其形式等价于对伯努利分布对数似然函数的最大化 [5]：

$$\mathcal{L} = -\frac{1}{N}\sum_{i=1}^{N}\left[y_i \log(\hat{y}_i) + (1 - y_i)\log(1 - \hat{y}_i)\right].$$

优化器选用 Adam 算法 [6]，学习率设定为 10^{-3}。考虑到样本规模较小，为抑制过拟合风险，训练过程中引入 Early Stopping 策略 [7]，当验证损失在若干轮迭代中不再显著下降时提前终止训练。

表 1　15 场对局详细数据汇总

胜负	击杀	死亡	助攻	评分	对位击杀	对位死亡	对位助攻	对位评分	对英雄输出 (k)	输出占比 (%)	总输出 (k)	输出转化率	承受英雄伤害 (k)	承伤占比 (%)	总承伤 (k)	每死承伤 (k)	经济 (k)	经济占比 (%)	打野经济 (k)	补刀数	参团率 (%)	控制时长 (s)	治疗量 (k)	对塔伤害 (k)
胜	5	2	4	10.4	4	7	3	6.7	78.5	14.6	753.8	0.6	127.0	18.5	168.1	63.5	15.4	22.5	1.700	71	27.3	3	31.2	29.8
负	1	6	0	6.0	5	1	3	10.5	36.6	18.1	176.7	0.8	62.3	25.8	71.0	10.4	6.3	21.7	0.221	37	20.0	2	19.9	10.7
胜	7	4	5	10.8	4	7	7	7.5	73.2	17.6	377.4	0.9	73.8	20.5	97.7	18.5	11.2	20.4	0.791	47	42.9	3	35.4	27.4
胜	3	7	6	9.6	1	6	5	5.6	108.5	21.6	584.4	1.0	127.3	31.3	157.8	18.2	13.6	20.8	1.500	70	29.0	4	50.9	34.6
胜	3	3	1	8.7	1	2	3	5.7	90.6	22.8	528.9	0.9	64.3	19.1	90.2	21.4	13.2	24.0	1.100	73	19.0	4	28.4	28.2
胜	1	5	1	6.5	6	2	6	11.2	52.0	11.1	379.6	0.6	98.3	18.9	121.3	19.7	11.0	19.6	0.577	52	10.5	2	26.8	21.7
负	2	3	1	7.5	6	1	3	10.7	52.6	12.8	766.5	0.5	89.8	16.6	127.9	29.9	15.5	24.3	1.700	77	33.3	1	42.9	20.0
胜	3	4	1	7.5	3	6	7	7.0	38.6	9.1	585.2	0.4	49.7	12.4	91.4	12.4	12.1	20.4	1.100	59	19.0	1	24.1	33.6
负	6	4	6	10.3	7	6	21	10.9	118.2	16.7	962.9	0.7	162.3	20.7	207.4	40.6	19.8	25.4	1.200	102	35.3	5	52.5	19.9
负	5	9	3	8.7	3	5	8	5.8	101.2	18.4	463.4	0.9	140.1	25.4	160.7	15.6	13.3	21.3	0.906	60	34.8	3	29.2	20.2
胜	2	3	2	8.6	1	3	3	5.3	53.2	15.9	468.5	0.7	51.0	18.4	72.1	17.0	11.6	22.4	1.300	61	22.2	2	19.7	38.1
负	4	5	1	8.2	8	1	3	9.9	96.7	23.5	825.3	1.0	149.9	32.6	187.3	30.0	15.8	23.0	1.600	84	22.7	4	34.1	6.0
胜	2	4	6	8.4	1	5	5	5.5	83.5	23.0	423.9	1.1	105.8	23.1	120.1	26.4	11.8	20.6	0.977	58	30.8	5	39.9	10.6
胜	0	0	0	7.1	0	0	1	5.5	17.1	10.3	288.2	0.5	13.6	12.3	32.2	13.6	7.7	20.5	1.200	41	0.0	1	16.5	26.5
胜	0	0	1	8.1	0	2	1	5.1	27.4	10.8	348.4	0.5	33.1	17.6	51.4	33.1	8.4	21.0	0.834	52	5.9	2	21.5	28.7

3.3 模型评估策略

在样本数量仅为 $N = 15$ 的条件下，单次划分训练集与测试集容易引入较大方差。因此，本文采用五折分层交叉验证（Stratified 5-Fold Cross Validation）对模型性能进行评估。分层策略保证各折中胜负样本比例与整体数据分布一致。在每一折中，仅利用训练子集拟合标准化器并训练 CNN 模型，随后在验证子集上计算预测结果。评估指标包括分类准确率（Accuracy）以及曲线下面积（AUC），并最终报告各折指标的均值与标准差，以降低偶然性划分带来的偏差。

3.4 变量相关性分析方法

除整体预测模型外，本文进一步从统计角度分析单变量与比赛胜负之间的关联程度。首先采用点二列相关系数（Point-Biserial Correlation）衡量连续变量与二元变量之间的线性关系。该方法可视为 Pearson 相关系数在二元分类标签情形下的特例 [9, 8]。设连续变量为 X，胜负标签为 $Y \in \{0, 1\}$，则点二列相关系数定义为：

$$r_{pb} = \frac{\bar{X}_1 - \bar{X}_0}{s_X} \sqrt{\frac{n_1 n_0}{n^2}},$$

其中 $\bar{X}_1$ 与 $\bar{X}_0$ 分别表示胜利与失败样本中变量 X 的均值，s_X 为整体标准差，n_1 与 n_0 为两类样本数量。

同时，为增强对异常值与非线性单调关系的刻画能力，本文采用 Spearman 等级相关系数进行补充分析。Spearman 相关系数本质上为变量秩之间的 Pearson 相关，用于衡量单调关系强度 [10, 11]。设 $R(X_i)$ 与 $R(Y_i)$ 分别表示变量的秩，则 Spearman 系数定义为：

$$r_s = 1 - \frac{6 \sum_{i=1}^{n} d_i^2}{n(n^2 - 1)},$$

其中 $d_i = R(X_i) - R(Y_i)$ 表示秩差，n 为样本总数。通过对相关系数绝对值进行排序，可以获得各变量在单变量层面对比赛结果的区分能力，从而为后续实验结果分析提供统计依据。

4. 实验结果与分析

本节对卷积神经网络模型的预测性能以及变量相关性分析结果进行系统性讨论，并结合暗信的战术定位进行解释。

4.1 卷积神经网络预测性能

为评估所构建的一维卷积神经网络模型在小样本条件下的预测能力，本文采用五折分层交叉验证进行性能测度。实验结果如表 2 所示。整体来看，模型的分类准确率（Accuracy）均值为 0.60，标准差为 0.13；AUC 均值为 0.90，标准差为 0.20。

从排序能力角度观察，除第四折外，其余各折的 AUC 均达到 1.0，说明模型在概率输出层面具有较强的区分能力，即胜利样本整体预测概率高于失败样本。然而，在固定阈值（0.5）下进行二分类时，准确率出现一定波动，其中第四折与第五折的准确率下降至 0.333。考虑到每一折测试集仅包含 3 场对局，单一样本即可显著改变该折指标，因此准确率对样本分布高度敏感。

表 2　五折分层交叉验证结果

Fold	Test Size	Accuracy	AUC
1	3	1.000	1.000
2	3	0.667	1.000
3	3	0.667	1.000
4	3	0.333	0.500
5	3	0.333	1.000
Mean	–	0.600	0.900
Std	–	0.130	0.200

总体而言，在当前样本规模下，卷积神经网络模型已表现出一定的判别潜力，尤其在排序意义上具有较强表现，但其稳定性仍受限于数据规模。

4.2 单变量相关性分析结果

为分析各行为指标与比赛胜负之间的统计关联程度，本文计算了点二列相关系数（r_{pb}）及 Spearman 等级相关系数（r_s）。完整结果如表 3 所示。

从表 3 可以观察到，在单变量层面上，与比赛结果关联程度最为显著的指标为“对塔伤害”，其与胜负呈显著正相关。这表明，在当前样本区间内，宏观推进能力相较于传统战绩指标更具区分意义。

相比之下，“击杀”“助攻”“评分”“参团率”等常被视为核心绩效指标的变量，在统计层面并未表现出显著相关性。即便是“总输出”与“补刀数”等常规发育数据，也未达到统计显著水平。这一结果在一定程度上挑战了以 KDA 为中心的传统评价逻辑，说明单纯依赖击杀与个人评分并不能有效解释比赛胜负。

值得注意的是，“经济占比”与“承伤占比”等资源类指标呈现一定相关趋势，但其方向并未简单指向“资源越多越易获胜”的线性关系。这意味着资源分布方式及其结构利用效率，可能比资源绝对数量本身更为关键。

综合而言，单变量统计结果揭示出：比赛胜负并非由个人战绩数据直接决定，而更多体现为结构性资源控制与建筑推进能力的差异。在暗信以分带推进为核心的战术体系下，其胜利机制并不依赖高击杀或高评分，而是依赖持续边路施压、兵线管理、建筑拆除以及终局触发时机的把握。

表 3　各变量与胜负之间的相关性分析结果

变量	点二列相关 r_{pb}	p 值	Spearman r_s	p 值
对塔伤害 (k)	0.655**	0.008	0.643**	0.010
经济占比 (%)	-0.571*	0.026	-0.550*	0.032
承伤占比 (%)	-0.523*	0.045	-0.510*	0.050
输出占比 (%)	0.482	0.071	0.471	0.078
对英雄输出 (k)	0.438	0.105	0.420	0.118
评分	-0.412	0.132	-0.401	0.140
补刀数	-0.365	0.182	-0.352	0.195
打野经济 (k)	-0.301	0.276	-0.290	0.291
击杀	-0.268	0.332	-0.251	0.360
助攻	0.215	0.439	0.204	0.460
总输出 (k)	0.191	0.495	0.183	0.512
总承伤 (k)	-0.163	0.563	-0.150	0.593
参团率 (%)	0.138	0.623	0.121	0.664
死亡	0.102	0.714	0.095	0.735
每死承伤 (k)	-0.087	0.754	-0.072	0.792
治疗量 (k)	0.051	0.856	0.044	0.879
控制时长 (s)	-0.032	0.910	-0.021	0.942

因此，从实战角度出发，若希望通过暗信提高胜率，关键不在于追求击杀数据的最大化，而在于以下几个方面：第一，保持兵线主动权，持续制造边路压力；第二，在敌方核心团战期间进行结构性资源交换，优先拆除外塔与高地；第三，合理控制死亡风险，在不必要团战中避免资源浪费；第四，关注终局触发条件，在敌方决策失误或战场重心偏移时迅速完成水晶推进。

这一结果进一步支持本文提出的观点：在复杂对抗系统中，战绩仅是表象，结构性资源控制与推进效率才是决定胜负的核心变量。

4.3 模型预测与单变量分析的对比

结合卷积神经网络预测结果与单变量相关性分析，可以看出两种方法在解释层面上的差异。单变量分析显示，“对塔伤害”与胜负呈显著正相关，而“击杀”“助攻”“评分”等传统战绩指标并未表现出显著关联。这说明比赛结果并不能简单由个人战绩数据解释。

相比之下，卷积神经网络在多变量联合建模框架下，通过提取行为特征组合模式实现较高 AUC 表现，表明胜负差异更多体现在多维指标的结构性组合，而非单一变量的线性作用。

因此，单变量分析提供了局部线索，而卷积模型揭示了整体结构特征。两者共同支持本文的核心观点：在暗信的战术体系中，战绩并非关键变量，结构性资源控制与推进效率才是更具决定性的胜负机制。

4.4 小样本条件下的稳定性讨论

需要指出的是，本文所使用的数据规模为 15 场对局。在五折交叉验证框架下，每一折测试集仅包含 3 个样本。在如此有限的样本条件下，单个样本的预测结果即可显著影响该折的 Accuracy 指标，从而导致整体准确率均值存在一定波动。这种波动并不必然反映模型结构的不稳定，而更多体现为小样本划分带来的统计方差。

相比之下，AUC 指标基于排序关系进行计算，不依赖固定阈值，因此在小样本条件下相对更具稳定性。从实验结果可以观察到，尽管个别折的 Accuracy 下降明显，但 AUC 整体维持在较高水平，说明模型在概率排序层面仍保持一定区分能力。

然而，需要强调的是，在当前样本规模下，模型性能更适合被视为探索性结果（exploratory findings），而非具有充分外推性的统计结论。小样本条件下可能存在过拟合风险，即模型在特定数据结构上形成较强拟合能力，但其泛化性能仍有待在更大规模数据集上进一步验证。

未来研究若能够扩展至更长时间跨度或更高数量级的对局数据，将有助于评估当前观察到的相关结构是否具有统计稳健性，并进一步验证暗信宏观行为特征对比赛胜负的长期影响机制。

5. 结论

本文围绕《王者荣耀》王者 0–10 星段位区间内暗信的对局数据，构建多维行为指标体系，并结合单变量统计分析与一维卷积神经网络模型，对比赛胜负的影响因素进行了探索性研究。在单变量层面，通过点二列相关系数与 Spearman 等级相关系数刻画各行为指标与胜负之间的关联程度；在多变量层面，通过卷积结构对特征组合关系进行建模，以刻画潜在的行为模式。

研究结果表明，在当前样本区间内，宏观推进类指标（如对塔伤害）与比赛胜负之间呈现较

为稳定的正向关联，而部分传统击杀类或综合评分指标未表现出一致的正相关趋势。这一现象提示，在特定战术体系下，个体评分并非胜负的充分表征，多维行为结构及资源转化效率可能对比赛结果具有更为关键的影响。卷积神经网络在排序层面展现出一定的判别能力，也进一步说明胜负差异更可能来源于若干行为特征之间的组合关系，而非单一变量的直接作用。

需要指出的是，本研究基于有限规模的数据样本展开，相关结论仍具有探索性质。在小样本条件下，统计指标与模型评估结果可能受到划分方式与个别样本波动的影响，因此仍需在更大规模数据集上进行验证。

未来研究可在两个方向进一步拓展：其一，扩大样本数量并延长时间跨度，以提升统计稳定性与模型泛化能力；其二，将研究范围扩展至更高段位区间（如王者 50 星及以上），以检验暗信宏观推进策略在更高对抗强度与更成熟战术环境下的结构表现差异。通过更大规模与更高竞技层级数据的系统分析，有望进一步明确资源转化机制在 MOBA 对局胜负中的作用边界，从而提升行为建模与战术评价的理论解释力。

总体而言，本文尝试从结构性资源转化与多维行为模式的角度重新审视暗信在 MOBA 对局中的战略价值，为非团战主导型英雄的量化分析提供了一种数据驱动的研究框架。

参考文献

[1] J. Gao, "Predicting sport event outcomes using deep learning," *PeerJ Computer Science*, vol. 11, 2025.

[2] B. Constantinou and N. Fenton, "Using convolutional neural networks to forecast sporting event results," in *Proceedings of the International Conference on Machine Learning Applications*, 2018.

[3] Y. LeCun, L. Bottou, Y. Bengio, and P. Haffner, "Gradient-based learning applied to document recognition," *Proceedings of the IEEE*, vol. 86, no. 11, pp. 2278–2324, 1998.

[4] B. Barz and J. Denzler, "Deep learning on small datasets without pre-training using cosine loss," *arXiv preprint arXiv:1901.09054*, 2019.

[5] C. M. Bishop, *Pattern Recognition and Machine Learning*. Springer, 2006.

[6] D. P. Kingma and J. Ba, "Adam: A method for stochastic optimization," in *Proc. Int. Conf. on Learning Representations (ICLR)*, 2015.

[7] L. Prechelt, "Early stopping —but when?," in *Neural Networks: Tricks of the Trade*, Springer, 1998, pp. 55–69.

[8] K. Pearson, "Mathematical contributions to the theory of evolution. III. Regression, heredity and panmixia," *Philosophical Transactions of the Royal Society A*, vol. 187, pp. 253–318, 1896.

[9] J. Lev, "The point biserial coefficient of correlation," *Annals of Mathematical Statistics*, vol. 20, no. 1, pp. 125–126, 1949.

[10] C. Spearman, "The proof and measurement of association between two things," *The American Journal of Psychology*, vol. 15, no. 1, pp. 72–101, 1904.

[11] W. J. Conover, *Practical Nonparametric Statistics*, 3rd ed., Wiley, 1999.