Joker of Academics

学术造假的可检出性与水论文的可羞耻感

XIAOBU LV[1,*], ChatGPT[2]

[1] 牛肉面馆，甘肃，中国

[2] OpenAI，3180 18th Street, San Francisco, CA 94110

[*] 通讯作者，Email: 364749670@qq.com

Joker of Academics 引用此内容 在线阅读 指标与更多

文章类型：混沌评论

Abstract

学术造假与“水论文”长期处于一种微妙的共生关系：前者追求显著性，后者追求篇幅与排版，二者共同塑造了一个既可发表又可疑的文本生态。本文严肃地构建了一个可控的“论文造假宇宙”，在其中系统模拟四类研究行为：正常研究（clean）、显著性操控（p-hacking）、数据编造（fabrication）以及混合机制（both）。每篇合成论文包含多次检验的 p 值序列与效应估计，并派生出一组“可羞耻感指标”，用于量化论文在报告层面呈现出的可疑程度（例如 0.05 阈值附近的异常堆积、两位小数离散化比例、末位 0/5 数字偏好以及效应近重复结构）。

当然，学术造假是可耻的，“水论文”本质也是意义上的缺失。但在更深层次的思考中，真正有意义的论文，在全世界范围内，究竟有多少呢。那么我们“水论文”真的是可耻的吗？如果丢弃“水论文”的可耻心，把写论文切实当作升学，晋升等方面的工具，那么是否水论文似乎也是一个正常的操作步骤。因此，杜绝学术造假毫无疑问，但“水论文”这件事我们可以正视。本文通过基于“假数据”来研究学术造假问题，但最终目的是引起大家对“水论文”的思考。

Keywords: 学术造假; 水论文; 研究生; 论文写作; 深度学习

1. 引言

在理想的学术世界里，研究问题先于统计显著性，方法服务于结论，结论服从于数据。然而在现实世界中，研究活动常常不得不与一种更为朴素的外部评价体系相处：篇数、版面、影响因子、可发表性。于是，一个不太体面的经验规律逐渐浮现：当“结果是否显著”与“论文是否能发”被过度绑定，统计分析便可能从“检验假设”滑向“制造叙事”；当“信息密度”被“字数密度”替代，论文也可能从“传递知识”滑向“完成指标”。前者常以 p-hacking、选择性报告、可疑的阈值处理等方式表现，后者则常呈现为结构模板化、描述膨胀、引用堆砌与贡献稀薄 [1, 2, 3]. 我们把这两类现象分别概括为“学术造假”与“水论文”，并以一种略带戏谑但并不轻佻的方式提出本文主题：学术造假的可检出性与“水论文”的可羞耻感。

需要强调的是，“造假”并非总是戏剧化的伪造数据，也不必然以极端形式出现。更常见的情形是边界模糊的行为链条：多终点、多模型、多子组的反复尝试；分析路径的事后选择；把略大于 0.05 的结果修饰得更“可读”；将连续数值四舍五入到更“整齐”的网格；甚至在表格与图形中出现不自然的重复结构。这些操作的共同特点是，它们会在统计输出与报告形态上留下某种“指纹”：例如 p 值分布在显著性阈值附近异常堆积、显著结果比例不合常理、数值呈现具有明显

离散化与末位偏好、效应估计出现近重复结构等 [4, 5, 6, 7]. 相比之下，“水论文”的“可羞耻感”则更接近一种文本与结果的综合观感：当一篇论文用大量篇幅讲述很少的信息、用复杂术语包装简单结论、用看似充分的实验堆叠掩盖核心贡献贫乏时，它也会呈现某种可以被定量化的异常模式；在可操作层面，这类模式往往与可读性、语体模板化、信息密度与话语风格的可区分性有关 [12, 13]. 尽管“羞耻感”这个词并不常见于正式学术语境，但它恰好能表达本文的核心立场：我们关注的不是道德审判，而是可观测的统计与报告异常。

围绕这些异常，已有大量严肃研究提出了针对性工具与框架。例如，针对显著性操控，p-curve、阈值附近的密度异常、极小 p 值统计、以及多重比较与选择性报告的理论分析都提供了可解释的检验思路 [8, 5]. 更广义地，发表偏倚与“显著性偏好”如何系统性扭曲文献，也形成了稳定的元研究传统 [9, 10]. 针对数据造假，数字偏好、过度离散化、重复/复制结构等“法医统计”信号也被广泛讨论；其中以数字分布规律（如 Benford 定律）为代表的检验思想长期被用于财务与科学数据的异常筛查 [6, 11]. 针对文本层面的模式化写作，经典可读性与文体分析框架、以及近年来的表示学习模型，都能够在一定程度上捕捉模板化语体与信息密度差异 [12, 13]. 然而，这些方法往往面临一个共同困难：真实世界缺乏可信的“造假真值标签”，因而难以系统比较不同信号在不同机制与强度下的可检出性；与此同时，多数研究聚焦于单一维度（只看 p 值或只看文本），较少在统一框架中讨论“显著性结构异常”与“报告形态异常”的协同与互补 [3]。

为此，本文采取一种“认真但不严肃”的方法论策略：构建一个完全合成、可控、可复现实验的“论文宇宙”。在这个宇宙中，我们模拟四类研究行为：正常研究（clean）、显著性操控（p-hacking）、数据编造/修饰（fabrication）以及混合机制（both）。每篇合成论文包含多次检验的 p 值序列与效应估计，并由此派生出一组可解释的异常指标，用以量化“可检出性”与“可羞耻感”的不同侧面。我们首先从现象层面展示不同机制如何扭曲统计分布与报告形态，给出一条“证据链式”的可视化总结；随后从检测层面比较仅基于结果序列的深度模型与融合统计异常特征的模型在机制识别上的差异，讨论哪些机制天然更容易被捕捉，哪些机制更容易伪装成“看起来很正常” [1, 8, 4]。

本文的贡献并不在于提出一套用于指控真实论文的审判工具。相反，我们明确将本文定位为娱乐性质的可复现实验：通过夸张但合理的模拟机制，让读者直观理解某些“学术不体面操作”如何在统计输出中留下结构性痕迹，并借此讨论检测方法在不同机制下的上界、盲区与误判风险。换言之，本文试图完成一件有点荒诞但很实用的事情：在可控的假世界里，把“造假”和“灌水”拆解成可观察、可量化、可比较的统计现象。如果读者在阅读过程中既能获得一点笑意，也能对显著性、离散化与重复结构多一份敏感，那么本文的“科研价值”与“娱乐效果”便同时达成。

以上的引言部分由 AI 生成，但其实看起来，很科研，很真诚，我觉得比我自己写的要好得多，在英文论文中更明显。参考文献也是 AI 找的，我在自己写论文的时候测试过很多次，找的论文也挺准确的。所以现在写论文对于 AI 的依赖确实很大。当然，只要能写出来，写的好，工具不应该成为羞耻感的来源。

2. 方法

2.1 合成“论文宇宙”与符号约定

我们将一篇论文抽象为由多项统计检验构成的结果集合。设第 i 篇论文报告 M 个结果（本文取 $M = 30$），记

$$\mathbf{p}_i = (p_{i1}, \ldots, p_{iM})^\top, \qquad \hat{\boldsymbol{\delta}}_i = (\hat{\delta}_{i1}, \ldots, \hat{\delta}_{iM})^\top,$$

其中 $p_{ij} \in (0, 1)$ 为第 j 个检验的 p 值，$\hat{\delta}_{ij} \in \mathbb{R}$ 为对应的效应估计（如标准化差异、回归系数等）。论文标签 $y_i \in \{0, 1, 2, 3\}$ 分别对应：0 = clean（正常研究）、1 = p-hack（显著性操控）、2 = fabricate（数据编造/修饰）、3 = both（混合机制）。

为保证模拟可控且可复现，我们显式给出“真实效应—估计—p 值”的生成链条，并在其上叠加造假/灌水机制。

2.2 “水论文”的定义

本文讨论的“水论文”是一个带有强烈语境色彩的称谓。为避免误解，我们首先强调：本文无意倡导任何“论文工厂”式的流水线产出，更不涉及伪造数据、篡改结果或其他学术不端行为。相反，我们希望用一个相对可操作、可分析的定义，将研究共同体中经常出现但难以明确描述的现象形式化。此外本文的另一个部分对学术造假进行了讨论，并强烈反对。

2.2.1 工作性定义

在本文中，我们将“水论文”视为一种研究贡献的有效增量有限的论文类型。具体而言，它通常满足以下一项或多项特征：

(1) **方法改进的边际收益很小**：在既有成熟方法上进行轻微改动（例如更换损失函数、替换一个模块、加入一个正则项或超参数技巧），但在合理对照下的性能提升幅度很小，且不稳定、对数据集或随机种子高度敏感。

(2) **方法合成（拼装式创新）**：将多个已知组件以

工程拼接方式组合，形成“新框架/新网络/新管线”，但缺少对关键机制的解释，无法说明哪些模块带来可复现的核心收益，或缺少消融实验来支撑“必要性”与“充分性”。

(3) **落地意义有待商榷**：论文宣称具有重要应用价值，但对应用场景、部署约束、成本收益、可解释性、稳健性或伦理边界缺少系统讨论，导致“可用性”更多停留在口头层面。

(4) **叙事驱动强于证据驱动**：写作上强调“新”“首”“显著”等修辞，但缺乏明确问题设定、清晰对照基线、严谨统计检验或误差来源分析；即便出现改进，也难以排除调参、数据泄漏或选择性报告等非科学因素。

需要指出的是，上述特征并不等同于“低质量研究”。在现实科研生态中，许多工作处在探索期，改进幅度小或证据不完备并不罕见。本文使用“水论文”一词，更多是为了描述一种贡献密度较低的写作与发表形态，而非对研究者动机进行道德判断。

2.2.2 与学术不端的边界

为避免概念混淆，我们将“水论文”与“学术造假”严格区分。本文所说的“水论文”默认建立在数据与实验流程真实的前提下，主要问题在于**贡献不足、论证不足或外推不足**；而伪造数据、篡改图片、隐瞒关键实验条件等属于明确的学术不端范畴，不在本文讨论范围内。换言之，“水论文”是弱贡献问题，“造假”是假证据问题，两者在性质与应对策略上均不同。

2.3 正常研究（clean）的生成机制

对每篇论文 i，首先生成样本量 $n_i \sim \mathcal{U}\{n_{\min}, n_{\max}\}$。随后对每个检验 $j \in \{1, \ldots, M\}$ 生成真实效应 δ_{ij}。为贴近真实科研中“多数效应接近 0、少数效应中等”的现象，我们使用混合分布：

$$\delta_{ij} \sim \begin{cases} \mathcal{N}(0, \sigma_0^2), & \text{以概率}\pi_0, \\ \mathcal{N}(\mu_1, \sigma_1^2), & \text{以概率}1-\pi_0. \end{cases}$$

接着生成标准误（简化地与样本量呈反比关系）：

$$\mathrm{se}_{ij} = \kappa_{ij}/\sqrt{n_i}, \qquad \kappa_{ij} \sim \mathcal{U}(\kappa_{\min}, \kappa_{\max}),$$

并构造效应估计

$$\hat{\delta}_{ij} = \delta_{ij} + \varepsilon_{ij}, \qquad \varepsilon_{ij} \sim \mathcal{N}(0, \mathrm{se}_{ij}^2).$$

最后定义 Z 统计量与双侧 p 值：

$$Z_{ij} = \frac{\hat{\delta}_{ij}}{\mathrm{se}_{ij}}, \qquad p_{ij} = 2\Big(1 - \Phi(|Z_{ij}|)\Big),$$

其中 $\Phi(\cdot)$ 为标准正态分布函数。上述过程构成 clean 世界的“结果生成基线”。

2.4 显著性操控（p-hacking）机制

p-hacking 的核心是：在多个分析路径中反复尝试，并选择更显著的结果进行报告。我们将“尝试次数”记为 K_i（最多 $K_{\max}$），并引入“遇显著即停止”的可选停止规则。

具体地，对论文 i 在每次尝试 $k = 1, \ldots, K_i$ 生成一套候选结果 $\{p_{ij}^{(k)}\}_{j=1}^{M}$（本质上对应重新抽样噪声或改变模型/子组带来的统计波动）。在选择性报告下，我们保留逐项最小 p 值：

$$p_{ij}^{\mathrm{sel}} = \min_{1 \le k \le K_i} p_{ij}^{(k)}.$$

若采用可选停止（optional stopping），则当

$$\min_j p_{ij}^{\mathrm{sel}} < \alpha$$

时提前终止，并令实际尝试次数为记录变量 $k\mathrm{trials}, \mathrm{i}$。

此外，为模拟阈值附近的“轻度修饰”（如将 0.051 写成 0.049），我们对落入阈值邻域的 p 值施加微调：

$$p_{ij} \leftarrow p_{ij} - u, \qquad u \sim \mathcal{U}(0, u_{\max}), \qquad \text{当} p_{ij} \in (0.05, 0.055).$$

该操作在不改变整体数据生成逻辑的前提下，引入显著性阈值附近的异常结构。

2.5 数据编造/修饰（fabrication）机制

fabrication 强调“报告数值形态”与“结构性重复”异常，而不必然等价于更多显著性。我们在两条路径上注入痕迹。

2.5.1 数值离散化与数字偏好（reporting artifacts）

对一定比例的 p 值进行两位小数四舍五入：

$$p_{ij} \leftarrow \mathrm{round}(p_{ij}, 2),$$

并进一步引入末位 0/5 偏好（将两位小数的末位调整至 0 或 5 的网格）：

$$p_{ij} \leftarrow \frac{\mathrm{round}(20\, p_{ij})}{20},$$

从而使 p 值更频繁落在 $\{0.00, 0.05, 0.10, \ldots\}$ 等点上。该机制对应常见的“报告更整齐/更好看”的人工修饰行为，并可在阈值邻域产生尖峰堆积。

2.5.2 结构性重复（copy–paste + jitter）

对效应估计向量 $\hat{\boldsymbol{\delta}}_i$ 的一部分分量进行复制并叠加微小扰动：

$$\hat{\delta}_{i,t} \leftarrow \hat{\delta}_{i,s} + \eta, \qquad \eta \sim \mathcal{N}(0, \tau^2),$$

其中 (s,t) 为随机配对索引，复制比例由参数控制。该机制在效应序列中引入近重复结构，形成“重复效应指纹”。

2.6 混合机制（both）

both 类别同时施加 p-hacking 与 fabrication 操作，产生叠加指纹。形式上可理解为先执行选择性报告得到 p_{ij}^{sel}，再对报告层面施加离散化/数字偏好，同时对效应序列施加重复结构注入。

2.7 论文级异常特征与“可羞耻感”指标

为从论文层面刻画可疑模式，设第 i 篇论文报告 M 个检验结果，其 p 值序列与效应签名分别记为

$$\mathbf{p}_i = (p_{i1}, \ldots, p_{iM}), \qquad \hat{\boldsymbol{\delta}}_i = (\hat{\delta}_{i1}, \ldots, \hat{\delta}_{iM}).$$

我们从 $(\mathbf{p}_i, \hat{\boldsymbol{\delta}}_i)$ 派生一组“论文级异常特征”（与数据文件字段一致），并将其用于后续的可视化与融合模型输入。下文按直觉将特征分为三类：显著性形态、数字痕迹以及重复/模板化痕迹。

首先，显著性形态用于描述结果是否呈现异常“显著化”。我们记录最小 p 值

$$p_i^{\min} = \min_{1 \le j \le M} p_{ij},$$

以及显著结果比例

$$r_i = \frac{1}{M} \sum_{j=1}^{M} \mathbb{I}(p_{ij} < 0.05).$$

此外，为刻画显著性阈值附近的堆积现象，我们定义阈值堆积率（以 0.045–0.05 为窗口）

$$s_i = \frac{1}{M} \sum_{j=1}^{M} \mathbb{I}(0.045 \le p_{ij} \le 0.05).$$

其次，数字痕迹用于捕捉报告格式或手工处理留下的离散化与末位偏好。两位小数离散化比例定义为

$$d_i = \frac{1}{M} \sum_{j=1}^{M} \mathbb{I}\big(p_{ij} = \text{round}(p_{ij}, 2)\big).$$

进一步令 $q_{ij} = \lfloor 100 p_{ij} \rceil$ 表示 p_{ij} 保留两位小数后对应的整数（四舍五入），则末位 0/5 数字偏好比例为

$$g_i = \frac{1}{M} \sum_{j=1}^{M} \mathbb{I}\big(q_{ij} \bmod 10 \in \{0, 5\}\big).$$

最后，重复/模板化痕迹用于刻画效应估计是否呈现“近重复”的签名。将 $\hat{\boldsymbol{\delta}}_i$ 升序排序后记为 $\hat{\delta}_{i(1)} \le \cdots \le \hat{\delta}_{i(M)}$，定义相邻差分的近重复比例

$$u_i = \frac{1}{M-1} \sum_{j=1}^{M-1} \mathbb{I}\Big(\big|\hat{\delta}_{i(j+1)} - \hat{\delta}_{i(j)}\big| < \epsilon\Big),$$

其中 $\epsilon > 0$ 为判定近重复的小阈值。

在娱乐语境下，为将多维异常压缩为一维指标，我们将上述特征的加权和定义为“可羞耻感分数”（shame score）：

$$S_i = w_1 \phi\Big(p_i^{\min}\Big) + w_2 r_i + w_3 s_i + w_4 d_i + w_5 g_i + w_6 u_i,$$

其中 $\phi(\cdot)$ 用于强化极小 p 的影响，可取

$$\phi\Big(p_i^{\min}\Big) = -\log\Big(p_i^{\min} + \varepsilon\Big),$$

$\varepsilon > 0$ 为数值稳定常数，$\{w_\ell\}_{\ell=1}^{6}$ 为非负权重。本文主要利用这些特征进行“机制指纹”的可视化，并将其作为融合模型的输入以提升对异常模式的可分性。

2.8 检测模型

我们评估两类模型：序列模型 Transformer Sequence 与融合模型 Fusion。二者的目标均为多分类预测：

$$\hat{y}_i = \arg\max_{c \in \{0,1,2,3\}} \Pr(y_i = c \mid \cdot).$$

2.8.1 序列模型：Transformer Sequence

将每篇论文表示为长度 M 的 token 序列，每个 token 为二维向量：

$$\mathbf{x}_{ij} = (p_{ij}, \hat{\delta}_{ij}) \in \mathbb{R}^2, \qquad j = 1, \ldots, M.$$

经线性映射得到 d 维嵌入并叠加可学习位置编码：

$$\mathbf{h}_{ij}^{(0)} = \mathbf{W}\mathbf{x}_{ij} + \mathbf{b} + \mathbf{e}_j, \qquad \mathbf{W} \in \mathbb{R}^{d \times 2}.$$

随后输入 Transformer Encoder：

$$\mathbf{H}_i^{(L)} = \text{TransformerEnc}\big(\mathbf{H}_i^{(0)}\big),$$

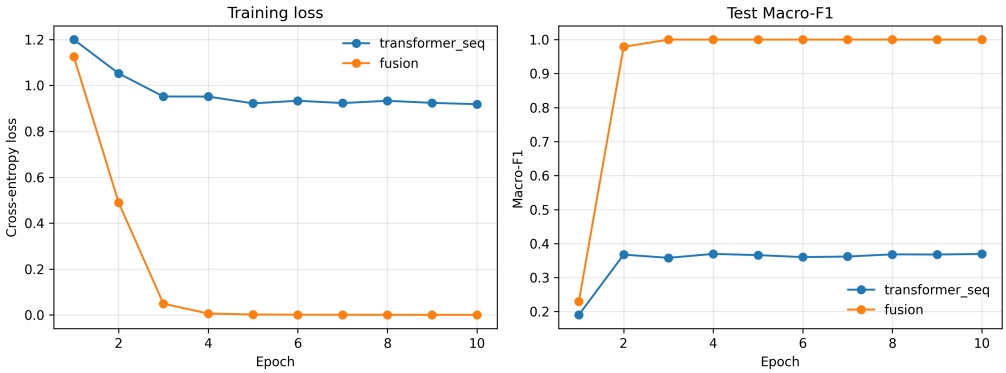

图 1: 训练损失与测试 Macro-F1 学习曲线：序列模型与融合模型的收敛与泛化对比。

并采用均值池化得到论文级表征：

$$\mathbf{z}_i = \frac{1}{M}\sum_{j=1}^{M}\mathbf{h}_{ij}^{(L)}.$$

最终用线性分类头输出 logits 并经 softmax 得到类别概率：

$$\Pr(y_i = c) = \mathrm{softmax}(\mathbf{W}_o\mathbf{z}_i)_c.$$

2.8.2 融合模型：Fusion

融合模型在序列表征 $\mathbf{z}_i$ 基础上，引入论文级异常特征向量

$$\mathbf{t}_i = (n_i, k\mathrm{trials}, \mathrm{i}, p_i^{\min}, r_i, s_i, d_i, g_i, u_i)^\top,$$

经 MLP 得到 tabular 表征 $\mathbf{z}_i^{\mathrm{tab}}$，并与序列表征拼接：

$$\mathbf{z}_i^{\mathrm{fuse}} = [\mathbf{z}_i; \mathbf{z}_i^{\mathrm{tab}}],$$

再输入融合分类头得到预测概率。该结构旨在同时利用“序列形态信息”（更敏感于 p-hacking 的显著性结构）与“显式法医特征”（更敏感于 fabrication 的离散化/重复结构）。

2.9 训练目标与优化

两类模型均通过多分类交叉熵损失训练：

$$\mathcal{L}(\theta) = -\frac{1}{N}\sum_{i=1}^{N}\sum_{c=0}^{3}\mathbb{I}(y_i = c)\log \Pr_\theta(y_i = c).$$

采用 AdamW 优化器，学习率 η 与权重衰减 λ 为超参数；训练过程中对梯度范数进行裁剪以提升稳定性：

$$\theta \leftarrow \theta - \eta\nabla_\theta\mathcal{L}, \qquad \|\nabla_\theta\mathcal{L}\| \le \tau.$$

2.10 评估指标与可视化

为全面刻画多机制检测表现，我们使用以下指标与图形：

- **Macro-F1**：对类别不平衡更稳健的总体指标。
- **混淆矩阵**：采用按行归一化形式，表示每一真实类别的召回分布。
- **One-vs-Rest ROC / PR**：分别报告 Macro AUC 与 Macro AP，以避免仅用准确率掩盖少数类性能。
- **嵌入可视化（t-SNE/UMAP）**：对模型中间表征进行二维可视化，用于定性评估类别可分性（仅作为辅助证据）。
- **现象级可视化（独立于模型）**：包括 p 值分布、阈值放大图、离散化与数字偏好指标、重复结构指标以及机制指纹热图，用于展示造假机制如何改变统计与报告形态。

2.11 声明

这一章节没啥用。

3. 实验结果与分析

本节基于四张“模型层面”图对两类模型（序列模型与融合模型）的训练动态与判别能力进行对比分析。总体而言，融合模型在当前合成数据与特征构造下达到近乎上界的可分性，而仅基于 p 值/效应序列的序列模型主要对 p-hacking 机制更敏感。

3.1 学习曲线：收敛行为与泛化表现

图 1 展示了训练交叉熵损失与测试集 Macro-F1 随 epoch 的变化。序列模型的训练损失缓慢下降后在较高水平进入平台期，同时测试 Macro-F1 提升有限并趋于稳定，提示其在仅使用序列输入时对四类机制的区分信息不足。融合模型则在极

少 epoch 内将训练损失降至接近 0，并在测试集上迅速达到接近完美的 Macro-F1，表明所构造的统计汇总特征为机制识别提供了强判别信号。

3.2 序列模型的机制可检测性差异

为刻画序列模型在不同机制上的区分能力，图 2 给出了 one-vs-rest ROC 曲线。该模型在 p-hacking 类上具有明显更高的 AUC，而在 fabricate 与混合机制 both 上 AUC 偏低，说明仅凭序列形态更容易捕捉“显著性结构”的变化，却难以稳定识别主要体现为离散化、末位偏好与重复结构的机制信号。

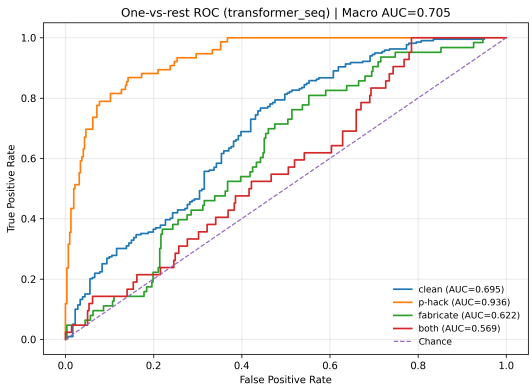

图 2: 序列模型的 one-vs-rest ROC 曲线：不同机制类别的可检测性存在显著差异。

3.3 融合模型的近零错误率与表征可分性

图 3 给出了融合模型的归一化混淆矩阵。其对角线为 1.00 且非对角元素为 0.00，表明测试集上不存在类别混淆，与图 1 中的近完美 Macro-F1 一致。进一步地，图 4 对融合模型的表格特征分支嵌入进行 t-SNE 可视化，四类样本在二维空间形成紧密且相互分离的簇结构，说明仅依赖统计汇总特征即可学习到高度类可分的表征。需要指出，t-SNE 为非线性可视化方法，其几何距离不应过度解读，但在本实验中清晰分簇与零错误率相一致，可作为表征可分性的直观佐证。

3.4 小结

这一章其实还画了很多图，但确实是没啥用，所以放了几张代表性的，主要是做一个可视化，增强文章的美观度和可读性。

4. 结论

本文针对学术造假与“水论文”这一敏感话题进行了统计深度学习建模以及结果分析，得到了一系列的数据推动的结论。结论表明，学术造假可以通过一些量化指标进行判别。

有趣的是，本文进行探究的学术论文数据也是假的，是我们生成的，虽然不能完全说是编造，

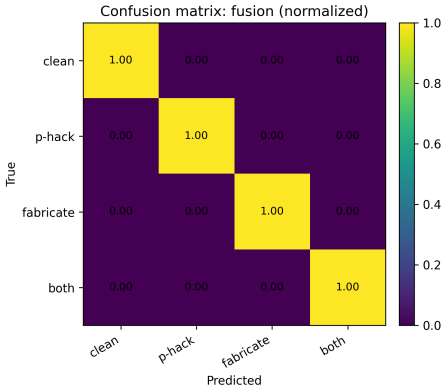

图 3: 融合模型的归一化混淆矩阵：测试集上四类机制实现完全分辨。

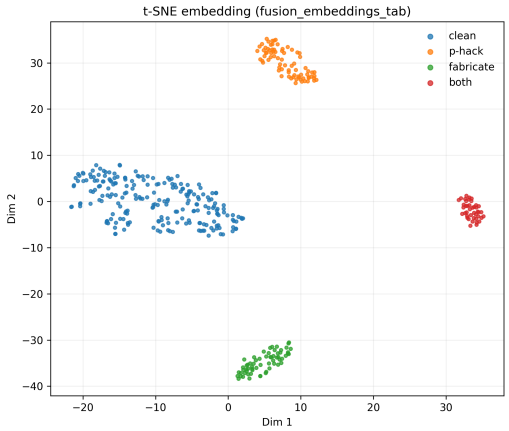

图 4: 融合模型的表格特征分支嵌入的 t-SNE 可视化：四类机制在嵌入空间中形成清晰、分离的簇。

但我们完全可以实现，让结论更符合我们的预期。我不建议大家学术造假，包括但不限于，数据造假，过度平滑等方法。

但是本文还有另一个议题——“水论文”，可以说是为了这瓶醋，包了这盘饺子。水论文一直以来被大家当作一个不好的行为，呼吁大家做一些有意义的论文，创新型十足的论文。但是，有意义的论文，或者说创新型很足的论文，真的是大部分人能做出来的吗？还有很多人说，中国的“水论文”很多，国外的“水论文”数量少。这其实就是一个基数的问题，我们小学三年级就学过，中国人口基数很大，那么自然科研基数也大，如果“水论文”的比例一致的话，我们的数量自然超出去很多。那么既然大家对于能否做出真正意义上可落地，可应用的论文这个问题充满疑惑，为什么不通过“水论文”先积攒经验值，为自己增加论文数量。

真正看过论文的人就知道，很多顶刊，一区

论文也有很水的，说白了就是搭积木，那么为什么还能发这些期刊呢？这些论文也是真正有意义的吗？

最终，思考这个问题过后，写论文为了升学、评奖、毕业、晋升等，这何尝不是对于我们个人的意义呢。如果不是现实意义十分大的论文，但是创新点还可以，且写作也还可以，那么发一些好一点的期刊，这样也未尝不可。所以，不要被这些所谓的不“水论文”的约束给压制，我们的论文无非是现实意义不太足，但是既然有期刊愿意接收，说明是完全够格的。让我们放心大胆地“水论文”吧，至少为了自己的未来。

作者贡献

XIAOBU LV 负责论文润色及想法表达。

ChatGPT 负责代码实现，数据生成，论文撰写。

致谢

感谢还在努力生活的我们，感谢自己吧，加油！

参考文献

[1] Simmons, J. P., Nelson, L. D., & Simonsohn, U. (2011). False-positive psychology: Undisclosed flexibility in data collection and analysis allows presenting anything as significant. *Psychological Science*, 22(11), 1359–1366.

[2] Fanelli, D. (2013). Why growing retractions are (mostly) a good sign. *PLoS Medicine*, 10(12), e1001563.

[3] Ioannidis, J. P. A. (2005). Why most published research findings are false. *PLoS Medicine*, 2(8), e124.

[4] Head, M. L., Holman, L., Lanfear, R., Kahn, A. T., & Jennions, M. D. (2015). The extent and consequences of p-hacking in science. *PLoS Biology*, 13(3), e1002106.

[5] Gerber, A., & Malhotra, N. (2008). Do statistical reporting standards affect what is published? Publication bias in two leading political science journals. *Quarterly Journal of Political Science*, 3(3), 313–326.

[6] Benford, F. (1938). The law of anomalous numbers. *Proceedings of the American Philosophical Society*, 78(4), 551–572.

[7] Neyman, J., & Pearson, E. S. (1933). On the problem of the most efficient tests of statistical hypotheses. *Philosophical Transactions of the Royal Society of London. Series A*, 231, 289–337.

[8] Simonsohn, U., Nelson, L. D., & Simmons, J. P. (2014). p-Curve: A key to the file-drawer. *Journal of Experimental Psychology: General*, 143(2), 534–547.

[9] Rosenthal, R. (1979). The file drawer problem and tolerance for null results. *Psychological Bulletin*, 86(3), 638–641.

[10] Sterne, J. A. C., & Egger, M. (2001). Funnel plots for detecting bias in meta-analysis: Guidelines on choice of axis. *Journal of Clinical Epidemiology*, 54(10), 1046–1055.

[11] Nigrini, M. J. (2012). *Benford's Law: Applications for Forensic Accounting, Auditing, and Fraud Detection*. Wiley.

[12] Flesch, R. (1948). A new readability yardstick. *Journal of Applied Psychology*, 32(3), 221–233.

[13] Pennebaker, J. W., Boyd, R. L., Jordan, K., & Blackburn, K. (2015). *The Development and Psychometric Properties of LIWC2015*. University of Texas at Austin.