薛定谔的方向盘
赛博修车佬的《自动驾驶生存指南》

姜休*

捞得一研究所，天下市，77777

摘　要：当一辆由 AI 控制的铁壳子在马路上即将面临“物理学超度”时，它该选择献祭车里的乘客，还是带走路上的行人？这就是自动驾驶界的“电车难题”。过去的哲学家们喜欢让 AI 戴上功利主义的眼镜去给人类“估价”，但这些招数都太虚了。与其算计谁的命更值钱，不如直接按游戏逻辑来——咱们来算算谁的“血条”更厚！本文提出了一种极度硬核的“全员掉血最小化算法”。别管你是谁，AI 只关心一件事：怎么撞才能让总体的“生命值（HP）”扣得最少。

关键词：物理超度；赛博道德；功利主义估值；血条保护机制；掉血最小化算法

中图分类号：S123.45　　**文献标识码：**A

1. 引言：引言：欢迎来到地球 Online 的“自动驾驶”资料片

图 1. AI 生死抉择

当人类终于把双手从方向盘上解放出来，准备在副驾驶上安心刷短视频时，硅基生物（AI）却在底层代码里疯狂冒冷汗。在这个名为“自动驾驶”的全新版本中，有一个史诗级的系统 Bug 至今没有修复：当一辆两吨重的钢铁巨兽刹车失灵，且物理引擎判定一场车祸绝对无法避免时，握着方向盘的 AI 该化身为谁的死神？

过去几百年，哲学家们在象牙塔里喝着咖啡，轻描淡写地拿“电车难题”互相抬杠。但现在，这个形而上的思想实验，变成了程序员们明天就得提交（Push）上线的夺命工单。当人类把“生杀大权”交给几行冷冰冰的代码时，AI 到底在算计什么？本文不熬虚无缥缈的道德鸡汤，咱们只用最硬核的物理逻辑和游戏策划的视角，来扒一扒当 AI 面对生死抉择时，它的中央处理器里到底在上演怎样的疯狂博弈。

2. 新手村的哲学死局：电车难题与狂暴铁皮

“电车难题”是个老掉牙的哲学思想实验：一个疯子把五个人绑在轨道上，你手里有个拉杆，拉一下电车变道压死另一个人，不拉就压死这五个。现在，这个疯子失业了，因为自动驾驶汽车接管了这活儿。在 AI 驾驶的物理引擎里，如果汽车刹不住了，直行会把行人（NPC-A）撞成马赛克，打方向盘会让车主（Player-B）连车带人飞下悬崖。AI 该按哪个按钮（图 2）？

麻省理工学院（MIT）曾搞过一个叫“道德机器”的在线吃瓜平台，收集了全球碳基生物对 AI 杀手的偏好[1]。结果非常有意思：东方玩家喜欢“守序善良”，倾向保全遵纪守法的人。西方玩家崇尚“听天由命”，觉得车子就该走直线，撞死谁算谁倒霉。拉美玩家则有点慕强，倾向于救下年轻、健康或地位高的人。虽然各怀鬼胎，

但全人类在三个底层逻辑上达成了共识：人类的命比狗子贵、年轻人的命比老头贵、人多比人少贵。

3. 功利主义计算器：你的社会价值有几斤几两？

图 2. 效用算法

基于上述人类的真实想法，学者们搞出了一套“效用算法”（图 2）。简单来说，这就是一个“社会价值扫描仪”。想象一下，AI 的雷达扫过 A 和 B，瞬间读取了你们的年龄、存款、发量和阶级。AI 一阵狂算后得出结论：小孩、女人、精英和人多的那方，对地球 Online 的版本更新更有用。于是，效用值低的那一方，对不起，你被系统判定为了“可消耗资源”。

这种算法的巅峰代表是早期的谷歌。2016 年，谷歌自动驾驶团队的大佬甚至直白地表示：我们的车会欺软怕硬，为了保护脆弱的肉身（行人和骑手），我们会选择去撞硬邦邦的死物或其他车。这听起来很伟大对吧？89%的人在做问卷时都狂按赞，表示功利主义万岁[2]。但是！人类的本质是双标。当问卷里加上一句：“你愿意花钱买这台随时准备为了拯救路人而把你弹射出去的‘高尚汽车’吗？”受访者的购买意愿瞬间暴跌。这就很尴尬了，大家都想当好人，但都不想当死人。

4. 破局思路：不看身价，看“护甲”的共同伤害最小算法

图 3. 共同伤害最小算法

既然算“社会价值”容易翻车，那我们不如换个物理学思路：放弃身份歧视，直接计算碰撞产生的“物理破坏总量”。这就引出了本文的核武级脑洞——共同伤害最小算法（图 3）。

在这个算法里，AI 不再管 A 是霸道总裁还是 B 是拾荒大爷，A 和 B 被捆绑成了一个命运共同体。算法的唯一 KPI，是确保撞击前后的总“生命值（HP）”流失最少。

高能预警——反直觉的物理学奇迹来了：

假设前方 A 是一个极其瘦弱的脆皮法师，B 是十个正在练金钟罩的肌肉大汉。如果按效用算法，绝对是撞死 A 保全 B 的十个人。但“共同伤害最小算法”一算：

撞 A：脆皮法师承受不住两吨钢铁，HP 归零，致死率 100%。

撞 B：十个大汉由于肉厚防高，加上受力面积分散，结果大家只是擦破皮或骨折，无人死亡。

结论：AI 会一脚油门创向那十个大汉！

这就是该算法的硬核之处：你当前的健康状态越好、当前医疗水平能把你救活的概率越高、你被撞后预期的掉血量越少，AI 就越觉得“你比较抗揍，就撞你了”。

为了让这套粗暴的理论显得有文化，我们必须上一段冰冷无情的数学公式。主体 A 或 B 的当前生命状况记作 $C(x_i)$。自动驾驶汽车所作出的选择将造成的 A 或 B 预期死亡率 $De(r_i, x_i)$，得出车辆动向 r 对主体的共同伤害值 $Da(r_i, x_i)$，当 $Da(r, x)$最小时，得出最佳的车辆动向。最后算法核心表达式为：

$$\min\{ Da(r_i, x_i) = C(x_i) * De(r_i, x_i)\}$$

AI 会以每秒上万次的算力寻找这个方程的最小值，然后优雅地打死方向盘。

5. 总结：宇宙的终极玩笑

其实，不论是高高在上的“效用算法”，还是粗暴硬核的“掉血最小化算法”，从数学的宏观视角来看，它们都在给 A 和 B 打分。当你把样本量放大到几千万次车祸时，你会发现一个地狱笑话：无论用哪种算法，最终 A 和 B 被献祭的比例都会无限趋近于 50%对 50%。

这个世界是一个巨大的物理引擎，充满了无法完美解决的 Bug。没有哪一种道德代码能适应所有的车祸现场。我们唯一能做的，就是不断地给 AI 喂数据，让它在面对混乱的现实时，尽可能做出一个少挨点骂的决定。

参考文献（References）

[1] Maxmen A. Self-driving car dilemmas reveal that moral choices are not universal[J]. Nature, 2018, 562(7728): 469-469.

[2] Hauser,M.D.,Cushman,F.,Young,L.A. Dissociation Between Moral Judgments and Justification[J].Mind&Language,2007,22(1):1-21.

Schrödinger’s Steering Wheel: A Cyber-Mechanic's Survival Guide to Autonomous Driving

Ender Jiang*

Lao De Yi Research Institute, Tianxia 777777, China;

Abstract: When an AI-controlled iron box on the street is about to face a "kinetic exorcism," should it choose to sacrifice the passengers inside or wipe out the pedestrians outside? This is the autonomous driving industry's ultimate "Trolley Problem." Old-school philosophers loved making AIs wear utilitarian goggles to "price-tag" humanity, but those gimmicks are way too flimsy. Instead of calculating whose life is worth more, why not just apply straight-up gaming logic: let's calculate whose "HP bar" is thicker! This paper proposes an extremely hardcore "Total HP Loss Minimization Algorithm." No matter who you are, the AI only cares about one thing: how to crash in a way that deducts the least overall "Health Points (HP)."

Key words: kinetic Exorcism; cyber-morality; utilitarian valuation; HP bar protection mechanism; HP-Loss minimization algorithm