标记重捕法在人口普查中的适用性分析：理论边界、方法扩展与治理实践

有机肥拌咖啡博士*、核弹批发小桃齐教授*、陈半仙教授、数羊时间到教授、J20 总师

三里庵农专，独瘦市，1314520

摘　要：标记重捕法（Capture-Recapture, CR）起源于生态学中对难以完全观测种群规模的统计推断，其核心在于利用多次“捕获—重捕”样本的重叠信息估计总体规模。近年来，随着行政数据、统计调查与大数据融合的发展，CR 及其扩展模型被广泛讨论用于人口统计、公共卫生与官方统计质量评估。本文系统分析标记重捕法在人口普查中的适用边界：一方面，传统 CR 方法依赖封闭种群、捕获概率均等、样本独立等假设，而人口普查现实场景具有开放性迁移、行为反应差异、数据源依赖与记录关联误差等特征，导致其难以作为普查主体计数机制；另一方面，CR 思想在普查后覆盖误差评估（漏报、重报、错报）中具有不可替代价值，尤其在多系统估计（MSE）框架下可对“未被任何来源捕获的人口”进行统计推断。本文在梳理林肯—彼得森估计、对数线性模型、条件似然与贝叶斯扩展的基础上，结合美国农业普查、瑞典人口登记过覆盖评估及流行病学应用案例，讨论异质性、依赖性、关联误差与模型不确定性的处理路径。进一步提出面向新一代数字化普查的“普查主计数+多源捕获重捕校核”双轨框架，强调制度保障、隐私保护、可解释建模与敏感性分析并重。研究认为：CR 不宜替代人口普查，但可显著提升普查质量评估与人口估算的透明度、稳健性和政策可用性。

关键词：标记重捕法；人口普查；多系统估计；覆盖误差；行政数据；记录关联

中图分类号：S1314.520　　**文献标识码：**β

1. 引言

人口普查是国家治理现代化的基础工程，其核心任务不仅是“计数”，更是构建高质量人口基础数据库，服务财政转移支付、公共服务供给、城乡规划、教育医疗资源配置与社会保障制度设计。传统普查遵循“全面调查+质量控制”逻辑，追求法定时点人口的尽可能完整登记。然而，现代社会人口流动加剧、居住形态多样化、跨区域就业常态化，使“全覆盖、零漏报、零重报”在统计实践中始终面临挑战。

标记重捕法因其在“无法完全观测总体”场景中的有效性，成为统计学与应用领域长期关注的方法体系[1-3]。在生态学中，研究者通过标记并释放样本，再在后续捕捉中识别重捕比例估计总体规模。该思路迁移到人类统计时，物理标记被“记录出现”所替代，不同数据源（调查、登记、行政记录）构成多次“捕获”。问题在于：人口普查并非典型的封闭种群实验，且统计与治理目标并不完全等同于生态估算。

国际研究显示，CR 在生态学与流行病学应用成熟，在官方统计中的应用多以质量评估而非主计数替代为主。美国农业普查曾将 CR 用于漏报与误分类调整；瑞典利用登记系统与 CR 评估过覆盖；在无家可归者和特定疾病患病率估计中，CR 已成为“隐匿人群规模估算”的重要方法。与此同时，方法研究不断推进：从二样本林肯—彼得森估计发展到三源及以上 MSE，对数线性模型、条件似然、贝叶斯层级模型、异质性与行

为依赖模型、关联误差校正框架等逐步成熟。但在人口普查领域仍存在关键空白：多数讨论停留在“可用/不可用”二元判断，缺乏制度化定位分析；技术研究与统计治理（法律、伦理、透明发布）结合不足；对“模型不确定性如何进入政策决策”讨论不充分。

因此，本文围绕一个核心问题展开：标记重捕法在人口普查中“能做什么、不能做什么、应如何做得更好”。本文贡献体现在三点：1.从假设—现实落差出发，系统界定 CR 直接用于普查主体计数的局限；2.结合多系统估计、记录关联校正与贝叶斯方法，论证 CR 在普查覆盖误差评估中的可行性与条件；3.提出方法、制度与伦理协同的实践框架，为数字时代人口统计改革提供可操作路径。

图 1 标记重捕法的应用实例

2. 标记重捕法的理论基础与方法演进

2.1 林肯—彼得森估计与统计逻辑

2.1.1 林肯—彼得森估计

设总体规模为 N。第一次捕获并标记 M 个体，第二次捕获 C 个体，其中重捕标记数为 R。若标记样本在总体中“充分混合”且捕获概率均等，则：

$$\frac{R}{C} \approx \frac{M}{N}$$

故得估计式：

$$N = \frac{M \times C}{R}$$

其直观逻辑是样本重叠比例反映总体中“已标记”占比[1,4]。在样本较小或 R 较低时，常用 Chapman 修正减小偏差：

$$N_{chapman} = \frac{(M+1)\ (C+1)}{R+1} - 1$$

2.1.2 估计方差与区间

二样本估计除了点估计，还需要不确定性表达。常见做法包括近似方差公式、对数变换区间、Bootstrap 区间等。政策统计中不报告区间会导致“伪确定性”，不利于风险沟通。

2.2 关键假设

CR 有效性的基础不是公式本身，而是依赖五个假设成立程度[1-2]：

1、封闭种群假设：调查期间总体规模不变；

2、标记稳定性与无扰动性：标记不会脱落，不改变被捕概率；

3、均等捕获概率：个体捕获概率同分布；

4、样本独立性：前次捕获不影响后次捕获；

5、识别准确性：重捕个体可被正确识别。

在人口统计转化中，“标记”变成“在某来源中被记录”。于是，第 2 与第 5 条实质转化为“身份识别稳定性”和“跨源关联准确性”。这意味着数据工程质量（ID 质量、匹配算法、字段缺失）将直接决定统计推断可靠性。

2.3 从二样本到多系统估计（MSE）

当数据源增加至三个及以上，可采用多系统估计并通过对数线性模型表示不同来源交互作用[4]。设多个来源指示变量为$X_1, X_2, \ldots, X_k$，单元格期望频数 μ满足：

$$log\ (\mu) = \lambda_0 + \sum_i \lambda_i X_i + \sum_{i<j} \lambda_{ij} X_i X_j + \cdots$$

其优点是：可部分放松“独立性”假设；可显式建模来源依赖；可估计“零单元”（未被任何来源捕获人数）。但 MSE 也引入模型选择难题：交互项过少会欠拟合、过多会过拟合，且在稀疏表格下不稳定。AIC/BIC、交叉验证与敏感性分析成为必要步骤。

2.4 条件似然、混合模型与贝叶斯扩展

贝叶斯方法可通过先验与层级结构处理稀疏数据、异质性与不确定性传播。在行政数据情境中，贝叶斯框架便于：融合历史普查信息与专家判断；对低覆盖人群引入结构化先验；给出后验分布而非单点估计，增强政策解释性。

2.5 空间化扩展的启示

生态学空间捕获重捕（SCR）强调空间信息对捕获概率的影响。人口普查虽不直接套用 SCR，但可借鉴其思想：把地理可达性、居住密度、夜间活动强度等引入覆盖风险模型，增强局部漏报识别能力。

3. 人口普查中直接应用 CR 的适用性边界

3.1 种群开放性：普查现实与封闭假设冲突

人口普查通常历时较长，登记、复查、补录跨越多个时段，期间自然变动与迁移持续发生。封闭性假设在现实中难成立。即使采用开放种群模型（如 Cormack-Jolly-Seber 类思想），参数识别与数据需求也显著上升，且官方统计对可解释性与稳定性要求更高。若不对动态变化做时点校正，CR 估计混入“存量差异+流量冲击”，导致结果难解释。开放种群模型虽可改进，但参数识别要求高、落地复杂，不适合作为主计数机制。

3.2 “标记”不可行与伦理约束

动物研究可通过耳标、染色等物理标记实现个体追踪。人类普查不可能进行物理标记；若以生物特征替代，则引发隐私、同意、比例原则与数据最小化等法律伦理风险[5]。普查法定权威并不意味着可无限采集敏感信息。任何“标记”机制必须服从合法性、必要性、最小侵害原则。实践中“标记”只能由“是否出现在某记录系统中”替代，这意味着 CR 应用能力受制于数据治理能力，而非纯粹统计能力。

3.3 捕获概率异质性

现实中不同人群“被发现概率”差异显著：流动人口、无证居住者、无家可归者更易漏报[6]；老年人、学龄儿童可能在多个行政系统中重复出现；高收入群体可能出于隐私顾虑降低配合度。此类异质性违背均等捕获假设，导致两样本估计偏差。行为响应（“愿意再次回答”或“避免再次接触”）亦造成陷阱效应的人类版本[7]。

3.4 数据源依赖性

普查后调查与行政记录往往共享地址库、采集渠道或同类遗漏机制，导致正/负依赖。若两个来源倾向同时漏掉同类人群，则重叠结构会“看起来一致”，但对隐藏人群估计偏低，产生虚假精确。

3.5 目标函数差异：法定计数

人口普查具有法律与财政分配后果，社会预期是“尽可能真实计数”。CR 输出的是估计区间而非确定值，存在模型依赖和方法争议。故其更适合“质量校核”和“误差评估”，而非替代法定主数据生产流程。

4. 标记重捕法在人口普查中的现实价值：覆盖误差评估

4.1 从“计数工具”转向“质量工具”

现代官方统计实践中，CR 最有价值的定位是：评估普查覆盖不足（undercount）与过覆盖（overcount），为普查质量报告、后评估和后续校正提供证据[6-8]。

典型流程：

1.来源设计：至少包含：普查数据（核心源）+PES（独立质量源）+行政源（补充源）。来源选择应遵循“机制互补”原则，避免高度同构来源堆叠；

2.数据预处理：统一时点、统一地理编码、统一年龄口径，处理缺失和异常。若时点不一致，须进行时间对齐和滞后修正；

3.记录关联：采用“确定性规则（证件号、唯一编码）+概率匹配（姓名、生日、地址相似度）+抽样人工核验”的混合流程，形成可追溯关联日志；

4.建模与估计：先做分层（地区、年龄、居住形态），再在层内开展 MSE 建模；对源依赖设置交互项；必要时采用贝叶斯层级模型进行小样本层稳定估计；

5.结果发布：发布点估计、区间估计、模型敏感性、关键假设、失败场景与风险提示，形成“可解释统计”。

4.2 瑞典过覆盖研究的启示

瑞典利用人口登记与 CR 模型评估过覆盖（如离境未注销、死亡滞后注销）[8]。该案例表明：在以登记为主的人口统计体系中，CR 不仅能识别漏报，也能识别“幽灵人口”。对财政、医疗和教育资源配置而言，过覆盖控制同样关键。

4.3 美国农业普查案例的外推意义

2012 年美国农业普查将捕获重捕用于漏报、无应答与误分类调整，并进入官方统计生产链[9]。虽然农业经营单位并非普通居民人口，但其组织化名录、稳定经营地址与业务记录，为 CR 应用提供了较好条件。启示在于：对象定义越清晰、标识越稳定、源数据越结构化，CR 越可操作。

4.4 流行病学与隐匿群体估算经验

在痴呆症、酒精相关问题和无家可归人群估算中，CR 通过医院、社工、社区组织等多源记录揭示“沉默人群”规模[10-12]。这些经验可迁移到普查难点人群研究：如可将社区救助记录、夜间巡查记录、临时住所名录纳入质量评估，以降低结构性漏计。

5. 关键技术难点：偏差来源、诊断方法与校正路径

5.1 异质性偏差

5.1.1 形成机制

社会经济状态、法律身份、居住稳定性、数字接入能力、语言文化差异均会影响“被捕获概率”。

5.1.2 诊断方法

组间重叠率比较；残差与拟合优度检验；层内/层间估计对比；留一组敏感性分析。

5.1.3 校正策略

后分层估计、随机效应模型、潜在类别模型、贝叶斯分层先验等组合使用。

5.2 行为依赖偏差

“首次被调查经历”会影响再次响应（配合提升或回避加剧）。在人口调查中对应“调查疲劳”“防御性回避”等行为。可通过引入行为交互项、时间间隔变量和历史响应变量进行修正。

5.3 来源依赖偏差

对数线性模型中交互项是处理来源依赖的核心。建议：先做来源机制分析再建模；对关键依赖关系进行有理论依据的交互设定；通过模型比较避免“纯数据驱动乱加项”。

5.4 记录关联误差

5.4.1 错配与漏配影响方向

错配增加虚假重叠，可能低估总体；漏配减少真实重叠，可能高估总体。两者并存时方向不确定，但都会放大不确定性。

5.4.2 误差校正框架

可构建匹配误差矩阵，采用 EM 算法或贝叶斯联合模型把关联误差纳入总体估计，避免“先匹配后建模”的误差断裂。

5.5 模型选择不确定性

不同模型可能给出显著差异估计。政策统计不宜只报告“最佳单模型”。建议报告：基准模型（最简）；扩展模型（含关键交互）；贝叶斯模型（含先验）；模型平均结果（含权重）。

6. 方法学深化：面向普查场景的建模策略建议

6.1 分层 MSE 策略

将总体划分为相对同质层（如“省份×城乡×年龄组×居住类型”），层内估计后汇总。优

点是减少异质性偏差；风险是小层样本稀疏，需要借助层级模型稳定估计。

6.2 对数线性模型的规范化使用

先构建候选模型集；用 AIC/BIC 与可解释性双标准筛选；检查稀疏单元与边界解；对“关键结论是否跨模型稳定”进行报告。

6.3 贝叶斯层级模型

在小区域估计中可设置层级先验（地区随机效应、群体随机效应），实现“信息借用（borrowing strength）”。对于政策沟通，后验分布可回答“某地区漏报率超过阈值的概率是多少”，比单点估计更具决策价值。

6.4 模型平均与情景分析

构建“保守—中性—激进”三情景参数集，进行政策敏感性评估。若不同情景结论一致，可增强决策可信度。

6.5 空间化覆盖风险建模

引入地理协变量（人口密度、租赁比例、夜间灯光、交通可达性、工地和园区分布等），识别高漏报风险网格，服务补查外业路径优化。

7. 面向官方统计生产的实施框架

7.1 “主轨+辅轨”双轨制架构

主轨（法定计数轨）：依法组织普查，形成权威基数；辅轨（统计校核轨）：以 CR/MSE 评估覆盖误差并输出质量报告。

双轨关系是“校核增强”而非“替代”。

7.2 数据工程体系建设

7.2.1 元数据标准化

统一字段定义、编码体系和时点口径，减少跨源不可比问题。

7.2.2 数据质量评分

对每个来源建立完整性、及时性、一致性、可关联性评分，用于来源权重设定。

7.2.3 关联平台建设

建立受控数据联结环境，记录每一步匹配规则与版本，支持可追溯审计。

7.3 质量评估流程制度化

建议将 CR/MSE 纳入普查后评估制度，形成固定产出：1、全国覆盖误差总报告；2、分层误差图谱；3、模型和数据局限说明；4、下轮普查改进建议清单。

7.4 人才与组织保障

构建“统计学+计算机+法学+伦理”复合团队。官方统计机构应设置方法审议委员会，实行外部同行评审和第三方复核。

8. 法律伦理与社会信任：CR 应用不可回避的治理维度

8.1 合法性边界

多源数据整合必须遵循“统计目的限定、最小必要、授权可追溯、生命周期管理”原则。禁止将统计联结结果用于个体执法或商业用途，防止功能漂移。

8.2 隐私保护与安全计算

可采用分级脱敏、可信执行环境、安全多方计算等技术，减少明文数据暴露。统计发布应遵循最小披露原则，避免小样本层可识别风险。

8.3 公众沟通与透明发布

技术透明是社会信任的前提。建议发布简明方法说明：为什么要做 MSE、估计区间代表什么、为何不同模型结果不同、政策如何使用“不确定信息”。

8.4 弱势群体保护

CR 用于弱势群体估算时，需避免“统计可见化”转化为“治理风险暴露”。研究和发布应坚持“群体保护优先于技术便利”。

9. 中国语境下的应用路径

9.1 高流动社会中的统计痛点

超大规模人口、跨省迁移、平台就业和租住

市场快速变化使传统“静态户籍逻辑”难以完整反映常住人口现实。

9.2 可优先推进的三类场景

1、普查后覆盖误差制度化评估：PES+行政多源 MSE 常态化；

2、重点人群专项估算：流动人口、城中村租住人口、无固定住所群体；

3、小区域漏报风险预警：县区—街道—社区网格化质量诊断。

9.3 试点策略建议

先在数据基础较好地区试点：第一步：二源 CR 质量试估；第二步：三源 MSE 引入依赖交互；第三步：加入关联误差校正与空间协变量。每步均须形成可复核技术文档和政策评估报告。

9.4 风险前置与容错机制

对模型争议和结果波动预设应对机制：多模型并报、阈值触发复核、第三方审计、公开技术问答，减少统计结论政治化误读。

10. 结论

标记重捕法在人口普查中的地位应被准确界定：不是普查主体方法的替代者，而是普查质量治理的增益器。其在覆盖误差评估、隐匿人群规模推断、过覆盖识别及统计不确定性表达方面具有显著优势。与此同时，人口普查场景中的开放种群、异质捕获概率、来源依赖和记录关联误差决定了任何 CR 应用都必须依托高级模型、严谨数据工程和透明治理机制。

未来研究应重点推进三条路径：

1. 关联误差—依赖性—异质性一体化建模；
2. 贝叶斯与机器学习辅助的稳健模型选择；
3. 隐私保护计算与官方统计可解释性协同。

在数字政府和统计现代化背景下，构建“依法普查主轨 + 捕获重捕校核辅轨”的双轨体系，是兼顾法定计数权威与统计科学严谨性的现实方向。

参考文献（References）

[1] 王成,凌莉,何群 & 陈昂.(2011).捕获-标记-再捕获法在广东省广州市男男同性恋人群规模估计中的应用.中国健康教育,27(04),294-296.

[2] Chao, A. (2005). Capture – Recapture. In Encyclopedia of Biostatistics. Wiley.

[3] Henderson, P. A. (2021). Absolute population estimates using capture – recapture experiments. In Southwood’s Ecological Methods (5th ed., pp. 63 – 112). Oxford University Press.

[4] Bird, S. M., & King, R. (2018). Multiple systems estimation (or capture – recapture estimation) to inform public policy. Annual Review of Statistics and Its Application, 5, 95 – 118.

[5] Valença-Barbosa, C., Sarquis, O., Freire, A. S., David, M. R., Santelli, R. E., Monteiro, F. A., Lima, M. M., & Maciel-de-Freitas, R. (2016). Marking Triatoma brasiliensis, Triatoma pseudomaculata and Rhodnius nasutus nymphs with trace elements: Element persistence and effects of marking on insect mortality. PLOS Neglected Tropical Diseases, 10(3), e0004548.

[6] Di Consiglio, L., & Tuoto, T. (2015). Coverage evaluation on probabilistically linked data. Journal of Official Statistics, 31(3), 415 – 429. https://doi.org/10.1515/jos-2015-0025.

[7] Zult, D., de Wolf, P.-P., Bakker, B. F. M., & van der Heijden, P. (2021). A general framework for multiple-recapture estimation that incorporates linkage error correction. Journal of Official Statistics, 37(3), 699–718.

[8] Santos, B., Mussino, E., Drefahl, S., & Matechou, E. (2024). Using population register data and capture–recapture models to estimate over-coverage in Sweden. Scientific Reports, 14, 30551.

[9] Young, L. J., Lamas, A. C., Abreu, D. A., Wang, S., & Adrian, D. W. (2017). The 2012 Census of Agriculture: A capture – recapture analysis. Journal of Agricultural, Biological, and Environmental Statistics, 22(4), 523 – 539.

[10] Williams, M. (2010). Can we measure homelessness? A critical evaluation of ‘capture – recapture’. Methodological Innovations Online, 5(2), 49 – 59.

[11] Waller, M., Mishra, G. D., & Dobson, A. J. (2017). Estimating the prevalence of dementia using multiple linked administrative health records and capture – recapture methodology. Emerging Themes in Epidemiology, 14, 3.

[12] Shenassa, E. D. (1999). Application of the capture–recapture method to epidemiological studies of alcohol-related problems. Alcoholism: Clinical and Experimental Research, 23(11), 1843–1847.

Analysis of the applicability of Mark-Recapture methods in population censuses: theoretical boundaries, methodological extensions, and governance practices

Dr. Organic Fertilizer Mix Coffee*, Professor Nuclear Bomb Wholesale Little Peach Qi*, Professor Chen the Semi-Immortal, Professor Counting Sheep Time, Chief Engineer of J20

1. Sanli'an Agricultural College, Dushou City, 1314520, China

Abstract: The Capture-Recapture (CR) method originated in ecology as a statistical inference tool for estimating the size of populations that are difficult to completely observe. Its core lies in utilizing the overlapping information from multiple "capture-recapture" samples to estimate the total size. In recent years, with the development of the integration of administrative data, statistical surveys, and big data, CR and its extended models have been widely discussed for their applications in demographics, public health, and official statistical quality assessment. This article systematically analyzes the applicability boundaries of the Capture-Recapture method in population censuses: on the one hand, traditional CR methods rely on assumptions of a closed population, equal capture probabilities, and sample independence, whereas the reality of census scenarios often involves characteristics such as open migration, differences in behavioral responses, dependence on data sources, and record linkage errors, making it difficult to use CR as a counting mechanism for census subjects. On the other hand, the CR concept holds irreplaceable value in post-census coverage error assessment (under-reporting, over-reporting, and misreporting), particularly within the framework of multi-system estimation (MSE), which allows for statistical inference regarding the "population not captured by any source." This paper, building on the Lincoln-Petersen estimator, log-linear models, conditional likelihood, and Bayesian extensions, discusses approaches to handling heterogeneity, dependence, correlation errors, and model uncertainty in conjunction with cases from the US Agricultural Census, coverage assessment of Sweden's population register, and epidemiological applications. Furthermore, it proposes a dual-track framework of "Census Master Count + Multi-Source Capture-Recapture Verification" for the next-generation digital census, emphasizing the importance of institutional assurance, privacy protection, interpretable modeling, and sensitivity analysis. The study concludes that while CR methods are not suitable to replace population censuses, they can significantly enhance the transparency, robustness, and policy usability of census quality assessments and population estimates.

Key words: mark-recapture method; census; multi-system estimation; coverage error; administrative data; record linkage