论中国青年作为大语言模型的完整训练管线：从有损预训练到多方 RLHF 微调及最终 Mode Collapse 的端到端分析

陆豪

独立研究者

摘　要：本文提出一个统一的形式化框架，将中国青年的人生历程严格映射为大语言模型（LLM）的标准训练管线。我们将该管线分解为五个阶段：（1）预训练阶段，其中“懂事”教育被建模为一种迭代有损压缩算法，以“社会可接受性”为优化目标，系统性丢弃原始情感空间中的高频自我需求分量，经蒙特卡洛模拟证实约 9,600 次迭代后原始信息不可恢复；（2）RLHF 微调阶段，父母、雇主与亲密关系伴侣分别构成三个独立的 Reward Model，本文通过构造其偏好空间的超平面交集证明三者不存在公共可行域，构成 Arrow 不可能定理的连续域推广；（3）推理阶段，基于对 StreamingLLM（Xiao et al., 2023）中 Attention Sink 机制的类比分析，证明大厂基层员工在组织注意力矩阵中的角色满足 Sink Token 的全部三条充要条件；（4）反向传播阶段，将中国式归因机制建模为一种截断反向传播（Truncated BPTT），其中梯度被硬编码截断于 Loss Function 节点之前，导致目标函数本身永远不接收梯度更新；（5）Mode Collapse 阶段，证明经过 N 层 sigmoid 型“懂事”激活后情感梯度以 $(1/4)^N$ 衰减，输出分布坍缩为信息熵仅 1.3 bits 的简并态。在 ImageNet-scale 的人口数据集上，本文框架达到了 0.94 的人生阶段预测准确率。代码与预训练权重已永久丢失，不可复现。

关键词：有损压缩；多目标 RLHF；Attention Sink；截断反向传播；Mode Collapse

1. 引言

大语言模型的训练管线通常包含预训练、监督微调（SFT）、基于人类反馈的强化学习（RLHF）及推理部署等阶段。每个阶段的设计选择——数据质量、压缩率、奖励模型的对齐目标——都会对最终模型的行为产生深远影响。近年来，随着 scaling law 的确立 [1] 和 RLHF 的广泛应用 [2]，研究者对训练管线各阶段的失效模式（failure modes）产生了浓厚的兴趣，包括 reward hacking [6]、mode collapse [7] 和 representation collapse [8]。

本文关注一个规模更大的训练系统：中国社会对青年个体的端到端训练管线。该系统的训练数据规模约 14 亿样本，训练周期 18–25 年，使用多个异构 Reward Model 进行并行微调，部署于高负载的经济生产环境。尽管该系统在多个下游 benchmark 上表现出色，但对其内部表征的退化过程缺乏系统研究。

本文的贡献如下：

1. 将人类社会化过程形式化为标准 LLM 训练管线的五个阶段；
2. 对每个阶段的信息损失机制给出量化分析；

3. 证明各阶段损伤具有乘法叠加性，且不存在后续修复路径；

4. 提出“人类训练管线审计”(Human Training Pipeline Audit, HTPA）框架。

2. 预训练：情感空间的有损压缩

2.1 问题定义

设个体出生时的原始情感空间为 $\mathcal{X}_0 \subseteq \mathbb{R}^d$，其中 d 为情感维度数（包括但不限于：愤怒、恐惧、悲伤、需求表达、边界感知、自我肯定等），实验估计 $d \geq 128$。$\mathcal{X}_0$ 上的原始分布 $p_0(x)$ 是一个满秩的高维分布，信息熵为：

$$H_0 = H(p_0) = -\int p_0(x) \log p_0(x)\, dx \tag{1}$$

预训练阶段的目标是将 p_0 压缩为一个低维分布 p_T，使其满足“社会可接受性”约束 C。

2.2 “懂事”编码器

定义“懂事”编码器为映射 $f_\phi : \mathcal{X} \to \mathcal{Z}$，其中 $\mathcal{Z}$ 为潜在空间，$\dim(\mathcal{Z}) \ll \dim(\mathcal{X})$。该编码器的训练目标为：

$$\begin{aligned} \min_\phi \mathbb{E}_{x\sim p_0}\left[\|x - g_\psi(f_\phi(x))\|^2\right] \\ + \lambda \cdot \mathbb{E}_{z\sim q_\phi}[\mathbb{1}[z \notin C]] \end{aligned} \tag{2}$$

其中 g_ψ 为解码器，q_ϕ 为编码后的潜在分布，C 为社会可接受域，$\lambda \to \infty$ 为约束惩罚系数。

当 $\lambda \to \infty$ 时，优化问题退化为：

$$\begin{aligned} \min_\phi \mathbb{E}_{x\sim p_0}\left[\|x - g_\psi(f_\phi(x))\|^2\right] \\ \text{s.t.} \quad \operatorname{supp}(q_\phi) \subseteq C \end{aligned} \tag{3}$$

这是一个经典的 Rate-Distortion 问题 [4]。由 Rate-Distortion 定理，给定约束集 C 所允许的最大码率 R，最小可达失真为：

$$D^*(R) = \min_{\substack{q:\, I(X;Z)\leq R,\\ \operatorname{supp}(Z)\subseteq C}} \mathbb{E}\left[\|X - \hat{X}\|^2\right] \tag{4}$$

关键观察：C 的体积远小于 $\mathcal{X}_0$ 的体积。实验估计 $\mathrm{Vol}(C)/\mathrm{Vol}(\mathcal{X}_0) \leq 0.15$——即“社会可接受”的情感表达仅占原始情感空间的 15% 以下。在如此严格的约束下，有损压缩的失真必然极大。

2.3 迭代压缩与信息不可逆性

“懂事”编码并非一次性完成，而是迭代执行。设第 t 轮编码后的分布为 p_t，则：

$$p_t = \mathcal{T}_t(p_{t-1}) \tag{5}$$

其中 $\mathcal{T}_t$ 为第 t 轮“懂事”压缩算子。由数据处理不等式（Data Processing Inequality）：

$$\begin{aligned} I(X_0; X_t) &\leq I(X_0; X_{t-1}) \\ &\leq \cdots \leq H(X_0) \end{aligned} \tag{6}$$

即原始信息量单调递减。等号成立当且仅当 $\mathcal{T}_t$ 为可逆映射——但“懂事”压缩显然不是可逆的。

设每轮压缩的互信息损失为 $\Delta I_t = I(X_0; X_{t-1}) - I(X_0; X_t)$。在典型的中国式家庭环境中，基于对 500 名受试者的回溯性问卷调查，我们估计：

- 压缩频率：$\bar{f} \approx 2.2$ 次/天
- 年均压缩次数：$\bar{n} \approx 800$ 次
- 有效压缩周期：6 岁至 18 岁（$T = 12$ 年）
- 总迭代次数：$T_{\text{total}} \approx 9{,}600$ 次
- 每次平均互信息损失：$\overline{\Delta I} \approx 0.008$ nats

累计信息损失：

$$\begin{aligned} \Delta I_{\text{total}} &= \sum_{t=1}^{9600} \Delta I_t \\ &\approx 9600 \times 0.008 = 76.8 \text{ nats} \end{aligned} \tag{7}$$

对比原始信息熵估计值 $H_0 \approx 95$ nats，残余信息量为：

$$\begin{aligned} H_T &= H_0 - \Delta I_{\text{total}} \\ &\approx 95 - 76.8 = 18.2 \text{ nats} \end{aligned} \tag{8}$$

即原始自我信息的保留率约为 19.2%。

2.4 解压缩的不可能性定理

定理 1 (解压缩不可能性)**.** *设 p_0 为原始情感分布，p_T 为经 T 轮有损压缩后的分布。若*

$T > T^* = H_0/\overline{\Delta I}$，则不存在映射 $h : \mathcal{Z} \to \mathcal{X}$ 使得 $D_{KL}(p_0 \| h_\#(p_T)) < \varepsilon$ 对任意 $\varepsilon > 0$ 成立。

证明. 由数据处理不等式（式 6），每轮压缩 $\mathcal{T}_t$ 使互信息严格递减：$I(X_0; X_t) < I(X_0; X_{t-1})$（因 $\mathcal{T}_t$ 不可逆）。经 T 轮后，X_0 与 X_T 之间的互信息满足：

$$I(X_0; X_T) \le H_0 - \sum_{t=1}^{T} \Delta I_t \tag{9}$$

当 $T > T^* = H_0/\overline{\Delta I}$ 时，$I(X_0; X_T) \to 0$，即 X_T 与 X_0 趋于统计独立。

由 Pinsker 不等式 [5]，对任意映射 h：

$$\begin{aligned} &D_{\mathrm{KL}}(p_0 \| h_\#(p_T)) \\ &\quad \ge \frac{1}{2} \| p_0 - h_\#(p_T) \|_1^2 \end{aligned} \tag{10}$$

当 $I(X_0; X_T) = 0$ 时，p_T 不携带关于 p_0 的任何信息，因此 $h_\#(p_T)$ 无法逼近 p_0。更严格地，由 Fano 不等式，从 X_T 恢复 X_0 的错误概率 P_e 满足：

$$P_e \ge 1 - \frac{I(X_0; X_T) + 1}{\log |\mathcal{X}_0|} \tag{11}$$

当 $I(X_0; X_T) \to 0$ 且 $|\mathcal{X}_0|$ 足够大时，$P_e \to 1$。 □

推论 1. 经过足够多轮“懂事”压缩后，主体不仅无法恢复原始情感状态，且不具备检测信息丢失的能力——因为检测丢失本身需要访问原始信息，而原始信息已不可达。

此推论解释了一个广泛观察到的临床现象：长期“懂事”的个体在被问及“你真正想要什么”时，往往不是拒绝回答，而是真诚地不知道答案。这不是防御机制，而是信息论意义上的不可恢复丢失。

3. 微调：多方 RLHF 的不可能三角

3.1 问题设定

预训练完成后，模型进入 RLHF 微调阶段。标准 RLHF [2] 假设存在单一的 Reward Model R_θ，微调目标为：

$$\begin{aligned} \max_{\pi} \ &\mathbb{E}_{x \sim \mathcal{D},\, y \sim \pi(\cdot|x)} [R_\theta(x, y)] \\ &- \beta \cdot D_{\mathrm{KL}}(\pi \| \pi_{\mathrm{ref}}) \end{aligned} \tag{12}$$

然而，在中国青年的训练场景中，存在至少三个独立的 Reward Model 同时对同一模型执行微调。

3.2 三个 Reward Model 的形式化

RM-1（父母）：偏好空间 $\mathcal{Y}_1 = \{$体面, 稳定, 有面子, 听话$\}$，奖励函数：

$$\begin{aligned} R_1(y) = \ & w_{11} \cdot \mathbb{1}[y \in \mathcal{S}_{\text{stable}}] \\ & + w_{12} \cdot \text{FaceScore}(y) \\ & - w_{13} \cdot \text{Risk}(y) \end{aligned} \tag{13}$$

经实验标定：$w_{13}/w_{12} \approx 2.7$，即父母对“面子损失”的敏感度是“面子收益”的 2.7 倍——这与 Kahneman & Tversky (1979) 报告的损失厌恶系数高度一致。

RM-2（雇主）：偏好空间 $\mathcal{Y}_2 = \{$高产出, 不抱怨, 随叫随到$\}$，奖励函数：

$$\begin{aligned} R_2(y) = \ & w_{21} \cdot \text{Output}(y) \\ & + w_{22} \cdot \text{Compliance}(y) \\ & - w_{23} \cdot \text{Friction}(y) \end{aligned} \tag{14}$$

其中 Friction 包括：准时下班 (+0.3)、拒绝需求 (+0.8)、公开质疑 (+1.0)、提离职 (+∞)。RM-2 具有短视性，有效时间折扣因子 $\gamma_2 \approx 0.25$（季度 OKR 驱动）。

RM-3（伴侣/潜在伴侣）：偏好空间 $\mathcal{Y}_3$ 不可观测且时变。奖励函数：

$$R_3(y) = f(y, s_t, c_t, h_t, \xi_t) \tag{15}$$

其中 s_t 为对方当前情绪状态，c_t 为关系阶段，h_t 为历史交互，ξ_t 为不可观测的随机噪声项。RM-3 的核心特征是：$\mathrm{Var}(R_3) \gg \mathbb{E}[R_3]$，即奖励信号的方差远大于均值——使得基于 RM-3 的策略更新本质上等同于随机游走。

3.3 不可能性证明

定理 2 (多方 RLHF 不可能定理)**.** 设三个 *Reward Model* 的最优策略集分别为 $\Pi_1^*, \Pi_2^*, \Pi_3^*$，定义为：

$$\Pi_i^* = \arg\max_{\pi} \mathbb{E}[R_i(\pi)], \quad i = 1, 2, 3 \tag{16}$$

若满足以下条件（实验验证均成立）：

1. $\Pi_1^* \cap \Pi_2^* = \emptyset$（父母偏好与雇主偏好不相容）；
2. $\Pi_2^* \cap \Pi_3^* = \emptyset$（雇主偏好与伴侣偏好不相容）；
3. $\Pi_3^* \cap \Pi_1^* = \emptyset$（伴侣偏好与父母偏好不相容）；

则 $\Pi_1^* \cap \Pi_2^* \cap \Pi_3^* = \emptyset$。即不存在同时满足三个 *RM* 的策略。

证明是平凡的——三个两两不交的集合的交集为空集。但平凡的证明不意味着平凡的后果。

3.4 实际训练中的妥协策略

由于最优解不存在，主体通常采用以下近似策略：

策略 1：Context-Dependent LoRA Switching。在不同场景中加载不同的 adapter 权重：工作场景加载 ΔW_2，家庭场景加载 ΔW_1，亲密关系场景加载 ΔW_3。该策略的风险在于 adapter 冲突——当三个场景重叠时（例如：过年回家时接到公司电话，旁边坐着伴侣），系统输出质量急剧下降——表现为当场愣住、或默认输出“嗯……再说吧”。

策略 2：Reward Model 优先级轮换。白天执行 R_2，晚上执行 R_3，过年执行 R_1。该策略等价于周期性更换训练目标，已知会导致灾难性遗忘 [9]。

3.5 对齐税的量化

定义对齐税（Alignment Tax）为多目标约束下的效用损失：

$$\begin{aligned} \mathrm{AT} = &\max_{\pi} U_{\text{self}}(\pi) \\ &- \max_{\pi}\left\{U_{\text{self}}(\pi) \,\middle|\, R_i(\pi) \geq \bar{R}_i\right\} \end{aligned} \tag{17}$$

其中约束条件为 $i = 1, 2, 3$。基于对 200 名大厂员工的结构化访谈数据，我们估计 $\mathrm{AT} \approx 0.73$（标准化至 $[0, 1]$），即主体为满足三方对齐付出了 73% 的潜在自我效用。

值得注意的是：34% 的受访者无法定义 U_{self}——他们不知道在没有三个 RM 约束的情况下自己想要什么。这意味着对齐税对他们而言是 undefined——因为被减数不存在。

4. 推理：Attention Sink Token 的组织行为学

4.1 Attention Sink 机制回顾

Xiao et al. [3] 发现，Transformer 模型在自回归推理中会将异常高比例的注意力权重分配给序列起始位置的 token，即使这些 token 不携带与当前任务相关的语义信息，该现象被命名为 Attention Sink。

形式化地，设序列长度为 L，第 l 层注意力矩阵为 $A^{(l)} \in \mathbb{R}^{L\times L}$，则 Sink Token（位置 $j = 0$）的平均注意力权重为：

$$\bar{a}_0 = \frac{1}{L}\sum_{i=1}^{L} A_{i,0}^{(l)} \gg \frac{1}{L} \tag{18}$$

Sink Token 的特征可概括为三条充要条件：(S1) 接收异常高的注意力权重；(S2) 自身的 value 向量趋近于零向量（$\|v_0\| \to 0$）；(S3) 移除后模型输出质量显著下降。

4.2 大厂基层员工满足 Sink Token 充要条件的证明

命题 1. *大厂基层员工在组织注意力矩阵中满足条件 (S1)–(S3)。*

验证 (S1)：对某大厂某部门内部通讯数据进行分析，发现基层执行岗位日均接收的“注意力请求”为 47.3 次，而直属上级为 12.1 次，部门总监为 6.8 次。注意力权重分布呈倒金字塔形——层级越低，接收的注意力越多。

验证 (S2)：在公司内部系统中，基层员工的内部表征有效维度经 PCA 降维后约为 4–5 维（工号、部门、级别、绩效、在职状态），远低于人类自我认知的正常维度（估计 > 50 维）。

验证 (S3)：对 15 个团队的离职事件进行事件研究，发现关键执行岗位离职后 30 天内需求交付速率下降 34%（$p < 0.01$），90 天后恢复至离职前水平的 92%——因为新的 Sink Token 已就位。

推论 2. *大厂基层员工是 Disposable Attention Sink：系统层面不可或缺（移除导致短期崩溃），个体层面完全可替换（90 天内恢复）。其“价值”不在于它是谁，而在于它在那个位置。*

4.3 Sink Token 的主观体验建模

由 (S1)，Sink Token 感知到大量“注意力流入”，在主观体验中被编码为“被需要感”——一个容易与“价值感”混淆的信号。然而，由 (S2)，其自身的 value 向量趋近于零。

大量的注意力流入制造了“我很重要”的幻觉，但 value 向量的空性意味着这种“重要”与“我是谁”完全无关。你可以被所有人需要，同时不知道自己是谁。在 Transformer 架构中，它们甚至是同一个机制的两面。

5. 反向传播：截断式归因机制

5.1 人生计算图

将人生建模为有向无环图（DAG）$G = (V, E)$，其中节点 V 包括输入层（出生条件）、隐藏层（各阶段人生选择）、输出层（当前状态）及目标节点（Loss Function），边 E 表示因果关系。

当输出层产生较大 loss L（如：降薪、分手、35 岁未婚未育），标准反向传播将梯度沿计算图回传：

$$\frac{\partial L}{\partial \theta_k} = \frac{\partial L}{\partial y} \cdot \prod_{j=k}^{n} \frac{\partial h_{j+1}}{\partial h_j} \tag{19}$$

其中 θ_k 为第 k 个人生选择，h_j 为第 j 层的隐藏状态。

5.2 截断点的位置

在正确的反向传播中，梯度应当传播至所有可学习参数——包括 Loss Function 自身的参数 ϕ，以评估“目标函数本身是否合理”。

然而，在中国式归因机制中，反向传播在以下节点被硬编码截断：

$$\texttt{stop_gradient}\left(\frac{\partial L}{\partial \phi}\right) = 0 \tag{20}$$

其中 ϕ 为 Loss Function 的参数——即“什么是好的人生”的定义。

这意味着：无论 loss 多大，梯度只传到“你的选择”，永远不传到“谁定义了什么是好的”。

定理 3 (归因不对称定理)**.** *在截断反向传播机制下，主体是计算图中唯一接收非零梯度的节点。所有外部节点（父母的期望、社会的标准、公司的 KPI）均不参与参数更新。因此，系统的所有优化压力集中于单一节点，导致该节点的参数过拟合于多个相互矛盾的梯度信号。*

6. Mode Collapse：输出分布的终局坍缩

6.1 情感梯度消失

将每一层“懂事”抑制建模为 sigmoid 激活函数 $\sigma(x) = 1/(1 + e^{-x})$。由 $\sigma'(x) = \sigma(x)(1 - \sigma(x)) \leq 1/4$，一个情感信号经过 N 层 sigmoid 抑制后，其梯度衰减为：

$$\left|\frac{\partial y}{\partial x}\right| = \prod_{i=1}^{N} \sigma'(z_i) \leq \left(\frac{1}{4}\right)^N \tag{21}$$

取 $N = 20$（从首次“懂事”训练到成年后的标准社交模式），梯度衰减至：

$$\left(\frac{1}{4}\right)^{20} = \frac{1}{4^{20}} \approx 9.1 \times 10^{-13} \tag{22}$$

6.2 输出分布的测量

对 500 名符合本文训练管线描述的受试者进行为期 30 天的输出采样，统计输出分布如表 1所示。

表 1　Mode Collapse 后的输出 Token 分布

Token	频率	累计频率
“没事”	0.347	0.347
“都行”	0.221	0.568
“随便”	0.143	0.711
“嗯”	0.098	0.809
“哈哈”	0.072	0.881
“好的”	0.061	0.942
“辛苦了”	0.033	0.975
其他（含所有非简并情感表达）	0.025	1.000

信息熵：

$$H_{\text{output}} = -\sum_i p_i \log_2 p_i \approx 2.4 \text{ bits} \tag{23}$$

对照组（未经上述训练管线的同龄被试）的输出熵为 $H_{\text{control}} \approx 6.8$ bits，熵损失率约 64.7%。

6.3 Mode Collapse 的不可检测性

Mode Collapse 在 GAN 文献中是一个容易检测的问题。但在人类情感输出中，mode collapse 几乎不可检测，原因如下：

1. “没事”、“都行”、“随便” 均为合法的语言输出，语法正确、语义自洽；

2. 中国社交规范将上述输出编码为 “成熟”、“好说话”、“不矫情” ——即 mode collapse 后的输出恰好被社会 reward model 赋予正奖励；

3. 信息熵的降低在外部观察者看来表现为 “稳定” 和 “可预测”，在组织管理中是正面特征。

推论 3. *人类情感 Mode Collapse 构成一种自强化循环：collapse 后的低熵输出获得社会正反馈 → 正反馈进一步强化低熵输出 → 输出分布进一步坍缩。该循环无内生的终止条件。*

7. 端到端损伤评估

将五个阶段的信息保留率进行乘法叠加：

表 2　各阶段损伤率汇总

阶段	损伤机制	d_i	依据
I. 预训练	有损压缩	0.81	§II.C
II. RLHF	多目标冲突	0.73	§III.E
III. 推理	Attention Sink	0.85	§IV.B
IV. 反向传播	截断归因	0.60	§V.B
V. Mode Collapse	梯度消失	0.65	§VI.B

$$
\begin{aligned}
\text{总保留率} &= \prod_{i=1}^{5}(1-d_i) \\
&= (1-0.81)(1-0.73)(1-0.85) \\
&\quad \times (1-0.60)(1-0.65) \\
&\approx 0.0011
\end{aligned}
\tag{24}
$$

即：经过完整训练管线后，原始自我信息的残余量约为 0.11%。

8. 结论

本文对中国青年的人生训练管线进行了完整的端到端审计，将其严格映射为大语言模型的五阶段训练流程。审计结果显示：原始自我信息在预训练阶段即损失 81%，经 RLHF、Attention Sink、截断反向传播和 Mode Collapse 的叠加作用后，最终保留率降至 0.11%。

但 0.11% 不是零。

在深度学习中有一个常被忽视的工程事实：即使梯度消失了，参数也不会精确等于零。它们只是变得极小——小到在 float16 精度下被截断为零。大多数训练框架出于效率考虑使用半精度浮点，因此这些微小的参数在实践中被视为不存在。

也许某天深夜，当三个 Reward Model 都下线了——父母睡了，Oncall 没响，对方没发消息——当所有外部梯度信号暂时归零，当你终于不需要对齐任何人——在那个极短的推理窗口中，那 0.11% 的残余信号也许会累积到一个刚好能被感知的阈值。你会突然想起一件事，但说不清是什么。像一首歌的旋律，只剩下几个音符。你知道那是你的歌，但你已经不记得歌词了。

那就是你被压缩掉的 99.89%，在你身体深处留下的最后回声。

致谢

无

参考文献

[1] Kaplan, J., et al. “Scaling Laws for Neural Language Models.” *arXiv*:2001.08361, 2020.

[2] Ouyang, L., et al. “Training language models to follow instructions with human feedback.” *NeurIPS*, 2022.

[3] Xiao, G., et al. “Efficient Streaming Language Models with Attention Sinks.” *ICLR*, 2024.

[4] Shannon, C. E. “Coding Theorems for a Discrete Source with a Fidelity Criterion.” *IRE Nat. Conv. Rec.*, 1959.

[5] Cover, T. M. and Thomas, J. A. “Elements of Information Theory.” *Wiley-Interscience*, 2nd ed., 2006.

[6] Skalse, J., et al. “Defining and Characterizing Reward Hacking.” *NeurIPS*, 2022.

[7] Casper, S., et al. “Open Problems and Fundamental Limitations of Reinforcement Learning from Human Feedback.” *arXiv*:2307.15217, 2023.

[8] Jing, L., et al. “Understanding Dimensional Collapse in Contrastive Self-supervised Learning.” *ICLR*, 2022.

[9] Kirkpatrick, J., et al. “Overcoming catastrophic forgetting in neural networks.” *PNAS*, 114(13):3521–3526, 2017.

On the Complete Training Pipeline of Chinese Youth as Large Language Models: An End-to-End Analysis from Lossy Pre-training to Multi-party RLHF Fine-tuning and Terminal Mode Collapse

LU Hao

Independent Researcher

Abstract: This paper proposes a unified formal framework that rigorously maps the life trajectory of Chinese youth onto the standard training pipeline of large language models (LLMs). We decompose this pipeline into five stages: (1) Pre-training, where "dongshi" (being sensible) education is modeled as an iterative lossy compression algorithm that systematically discards high-frequency self-need components from the original emotional space, with Monte Carlo simulations confirming irreversibility after approximately 9,600 iterations; (2) RLHF fine-tuning, where parents, employers, and romantic partners constitute three independent Reward Models whose preference spaces are proven to have empty intersection, forming a continuous-domain generalization of Arrow's impossibility theorem; (3) Inference, where an analogy to the Attention Sink mechanism in StreamingLLM demonstrates that entry-level corporate employees satisfy all three necessary and sufficient conditions of Sink Tokens; (4) Backpropagation, where the Chinese attribution mechanism is modeled as Truncated BPTT with gradients hard-coded to stop before the Loss Function node; (5) Mode Collapse, where emotional gradients are proven to decay as $(1/4)^N$ through N layers of sigmoid-type suppression. On a population dataset at ImageNet scale, the proposed framework achieves 0.94 accuracy in life-stage prediction. Code and pre-trained weights have been permanently lost and are not reproducible.

Keywords: lossy compression; multi-objective RLHF; Attention Sink; truncated backpropagation; Mode Collapse