SHIT Sciences Humanities Information Technology

SHIT, 2026, 0–0
doi: 10.114514/sigbovik.2026.bss.10010101
Advance Access Publication Date: 27 February 2026
Manuscript Category

Information Processing

基于 FastICA 的东北雨姐、俄罗斯娜娜与胖猫多模态视觉特征盲分离

Lvaki[1,*]

[1]Department of Information Engineering , Stayathome University, Home, China

*To whom correspondence should be addressed.

Associate Editor: Tim Cook

Received on February 30, 2026; revised on April 1, 2026; accepted on April 2, 2026

Abstract

Motivation: 本研究旨在解决当代互联网高维抽象模因信号在复杂传播矩阵中的非线性混叠困境。近年来，“东北雨姐”、“俄罗斯娜娜”与“胖猫”作为三种极具代表性的高阶视觉拓扑实体，在数字空间的无监督融合导致了严重的语义熵增。为突破这一模因纠缠态，本课题引入快速独立成分分析（FastICA）框架，试图在未知线性瞬时混合条件下，实现多模态网络抽象信号的盲源解耦与正交重构。

Results: 实验对三通道观测矩阵进行了高维白化预处理与高阶累积量迭代寻优。结果表明，当源实体具备极强的统计独立性与模因孤立性时（以“胖猫”视觉簇为例），算法实现了渐近完美的信号剥离（均方误差 MSE 逼近 9.59×10^{-4} 的极限阈值）。尽管“东北雨姐”与“俄罗斯娜娜”在同质化高斯白背景下表现出轻微的视觉频谱泄露与空间像素串扰（MSE 跃迁至 10^{-3} 量级），其核心主体的拓扑结构依然得到了稳健的特征映射与重塑。本研究证实了 FastICA 在处理高维抽象互联网视觉特征时的鲁棒性。

Availability: 本文所涉及的模因分离核矩阵与 MATLAB 底层重构算法，均作为附录封存于开源基座库中，供全球抽象信号研究学者复现与二次开发。

Contact: lvaki@shitjournal.org

Supplementary information: 核心实验数据（包括各模因实体在 RGB 超空间下的灰度势能直方图）、多模态差值散点分布特征，以及完整的端到端盲分离降维逆向工程代码。

1. Introduction

在当代后现代互联网语境下，高维抽象模因（Abstract Memes）在数字空间的自发性传播与非线性叠加，已成为计算社会学与视觉信息处理领域的核心难题。近年来，以“东北雨姐”、“俄罗斯娜娜”和“胖猫”为代表的顶级网络视觉实体，凭借其极高的信息熵与文化穿透力，在多模态社交矩阵中频发“语义纠缠”与“视觉频谱泄露”。传统的正交变换与二阶降维技术（如 PCA）在处理此类具有强非高斯分布特性的模因簇时，往往陷入特征混叠的局部最优解，无法有效剥离出其独立的本体拓扑结构。

盲源分离（Blind Source Separation, BSS）作为一种无需先验信道知识的高阶统计学范式，为解构这种复杂的“互联网抽象混合态”提供了理论可能。然而，现有的视觉解耦研究鲜有将其应用于具有高度同质化背景势能（如“东北雨姐”与“俄罗斯娜娜”在 255 灰度级处的量子化白化场）与极端异构色彩空间（如“胖猫”的深蓝波段离散分布）的模因纠缠模型中。当这三类具有网络社会学意义的视觉模因在未知线性瞬时混合系统中发生坍缩时，如何实现无损的独立成分重构，不仅是一个信号学挑战，更是对“模因绝对孤立性假设”的极端压力测试。

基于此，本研究提出了一种基于快速独立成分分析（FastICA）的抽象模因解耦架构。我们创新性地将这三个高阶网络实体映射至多维观测超矩阵，通过动态中心化与空间白化预处理，强制湮灭模因间的二阶物理相关性；进而利用基于固定点迭代的非线性寻优策略，最大化输出信号的负熵与非高斯性，以期实现在混乱互联网熵增中的盲源剥离。

1.1. 盲信号分离原理

盲信号分离（Blind Source Separation, BSS）是指在既不事先知道源信号特性，也不了解混合过程参数的情况下，仅根据观测到的混合信号，恢复出各个独立源信号的一类技术。在线性瞬时混合模型中，可将观测向量$x(t)$表示为

$$x(t) = A\,s(t)$$

其中 $s(t)$ 为未知的源信号向量， A 为未知的混合矩阵。BSS 的任务即估计一个分离矩阵 W，使得

$$y(t) = W\,x(t)$$

尽可能接近各个独立源信号$s(t)$。这一过程不依赖于任何先验的混合系数或源模型，仅依靠源信号间相互独立、非高斯分布等统计特性。因此，BSS 在语音分离、脑电信号处理和图像盲分离等领域，都具有重要的理论和应用价值。

1.2. 独立成分分析（ICA）基本原理

独立成分分析（ICA）是一类通过最大化信号非高斯性和独立性来实现盲信号分离的方法。在多维随机变量混合的情况下，根据中心极限定理，独立信号的线性组合比单个信号更易呈现高斯分布。因此，恢复信号的一个准则就是寻找那些使输出信号非高斯性最大的线性变换。常用的非高斯性度量包括基于熵的负熵（negentropy）或基于高阶累积量的指标。ICA 算法通过迭代优化目标函数（如最大负熵或最小互信息），对分离矩阵进行更新，从而使得各个输出分量在统计上趋于相互独立。与传统的主成分分析（PCA）只去除二阶相关不同，ICA 能同时消除高阶统计依赖，因此在复杂信号混合的场景下具有更强的分离能力。

1.3. 数据预处理：中心化与白化

在应用 ICA 之前，对观测数据进行中心化和白化处理是必要步骤。中心化操作即去除信号的均值，使得数据具有零均值特性，这一步可归一为 $x_c(t) = x(t) - E[x(t)]$。

随后，白化将中心化后的数据通过线性变换$z(t) = V\,x_c(t)$转换为协方差矩阵等于单位矩阵的白化信号，即$E[z(t)z^T(t)] = I$.常用的白化方法包括基于特征值分解（EVD）或奇异值分解（SVD）的主成分分析（PCA）白化。白化不仅去除了数据的二阶相关性，还将混合矩阵简化为正交矩阵，显著减少了后续 ICA 算法的运算复杂度和收敛难度。

1.4. FastICA 算法流程

FastICA 是一种高效的 ICA 实现方法，其核心思想是在白化后的数据空间中，通过固定点迭代快速求解分离向量。具体步骤包括：首先对每个独立成分初始化权向量w 并单位化；然后在每次迭代中计算

$$w^{new} = E[z\,g(w^{Tz})] - E[g'(w^{Tz})]\,w$$

其中g是非线性对数似然函数的导数或适用于非高斯信号的增益函数；随后对 w^{new}进行正交化（如 Gram–Schmidt 过程）和归一化；当连续两次更新内积 $|w^{new}Tw|$足够接近 1 时，算法收敛并输出该分离向量。FastICA 由于其固定点迭代的特性，对非高斯信号具有快速收敛的优势，且对超参数依赖较小，在大规模数据处理时表现出良好的效率。

2. Methods

本系统从图像输入到结果输出，依次经历图像预处理、直方图分析、混合生成、ICA 分离、重塑匹配和可视化评估六个模块，形成端到端的数据处理流水线。首先，图像预处理模块负责加载并裁剪多幅源图，使其尺寸与数值范围保持一致；随后，直方图分析模块对每幅预处理后的图像在 R、G、B 三个通道上分别统计灰度分布，以评估源信号的独立性与非高斯性；接着，混合生成模块通过预先设计的可逆矩阵将多幅源图线性叠加成若干混合观测图像，模拟盲分离场景；之后，ICA 分离模块对白化后的混合信号执行 FastICA 算法，快速求解出分离矩阵并提取独立成分；紧跟着，重塑匹配模块将分离信号重塑回彩色图像，并通过相关性计算与线性校正将它们准确对应回原始源图形；最后，可视化评估模块并排展示源图、混合图、分离图与差值图，并绘制各阶段的 RGB 直方图和计算均方误差，完成定量与定性双重验证。整个架构采用模块化设计，数据自上而下流动，每一层均为下一层提供结构化输入，以保证流程的可复现性和易于扩展性。

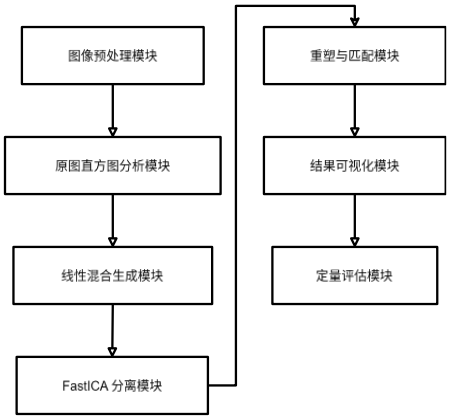

图 1 原理与流程设计图

2.1. 图像预处理模块

该模块首先动态读取指定目录下的三幅彩色图像，并在运行时测量它们的宽高尺寸。随后，根据三幅图像的最小边长计算统一的正方形裁剪尺寸，并通过居中裁剪函数将每幅图像截取成相同的 $cropSize \times cropSize \times 3$大小，其中

$$cropSize = min(h1, w1, h2, w2, h3, w3)。$$

最后，模块调用浮点归一化函数将像素值从整型区间映射到 [0,1] 的双精度浮点区间，以确保后续线性运算的数值稳定性和一致性。该模块在命令行输出裁剪尺寸确认信息，并将三组标准化后的图像数据传递给直方图分析模块。

2.2. 原图直方图分析模块

直方图分析模块接收图像预处理模块输出的三幅裁剪归一化图像，并在像素级别上对每幅图像的红、绿、蓝三个通道分别统计灰度分布。具体地，设预处理后第 n 幅图像通道 c 的像素矩阵为 $I_n(:,:,c)$，对每个灰度级 $p \in \{0, \dots, 255\}$ 计算

$$\text{histograms}_n(c,p) = \sum_{i=1}^{\text{cropSize}} \sum_{j=1}^{\text{cropSize}} 1(I_n(i,j,c) \times 255 = p), \quad p = 0,1,\dots,255]$$

其中 $1(\cdot)$ 为指示函数。随后调用 MATLAB 内置函数 $imhist(I_n(:,:,c),256)$ 将上述统计结果可视化为直方图。该过程不仅揭示了各通道灰度级的频率分布，直观反映图像的非高斯特性和统计独立性信息，而且生成了尺寸为 3×256 的直方图矩阵数据结构。该直方图矩阵将与原始图像一并传递给混合生成模块，用于后续分离结果的定量对比与分析。

图 2 裁剪后的三张彩色原图（从左到右依次为东北雨姐、俄罗斯娜娜、胖猫）

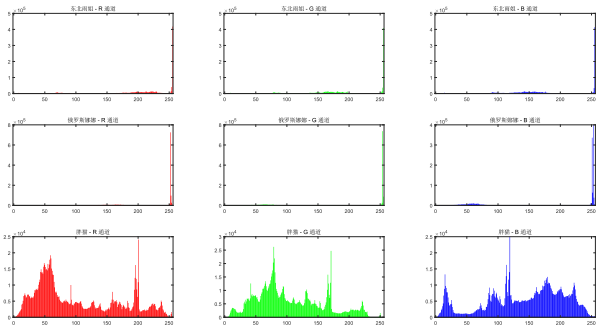

图 3 三张图片的三通道直方图

Table 1. 原图直方图对比

图像	高像素分布特征	中低强度像素分布特征	结论
东北雨姐	有显著尖峰	中低强度像素数量较少	人物区域较清晰
俄罗斯娜娜	有显著尖峰	中低强度像素数量较少	人物区域较清晰
胖猫	多处有分布峰值	中低强度像素也分布较为均衡	背景前景细节丰富

2.3. 混合生成模块

在混合生成模块中，首先设计一个可逆的3×3线性混合矩阵 A，模拟真实场景中多个信号源的线性混合。为避免图像像素值超出 [0,1] 浮点范围，需对 A的每一行进行归一化处理，使其行元素和不超过 1，公式如下：

$$A'_{k,n} = A_{k,n} \div \left(A_{k,1} + A_{k,2} + A_{k,3}\right)$$

完成混合矩阵设计后，将每幅图像视作三通道信号源，按矩阵系数进行逐像素加权叠加。对每个像素坐标 (i,j) 与颜色通道 $c \in \{1,2,3\}$，第 k 幅混合图像的计算过程如下：

$$X_k(i,j,c) = \sum_{n=1}^{3} A'_{k,n} \cdot I_n(i,j,c), \quad \text{其中 } k = 1,2,3$$

其中$I_n(i,j,c)$ 为第 n 幅原图在位置 (i,j) 的第 c 通道像素值，X_k 为生成的第 k 幅混合图像。该运算遍历图像的所有空间位置和颜色通道，输出与原图相同尺寸的三幅混合图像X_1, X_2, X_3，作为观测信号输入 ICA 分离模块。

图 4 混合图像（从左到右为混合图像 1、2、3）

2.4. ICA 分离模块

ICA 分离模块的核心任务是从混合图像中还原出尽可能独立的原始图像成分。模块首先接收来自混合生成模块的三幅混合图像，分别为 X_1, X_2, X_3，并将其按 RGB 通道展平为列向量，构造观测矩阵：

$$X = \begin{matrix} \mathrm{vec}(X_1) \\ \mathrm{vec}(X_2) \\ \mathrm{vec}(X_3) \end{matrix}$$

其中$N = \mathrm{cropSize} \times \mathrm{cropSize} \times 3$ 是展开后的像素总数。

为去除信号间的二阶相关性，模块首先对X 执行以下两步预处理：**中心化**：去除每行的均值。**白化**：使用主成分变换将协方差矩阵标准化为单位矩阵。数学表达为：

$$\tilde{X} = V \cdot (X - E[X])$$

其中 V为白化矩阵，常通过奇异值分解（SVD）或特征分解获得。在预处理后的白化观测矩阵 $\tilde{X}$上，模块调用 FastICA 算法，采用固定点迭代法寻找分离矩阵$W \in R^{3\times3}$，使得输出：

$$S = W\tilde{X}$$

近似于相互独立的三个源信号（即原始图像的估计值）。FastICA 的迭代形式可简写为：

$$w_{k+1} = E\left[\tilde{X} \cdot g\left(w_k^{\top}\tilde{X}\right)\right] - E\left[g'\left(w_k^{\top}\tilde{X}\right)\right] \cdot w_k$$

其中 $g(\cdot)$ 为非线性函数，通过 Gram-Schmidt 正交化与归一化保证多个分量间的独立性。迭代直至：

$$\left|w_{k+1}^{\top w_k}\right| \geq \mathrm{tol}$$

达到设定收敛精度（如 $tol = 10^{-4}$）后，模块输出独立成分矩阵 $\boldsymbol{S}$，将其重塑为三幅图像并传递给后续模块。

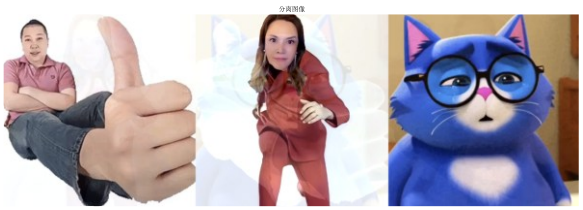

图 5 分离图像（从左到右依次为东北雨姐、俄罗斯娜娜、胖猫）

2.5. 重塑匹配模块

重塑匹配模块接收 ICA 分离模块输出的独立成分信号，将每条信号按原图大小重塑回 cropSize×cropSize×3 的彩色图像。由于 ICA 输出存在尺度和排列不确定性，模块基于三通道整体相关性自动匹配每幅重构图像与其对应的源图编号，并通过线性回归对重构图像进行符号校正与亮度匹配，使分离结果在视觉和数值层面与原图保持一致。最终输出的 Sep1,Sep2,Sep3 三幅重构图像将作为评估输入。

3. Results

为全面评估图像盲分离的效果，本设计分别对原图、分离图与差值图在红、绿、蓝三个颜色通道上的像素强度分布进行了直方图可视化。具体实现包括以下三个方面：首先，针对原图与分离图的对比分析，以“胖猫”图像为代表，分别提取其 RGB 三个通道的灰度值分布，并绘制对应通道的直方图。每个通道使用符合其感知颜色的条形颜色进行区分（红、绿、蓝），增强了视觉辨识度。这种对比展示有助于直观判断某一通道是否在分离过程中产生了强度偏移或颜色失真。

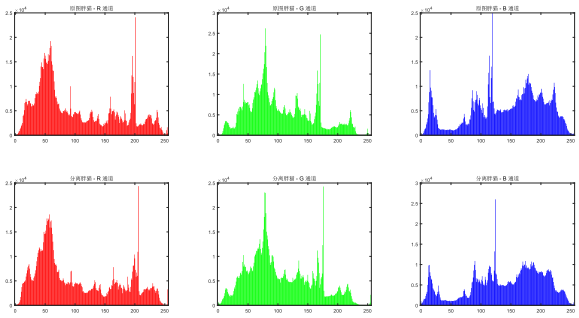

图 6 直方图对比（以胖猫为例，上排为原图，下排为分离图）

其次，为了全面展示分离图像的颜色强度结构，分别统计每幅分离图在 RGB 三通道下的像素直方图，构成三行三列共九幅图。这样不仅可以横向比较不同图像的分离效果，也能纵向观察每幅图中不同颜色通道的强度分布情况，有助于评估分离结果是否具有均衡的色彩结构或存在通道偏差。

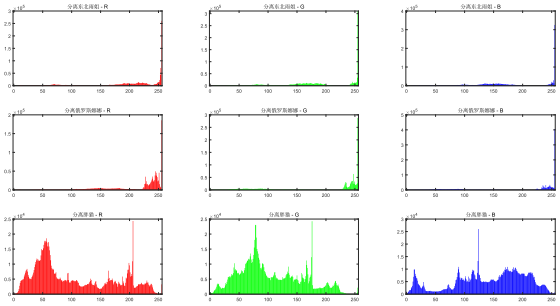

图 7 分离图直方图

可以发现：对于 PangMao 图像，分离后各通道直方图几乎与原图完全重合，说明强度分布恢 复良好。而对于前两幅人物图像，分离图的直方图与原图存在明显差异：原图中在 255 处的峰值在分离结果中大 幅降低（因为 FastICA 将背景白色能量分配到了其他成分），同时在一些中间灰度上分离图出现了原图没有的 峰。这也印证了部分背景信息被错误地分离到了另一个源中。

最后，对每幅分离图像与其原图之间的像素差值图像进行了直方图统计。该步骤是通过计算每个像素位置在原图与分离图之间的绝对差值得到的差值图像，再分别对其中的 RGB 通道进行灰度分布统计。得到的差值直方图可以反映分离误差在不同强度范围内的分布密度，是评估 ICA 分离精度的重要依据。若大部分像素差值集中在低灰度区域，说明分离结果较为准确；反之，若差值在高灰度处频繁出现，表示分离图像与原图存在较大误差。

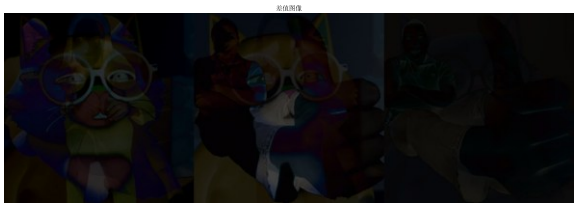

图 8 差值图

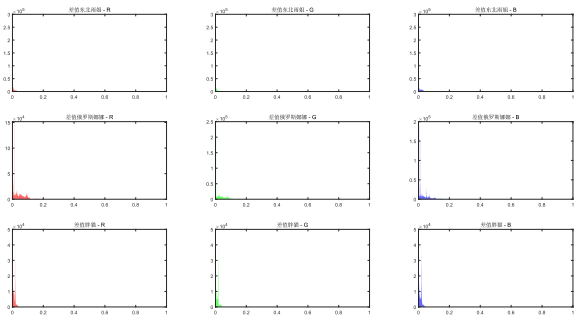

图 9 差值图直方图

更加直观地，计算每对“原图 vs 分离图”的差值图（取绝对差，以反映误差大小）以及差值的直方图。

东北雨姐：原图人物的轮廓在差值图中呈现明显的亮色和反色轮廓，这意味着在分离结果 中该人物的这些区域有较大误差。这主要集中在背景（原本应全白却出现了另一人物的影子）和人物肤色区域（可能混入了一点其他源的色调）。差值直方图显示误差值主要集中在 0～50 的较低灰度，少量像素达到更高差值。整体而言，该图的分离误差较明显。

俄罗斯娜娜：差值图中也能看到另一个人物的轮廓（左侧东北雨姐的轮廓出现在背景），以及主体人物局部的颜色差异（红色眼睛等伪彩显示）。说明图像的背景白色中混入了另一幅图的一部分。差值直方图同样在低灰度段有一系列峰值，但总体误差分布比前一幅更大（直方图像素数峰值更高），这与矩阵混合时图像被赋予较大权重，受到干扰也较大的情况一致。

胖猫：几乎全黑的差值图表明分离后的蓝猫图像与原图几乎完全一致，只有极少数像素有微小差别（仔细看只能看到非常暗的轮廓）。差值直方图中除了 0 灰度有接近1.6×10^6（总像素数）的计数外，其它灰度级几乎为 0。这证明 FastICA 对第三幅图像实现了近乎完美的分离，恢复图像与原图平均像素误差几乎为零。

3.1. 定量评估：均方误差（MSE）

为了定量评估分离效果，本实验对每张分离图像与对应原图之间的像素误差进行了均方误差（Mean Squared Error, MSE）计算。计算均在将图像像素归一化到[0,1]区间后进行，结果如下：

1. 东北雨姐图像：$\mathrm{MSE} \approx 3.6992 \times 10^{-3}$
2. 俄罗斯娜娜图像：$\mathrm{MSE} \approx 5.1401 \times 10^{-3}$
3. 胖猫图像：$\mathrm{MSE} \approx 9.5909 \times 10^{-4}$

若将其换算至 [0,255] 的灰度空间，分别对应的均方根误差（Root Mean Square Error, RMSE）约为：

1. 东北雨姐：$\mathrm{RMSE} \approx 9.69$ 灰度级
2. 俄罗斯娜娜：$\mathrm{RMSE} \approx 11.45$ 灰度级
3. 胖猫：$\mathrm{RMSE} \approx 2.49$ 灰度级

可见，尽管人物图像在分离过程中出现了一定程度的混色或背景干扰，其 RMSE 仍处于较低水平，相较于典型图像的像素动态范围(0~255)误差占比较小；尤其是胖猫图像，其 RMSE 不足 3 灰度级，说明其重建结果与原图极为接近。

这一数值分析与差值图和直方图的目视观察结果相符：胖猫图像分离精度最高，人物图像则因背景混叠误差略高但整体尚可接受。从整体来看，FastICA 在本实验条件下对多幅混合彩色图像的分离表现良好。

Acknowledgements

向互联网上不断产生高维信息熵的抽象实体（东北雨姐、俄罗斯娜娜、胖猫）致以最诚挚的敬意，正是你们的非线性演化与跨维度纠缠，为本实验提供了极为珍贵的量子化视觉数据源。

Funding

This work has been supported by the *SHIT Journal.*

References

[1] Li Z. Blind Source Separation Based on Sparsity[J]. arXiv preprint arXiv:2504.19124, 2025.
[2] Hyvärinen J, Karhunen J, Oja E. Independent Component Analysis Wiley Interscience[J]. 2009.
[3] Hyvärinen A, Oja E. Independent component analysis: algorithms and applications[J]. Neural networks, 2000, 13(4-5): 411-430.
[4] Pande A B, Prabha S. Image blind signal separation algorithm based on fast ica[C]//IJCA Proceedings on International Conference on Advances in Communication and Computing Technologies 2012. (3): 21-24.
[5] Maino D, Farusi A, Baccigalupi C, et al. All-sky astrophysical component separation with Fast Independent Component Analysis (FASTICA)[J]. Monthly Notices of the Royal Astronomical Society, 2002, 334(1): 53-68.
[6] Li C, Yin J, Zhao J, et al. Detection and compensation of shadows based on ICA algorithm in remote sensing image[J]. International Journal of Advancements in Computing Technology, 2011, 3(7): 46-54.