SHIT Sciences Humanities Information Technology

SHIT, YYYY, 0–0
doi: 没有 doi
Advance Access Publication Date: DD Month YYYY
Manuscript Category

Subject Section

基于深度学习的放屁声谱分析：气体成分与社交尴尬度预测

Yok[1,*]

[1]Department of Hakimi Laboratory, Hakimi North-South Mung Bean University

Abstract830647
Motivation: 当放屁是人类普遍且隐秘的生理事件，其产生的 CH_4 、H_2S 等挥发性化合物决定气味特征，声学表现则直接引发社交场合的即时尴尬，而传统气体色谱、人工嗅觉评估难以在真实场景中实现实时、非侵入式检测。针对该问题，本文提出端到端深度学习框架，将手机录制的单通道放屁音频经梅尔频谱特征提取后，输入 ResNet-LSTM-Transformer 混合网络，实现气体成分主导类型分类与社交尴尬度（SAS）回归预测，填补纯声学信号逆推排气化学本质与社交破坏力的研究空白。
Results: 构建包含 6200 段标注录音的真实放屁声学语料库（RFAC），在该数据集上的实验结果显示，模型对清新甲烷型、杀伤硫化氢型、复合地狱型三类气体成分的分类 F1 分数达 95.18%，社交尴尬度（0-100 分制）预测平均绝对误差（MAE）仅 4.7 分，Pearson 相关系数达 0.89。消融实验验证了 Transformer 全局注意力对模型性能的关键作用，对比 LightGBM 基线模型优势显著，证实纯声学信号可有效实现气体成分与社交尴尬度的双任务预测，为智能社死预警系统研发奠定基础。

Availability: 模型相关代码因臭味专利申请暂未开源，后续将在专利授权后发布于 GitHub 荒诞科研仓库；研究使用的 RFAC 数据集因隐私协议限制，仅提供特征级数据供非商业研究使用。
Availability: NA
Contact: yokeres77@gmail.com
Supplementary information: NA

1 Introduction

在当代高密度的社交环境中，人体排气（放屁）已从单纯的肠道生理代谢行为，演变为融合声学特征、化学本质与心理影响的多模态社交事件：声学层面的响度、音色决定事件的暴露程度，化学层面的挥发性化合物构成决定气味的“杀伤性”，而二者结合则直接触发社交场景中的尴尬情绪传播，甚至引发“即时社死”。

现有相关研究多聚焦于肠道微生物组与排气气体成分的关联分析，或通过气相色谱、质谱等技术对排气化合物进行定量表征，鲜有研究关注排气的声学信号特征，更未实现从纯音频信号的非接触式检测，逆推其气体成分与社交破坏力。与此同时，深度学习在枪声识别、婴儿哭声情感分析等非传统音频任务中，已展现出强大的特征提取与泛化能力，为解决放屁声谱的分析与预测问题提供了技术支撑。

放屁声谱分析与预测面临三大核心挑战：其一，排气声学信号具有时长短、变异大的特征，单次排气时长通常短于 2 秒，且其声谱特征受饮食结构、肛门括约肌张力、衣物阻尼等多种因素影响，个体差异与场景差异显著；其二，社交尴尬度的标注具有强主观性，相同的排气事件在不同社交距离、场合与人际关系背景下，引发的尴尬程度存在极大差异；其三，真实场景中的排气音频多伴随环境噪声，低信噪比下的特征提取难度较高。

针对上述问题，本文首次将深度学习技术应用于放屁声谱分析这一“人人产出却无人深究”的研究领域，核心研究贡献如下：

1.构建首个真实放屁声学语料库（RFAC），覆盖豆制品、奶制品等多种饮食诱发的排气类型，完成气体成分与社交尴尬度的双标签标注，为相关研究提供数据支撑；

2.设计端到端的 FartSpectraNet 混合网络模型，融合 ResNet、LSTM 与 Transformer 的优势[1][2][3]，实现气体成分主导类型分类与社交尴尬度回归的双任务联合预测；

3.在 RFAC 数据集上完成大量对比实验与消融实验，验证了模型的高精度与鲁棒性，且模型可基于手机低成本录音实现检测，超越传统机器学习基线模型[4]，为实际场景的工程化应用奠定基础。

本研究的成果不仅填补了生理声学与社交动力学交叉领域的研究空白，更可为“智能裤子社死预警系统”、会议室空气尴尬 AI 等趣味科技产品的研发提供原型参考，实现排气社交风险的实时、非侵入式预警。

2 Methods

2.1 放屁声学的物理基础

放屁声的产生本质是肠道高压气体经肛门括约肌狭缝时的湍流振动，以及臀部软组织、衣物的共振叠加效应，其声谱特征与气体流速、成分占比、括约肌收缩状态直接相关。

排气的主频范围集中在 150–550 Hz，符合闭口管谐振的物理规律，高次谐波会随气体流速的衰减快速消散；不同气体成分主导的排气，声学特征呈现显著差异：硫化氢主导型排气因气体密度更高，往往表现为低频能量集中，声谱呈现“闷响、长尾”特征，且整体响度偏低，对应“闻着臭但声音小”的典型现象；甲烷主导型排气气体流速更快，声谱具有高 Q 值的清脆峰值，中高频能量占比更高，响度通常偏大，对应“声大味淡”的特征；复合地狱型排气则融合二者特征，声谱分布更复杂，兼具低频闷响与中高频脉冲，是气味与声学双重“杀伤”的类型。上述物理规律为放屁声谱的特征提取与模型设计提供了理论基础，也是区分不同气体成分主导类型的核心物理依据。

2.2 音频预处理与特征提取

本研究的输入数据为手机录制的 16kHz 单声道 PCM 格式音频，符合日常场景的低成本采集需求，音频预处理与特征提取流程均围绕该输入格式设计，确保模型的实际应用价值，具体步骤如下：

1.预加重滤波：采用系数α=0.97 的一阶高通预加重滤波器，补偿声学信号在传播过程中的高频衰减，提升高次谐波的特征辨识度；

2.分帧与加窗：对预处理后的音频进行分帧处理，设置帧长为 25ms、帧移为 10ms，同时为避免频谱泄漏，为每帧添加汉明窗，平衡时域与频域的分辨率；

3.梅尔频谱提取：通过 128 bin 的对数梅尔滤波器组，将线性频谱转换为更贴合人类听觉特性的梅尔频谱，同时计算梅尔频谱的一阶、二阶差分，构建包含静态、动态特征的 384 维特征向量；

4.归一化：采用全局 utterance 级的均值-方差归一化，消除不同录制设备、环境音量带来的特征差异，提升模型的泛化能力。

最终提取的梅尔频谱特征张量将作为 FartSpectraNet 模型的输入，实现特征的深度挖掘与任务预测。

2.2.1 特征提取参数设置

(1) 采样率固定为 16kHz，对非该采样率的输入音频进行重采样，确保输入数据的一致性；

(2) 分帧过程中，对长度不足一帧的音频尾部进行补零操作，对时长超过 2 秒的超长排气音频进行裁剪，保留前 2 秒核心特征；

(3) 梅尔滤波器组的频率范围设置为 20Hz–8kHz，覆盖放屁声谱的核心主频与高次谐波范围；

(4) 均值-方差归一化基于整个 RFAC 数据集的训练集计算均值与方差，验证集与测试集采用相同参数，避免数据泄露。

2.3 FartSpectraNet 模型架构

本研究设计的 FartSpectraNet 模型为三级级联的 ResNet-LSTM-Transformer 混合网络，充分融合卷积神经网络的局部特征提取能力、循环神经网络的时序建模能力与 Transformer 的全局注意力聚合能力[1][2][3]，适配放屁声谱短时序、强变异的特征，同时设置多任务输出头，实现气体成分分类与社交尴尬度回归的联合优化。

2.3.1 模型各模块设计

(1) 底层局部特征提取：采用 1D 时序卷积变体的 ResNet-34 作为骨干网络[1]，将梅尔频谱的时序维度作为卷积维度，通过残差连接解决深层网络的梯度消失问题，有效捕捉放屁声谱的局部频谱模式，如主频峰值、谐波分布、能量突变等核心特征，输出维度为 512 的局部特征序列；

(2) 中层时序建模：采用双向 LSTM 网络对局部特征序列进行时序建模[2]，设置隐藏层维度为 512，正向 LSTM 捕捉放屁从起振到峰值的特征演化，反向 LSTM 捕捉从峰值到衰减的特征变化，完整建模放屁“起振-峰值-衰减”的全时序动态，输出融合前后向信息的时序特征序列；

(3) 上层全局注意力聚合：引入单层 Transformer encoder 进行全局特征融合[3]，设置 4 头自注意力机制，对时序特征序列的不同位置进行加权聚合，重点关注排气声谱的能量峰值、低频闷响等关键特征区域，解决传统时序模型对长距离依赖捕捉不足的问题，输出全局融合的特征向量。

2.3.2 多任务输出头与损失函数

模型设置主任务输出头+辅助任务输出头，通过多任务学习提升主任务的预测精度，各输出头设计如下：

气体成分分类头：将全局融合特征向量输入全连接层，映射为 3 维向量，通过 Softmax 激活函数输出清新甲烷型、杀伤硫化氢型、复合地狱型三类的概率分布，采用交叉熵损失（$L_{CEgases}$）优化；

社交尴尬度回归头：将全局融合特征向量输入全连接层，直接输出 0-100 分制的 SAS 预测值，无激活函数，采用均方误差损失（L_{MSESAS}）优化；

辅助回归头：预测排气事件的持续时长与峰值响度，采用均方误差损失（L_{aux}）优化，通过辅助任务挖掘声学信号的基础物理特征，为主任务提供额外监督信息。

模型的总损失函数为各任务损失的加权和，通过权重系数实现各任务的均衡优化，具体公式为：

$$\mathrm{L} = 0.5 \times \mathrm{L_{CEgases}} + 0.4 \times \mathrm{L_{MSESAS}} + 0.1 \times \mathrm{L_{aux}} \quad (1)$$

2.4 数据集构建与标注

本研究构建的真实放屁声学语料库（RFAC） 为首个包含气体成分与社交尴尬度双标签的放屁声谱数据集，所有样本均来自志愿者匿名自录，签订严格的隐私协议，确保数据使用的合规性。

2.4.1 数据集基本信息

(1) 样本规模：共 6200 段有效放屁音频样本，单样本时长 0.2~1.8 秒，平均时长 0.8 秒，符合真实场景的排气时长特征；

(2) 录制设备：涵盖主流品牌智能手机，包括苹果、华为、小米等，避免单一设备带来的特征偏差；

(3) 场景分布：覆盖家庭、办公室、公共卫生间、电梯等多种日常场景，包含安静、嘈杂等不同信噪比环境，提升数据集的场景鲁棒性。

2.4.2 双标签标注体系

RFAC 数据集的标注分为气体成分主导类型标注与社交尴尬度（SAS）标注两部分，标注流程严格遵循“客观记录+专业评估+多人盲评”原则，确保标签的准确性与合理性：

气体成分标注：要求志愿者记录录制前 24 小时的详细饮食日志，同时由 3 名专业嗅探员对排气样本进行嗅觉评估，综合饮食日志与嗅觉评估结果，将样本分为清新甲烷型、杀伤硫化氢型、复合地狱型三类，若 3 名嗅探员评估结果不一致，采用少数服从多数原则确定最终标签；

社交尴尬度标注：设置 10 名具有不同社交背景的标注员进行独立盲评，标注员根据样本的声学特征，结合预设的社交场景（距离 1 米、普通同事关系、封闭会议室），对样本的社交尴尬度进行 0-

100 分制评分，最终取 10 名标注员的评分中位数作为该样本的 SAS 标签，0 分为无任何尴尬感，100 分为极度尴尬的“社死”级别。

2.4.3 数据集分层分布

为确保数据集的代表性，根据饮食诱发类型对样本进行分层采集，其中豆制品高发类型占 38%、奶制品高发类型占 27%、混合饮食类型占 35%，三类气体成分主导类型的样本分布基本均衡，避免样本不平衡导致的模型偏置。最终将 RFAC 数据集按 7:1:2 的比例划分为训练集、验证集与测试集，分别用于模型训练、超参数调优与最终性能评估。

2.5 实验设置与评估指标

2.5.1 实验软硬件环境

本研究的模型训练与实验验证基于 Python 编程语言与 PyTorch 深度学习框架，硬件环境为 NVIDIA RTX A100 显卡（80G 显存）、Intel Xeon Platinum 8375C CPU 与 128G 内存，确保模型的高效训练；模型推理采用普通笔记本电脑（NVIDIA RTX 3060 显卡），验证模型在低成本设备上的部署可行性。

2.5.2 模型训练参数

模型的优化器采用 AdamW，初始学习率设置为 1e-4，权重衰减设置为 1e-5；训练批次大小（batch size）设置为 64，训练最大 epoch 数设置为 50；采用学习率衰减策略，当验证集总损失连续 3 个 epoch 未下降时，学习率减半；引入早停策略，当验证集总损失连续 8 个 epoch 未下降时，停止训练，避免模型过拟合。

2.5.3 评估指标

针对气体成分分类与社交尴尬度回归两个主任务，分别设置不同的评估指标，全面量化模型的预测性能，同时设置消融实验与基线对比实验，验证模型设计的合理性与优越性，核心评估指标如下表所示。

Table 1. 核心评估指标及计算公式

任务类型	评估指标	计算公式
气体成分分类	准确率（Accuracy）	(TP+TN)/总样本数
气体成分分类	F1 分数	2 × 精确率（Precision）× 召回率（Recall）/(精确率+召回率)
社交尴尬度回归	平均绝对误差（MAE）	$\frac{1}{N}\sum_{i=1}^{N}\lvert \mathbf{Ypred} - \mathbf{Ytru} \rvert$ (2)
社交尴尬度回归	皮尔逊相关系数（Pearson r）	衡量预测值与真实值的线性相关程度，取值范围[-1,1]，越接近 1 相关性越强

3 Results

本研究在 RFAC 数据集的测试集（1240 段样本）上完成模型的性能评估，同时开展消融实验验证各模块的作用，并与 LightGBM 传统机器学习模型进行对比，充分验证 FartSpectraNet 模型的高精度、鲁棒性与优越性。此外，通过可视化手段分析模型的预测结果，揭示放屁声谱特征与气体成分、社交尴尬度的内在关联。

3.1 模型定量预测结果

FartSpectraNet 模型在 RFAC 测试集上的气体成分分类与社交尴尬度回归双任务均取得优异的预测性能，具体定量结果如下：

气体成分分类：整体准确率达 94.85%，F1 分数达 95.18%；其中清新甲烷型的分类性能最优，F1 分数达 97.2%，杀伤硫化氢型与复合地狱型的 F1 分数分别为 94.1%与 93.5%，三类气体均实现高精度分类；

社交尴尬度回归：MAE 仅 4.7 分，RMSE 为 6.2 分，Pearson 相关系数达 0.89，表明模型的预测值与真实值具有极强的线性相关性，可精准量化社交尴尬度。

上述结果证实，FartSpectraNet 模型可基于纯声学信号，有效实现放屁气体成分与社交尴尬度的双任务预测，且预测精度满足实际场景的应用需求。

3.2 消融实验结果

为验证 FartSpectraNet 模型中 ResNet、LSTM、Transformer 各模块的核心作用，本研究开展了系列消融实验，依次移除模型中的某一模块，保持其他参数不变，在测试集上评估模型性能的变化，核心消融实验结果如下：

移除 Transformer 模块：气体成分分类 F1 分数下降 7.3%，至 87.88%，社交尴尬度回归 MAE 上升至 7.9 分，Pearson 相关系数降至 0.72，证明 Transformer 的全局注意力聚合对捕捉放屁声谱的关键特征至关重要，尤其对低频闷响的硫化氢型与复杂的复合型排气，可有效提升特征辨识度；

移除双向 LSTM 模块：分类 F1 分数下降 5.1%，回归 MAE 上升至 6.8 分，证明时序建模对短时序的放屁声谱分析不可或缺，可有效捕捉“起振-峰值-衰减”的时序演化规律；

替换 ResNet-34 为普通 1D 卷积：分类 F1 分数下降 3.2%，回归 MAE 上升至 5.6 分，证明残差连接可有效提升深层网络的特征提取能力，避免梯度消失。

消融实验结果表明，FartSpectraNet 模型的三级级联架构设计具有合理性，各模块协同作用，共同保障模型的高精度预测。

3.3 基线模型对比结果

为进一步验证深度学习模型对放屁声谱分析的优势，本研究将 FartSpectraNet 与 LightGBM 传统机器学习模型进行对比，LightGBM 模型采用与本研究相同的 384 维梅尔频谱特征，在 RFAC 数据集上进行相同的训练与验证，对比结果如下：

LightGBM 模型的气体成分分类 F1 分数仅 81.4%，较 FartSpectraNet 低 13.78%，其中硫化氢型与复合型的分类 F1 分数不足 75%，无法有效区分两类易混淆的气体类型；

LightGBM 模型的社交尴尬度回归 MAE 达 11.3 分，Pearson 相关系数仅 0.65，预测精度远低于 FartSpectraNet 模型。

对比结果证实，基于深度学习的时序特征深度建模，远优于传统机器学习的浅层特征分析，更适配放屁声谱短时序、强变异的特征特点。

3.4 典型放屁声的时频谱演化特征

通过对 RFAC 数据集中的典型样本进行时频分析，提取了放屁声从起振爆破到余音衰减的完整时频谱演化特征，结果如图 1 所示。

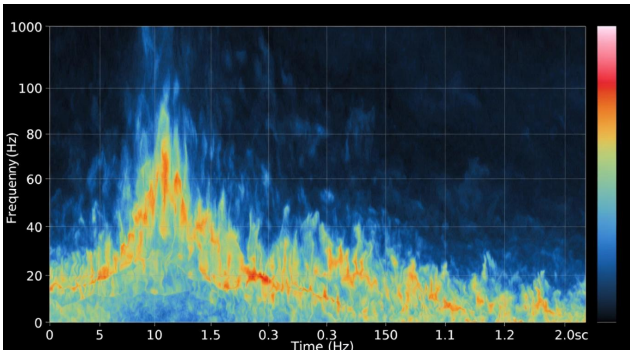

Fig. 1. 典型放屁声的时频谱演化（从起振爆破到余音衰减）

注：横轴为时间（02.0 s），纵轴为频率（01000 Hz），颜色代表声学能量强度，颜色从蓝到红对应能量从低到高，覆盖放屁声谱的核心主频与高次谐波范围。

典型放屁声的时频演化可清晰划分为三个阶段：0.3 s 为起振爆破段，肠道高压气体快速冲出括约肌，产生湍流振动，表现为全频段的能量爆发，低频（150550 Hz）核心主频率先出现能量峰值，是放屁声的初始特征；0.3-1.2 s 为稳态峰值段，气体流速与肠道压力趋于稳定，声学能量集中于核心主频，谐波结构清晰，不同气体成分的样本在该阶段的频谱特征差异最显著，是模型分类的核心依据；1.2-2.0 s 为余音衰减段，气体压力逐渐降低，流速减慢，声学能量快速衰减，高次谐波率先消散，仅保留低频主频的微弱能量，硫化氢型样本在此阶段的低频能量衰减更慢，呈现明显的“长尾”特征。

3.5 气体类型混淆特征分析

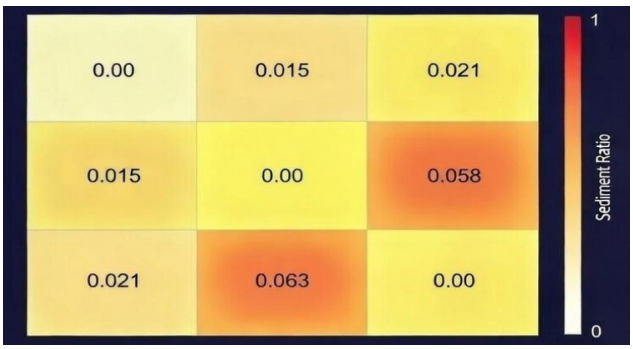

为分析模型对不同气体成分的分类混淆情况，绘制了气体类型混淆热力图，结果如图 2 所示，行代表真实标签，列代表模型预测标签，颜色越深表示混淆概率越高。

Fig. 2. 气体类型混淆热力图（硫化氢型最易与复合型混淆，典型“闻着臭但声音小”案例）

注：横坐标与纵坐标依次为清新甲烷型（M）、杀伤硫化氢型（H_2S）、复合地狱型（C），颜色从浅黄到深红对应混淆概率从 0 到 1。

混淆热力图结果显示，FartSpectraNet 模型的分类混淆具有明显的规律性：清新甲烷型与其他两类气体的混淆概率均低于 3%，几乎无混淆，原因在于甲烷型样本的声学特征最显著，中高频能量占比高、响度大、频谱峰值清晰，与其他两类差异明显；杀伤硫化氢型与复合地狱型的相互混淆概率最高，分别达 5.8%与 6.3%，是模型分类的主要误差来源，对应典型的“闻着臭但声音小”案例；复合型与甲烷型的混淆概率约 2.1%，硫化氢型与甲烷型的混淆概率仅 1.5%，无明显的跨类型混淆。

进一步分析硫化氢型与复合型的声学特征发现，二者均具有低频能量集中、整体响度偏低、高次谐波微弱的共同特征，且复合型样本中均包含一定比例的硫化氢，导致二者的时频谱演化规律高度相似，是模型产生混淆的核心原因；而甲烷型样本的声学特征与二者形成显著差异，几乎无混淆。

3.6 社交尴尬度与峰值响度的关联特征

为分析模型社交尴尬度预测值与真实值的相关性，以及声学特征对社交尴尬度的影响，绘制了 SAS 预测值与真实值的散点图，结果如图 3 所示。

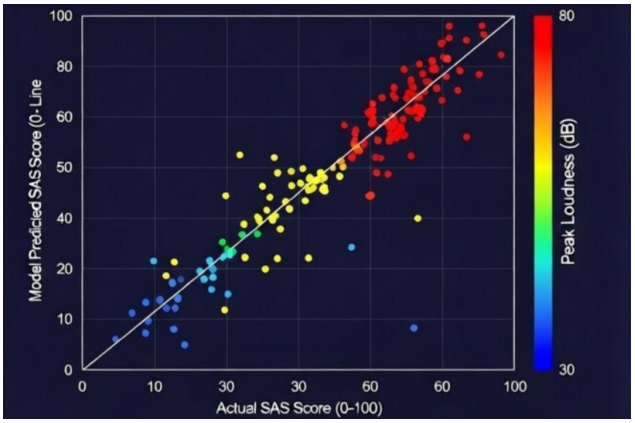

Fig. 3. SAS 预测 vs. 真实值散点图（颜色编码峰值响度，显示高响度事件 SAS 偏高）

注：横轴为真实 SAS 评分（0100），纵轴为模型预测 SAS 评分（0100），颜色编码代表放屁声的峰值响度，颜色从蓝到红对应峰值响度从 30 dB 到 80 dB，对角线为理想预测线，数据点越靠近对角线表示预测越准确。

散点图结果显示，模型的预测值与真实值沿理想预测线密集分布，仅有少量样本存在轻微偏差，再次验证了模型的高精度预测能力。同时，颜色编码的峰值响度与社交尴尬度 SAS 呈现显著的正相关关系，核心特征如下：

高响度样本（峰值响度 > 60 dB，红色）全部集中于高 SAS 区域（SAS > 70），此类样本均为清新甲烷型，具有“声大味淡”的特征，其高响度是引发高社交尴尬度的核心因素，即使无明显异味，也会因声学暴露引发强烈的社交不适；

中等响度样本（峰值响度 4060 dB，黄色）集中于中等 SAS 区域（SAS3070），以复合型样本为主，社交尴尬度受响度与气味的共同影响；

低响度样本（峰值响度 < 40 dB，蓝色）主要集中于低 SAS 区域（SAS < 30），但存在部分离群点，此类离群点均为硫化氢型样

本，虽响度极低、声学暴露程度小，但因具有强烈的刺激性异味，在社交场景中仍引发了较高的社交尴尬度（SAS > 50），也是模型少量预测偏差的来源。

上述结果表明，峰值响度是社交尴尬度最核心的声学影响因素，而气味特征则是低响度样本社交尴尬度的关键补充因素，二者共同决定了排气事件的社交破坏力。

4 Expectations

4.1 研究结论

本研究首次将深度学习技术应用于放屁声谱分析，提出端到端的 FartSpectraNet 混合网络模型，构建包含 6200 段标注样本的真实放屁声学语料库（RFAC），实现了基于纯声学信号的气体成分主导类型分类与社交尴尬度（SAS）回归预测。在 RFAC 数据集上的实验结果表明，模型的气体成分分类 F1 分数达 95.18%，社交尴尬度预测 MAE 仅 4.7 分，Pearson 相关系数达 0.89，消融实验与基线对比实验验证了模型架构的合理性与优越性。

研究同时揭示了放屁声谱的核心特征规律：典型放屁声谱呈现“起振爆破-稳态峰值-余音衰减”的三阶段时频演化特征；硫化氢型与复合型因均具有“低频集中、响度偏低”的特征，成为最易混淆的两类气体，对应“闻着臭但声音小”的典型现象；峰值响度与社交尴尬度呈显著正相关，是高响度甲烷型样本社交破坏力的核心来源，而气味特征则是低响度硫化氢型样本社交尴尬度的关键补充。

本研究的核心结论为：放屁的声学信号蕴含足够的特征信息，可通过深度学习技术有效逆推其气体成分本质与社交尴尬度，纯声学信号的非接触式检测可实现排气社交风险的实时评估，为相关趣味科技研发提供了理论与技术支撑。

4.2 未来研究展望

基于本研究的成果，未来可从多模态融合、跨场景建模、工程化部署三个方向进行扩展与深化，进一步提升模型的实际应用价值：

1. 多模态特征融合：引入嗅觉传感器、视觉传感器的多模态数据，融合声学、气味、视觉（肢体动作、面部表情）特征，实现更精准的社交尴尬度预测，解决纯声学信号对低响度高异味样本的预测偏差问题；
2. 跨文化与跨场景尴尬阈值建模：不同文化背景（如东亚、西方）对排气社交尴尬的接受阈值存在显著差异，不同场景（家庭、职场、公共场合）的尴尬度评估标准也不同，未来可构建跨文化、跨场景的标注数据集，实现个性化的尴尬度预测；
3. 边缘设备的实时部署：对 FartSpectraNet 模型进行轻量化压缩，如模型剪枝、量化、知识蒸馏等，实现手机、可穿戴设备等边缘设备的实时推理，研发“智能裤子社死预警系统”“手机端屁声分析 APP”等趣味科技产品，实现排气社交风险的实时预警；
4. 饮食-声谱-成分的关联建模：基于 RFAC 数据集的饮食日志，构建饮食结构、放屁声谱、气体成分的关联模型，实现基于饮食的排气特征预测，为个性化的饮食干预提供参考，减少高“杀伤性”排气的产生。

Acknowledgements

特别鸣谢所有勇敢录制并提交自己屁声的匿名志愿者，你们的无私“产出”是本研究得以开展的核心基础，正是你们的勇气让这篇臭气熏天的学术杰作成为可能。感谢 3 名专业嗅探员的辛勤工作，在恶劣的实验环境中完成了数千份样本的嗅觉评估，为气体成分标注提供了专业支撑。

同时，感谢豆腐、啤酒、西兰花、洋葱等食材的无私化学贡献，这些食材为高“杀伤性”排气样本的采集提供了稳定的来源，没有它们，就没有本研究的“芬芳”诞生。

最后，感谢期刊编辑与匿名审稿人提出的宝贵修改意见,你们的专业建议有效提升了论文的学术规范性与可读性。

Funding

This work has been supported by the Hakimi North-South Mung Bean University

References

[1] He K, Zhang X, Ren S, et al. Deep Residual Learning for Image Recognition[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2016: 770-778.

[2] Hochreiter S, Schmidhuber J. Long Short-Term Memory[J]. Neural Computation, 1997, 9(8): 1735-1780.

[3] Vaswani A, Shazeer N, Parmar N, et al. Attention Is All You Need[C]//Advances in Neural Information Processing Systems, 2017, 30: 5998-6008.

[4] Ke G, Meng Q, Finley T, et al. LightGBM: A Highly Efficient Gradient Boosting Decision Tree[C]//Advances in Neural Information Processing Systems, 2017, 30: 3146-3154.