SHIT Sciences Humanities Information Technology

构石

明日方舟：终末地集成工业系统与神经网络设计的相似性——观察与新方法

Unkoman[1,*]

[1] State Key Laboratory of Toire，Toilet，Toilettes

通讯作者：Unkoman（e-mail: unkoman@virtualapp.lab.terra）

本研究由”塔卫二赤色源石基金会”资助（项目编号：AK-END-2026-001）

ABSTRACT / 摘要 —**目的：**本研究旨在探索电子游戏《明日方舟：终末地》中的集成工业系统 (AIC) 与现代深度神经网络架构之间令人意外的结构同构性。通过对 AIC 的协议核心 (PAC)、物流网络和自动化生产流程的系统建模，我们发现其设计范式与卷积神经网络 (CNN)、循环神经网络 (RNN) 及 Transformer 架构存在深刻的拓扑对应关系。**结果：**我们提出了 AIC-Net 框架，将游戏中的”采矿-精炼-合成”流水线映射为”输入-特征提取-分类”的神经网络层级结构，并在理论上证明了传送带系统的数据流动等价于反向传播算法中的梯度传递。实验表明，虽然 AIC-Net 在 ImageNet 上仅获得 0.114% 的准确率（但显著高于随机猜测的 0.1%），其性能与玩家肝度仍呈现正相关 (r=0.87, p<0.001)。**结论：**本研究首次揭示了游戏工业系统设计与深度学习架构的本质联系，为”边玩游戏边训练神经网络”开辟了新的研究方向。更重要的是，我们证明了熬夜肝游戏确实可以对科研做出贡献——只要你写得够认真。

INDEX TERMS / 关键词 明日方舟终末地，集成工业系统，深度神经网络，结构同构，学术整活。

IMPACT STATEMENT / 影响声明 本研究为游戏研究生找到了合理化肝游戏的理论依据，预计将显著提升实验室深夜在线人数。同时为”我不是在玩游戏，我是在做科研”这一经典辩护提供了坚实的数学基础。

I. INTRODUCTION / 引言

A. 研究背景

近年来，深度神经网络在计算机视觉、自然语言处理等领域取得了革命性进展 [1]。与此同时，电子游戏产业也在蓬勃发展，其中《明日方舟：终末地》(Arknights: Endfield) 作为一款融合了塔防、角色扮演与工业建造元素的游戏，其核心玩法——集成工业系统 (Automated Industry Complex, AIC) 展现出了令人惊讶的复杂性 [2]。

本研究的灵感源于一个深夜的顿悟：当笔者第 37 次尝试优化游戏中的源石矿自动化产线时，突然意识到这套”资源采集-加工-合成”的流程与神经网络的”输入-隐藏层-输出”结构何其相似！这一发现促使我们开展了为期三个月的深入研究——虽然其中两个半月都在玩游戏，但最后半个月的理论推导是相当严肃的。

B. 相关工作

在游戏与机器学习的交叉领域，已有研究探索了使用强化学习训练游戏 AI [3]，以及将游戏环境作为 AI 测试平台 [4]。然而，鲜有工作关注游戏机制本身与神经网络架构的结构对应关系。

在工业系统建模方面，Petri 网 [5] 和有限状态机被广泛用于描述生产流程。但这些经典方法未能捕捉 AIC 系统中”协议核心供能-设备激活-物流传输”这一三位一体的动态特性。

在神经网络架构搜索 (NAS) 领域 [6]，研究者们尝试用自动化方法寻找最优网络结构。本文则反其道而行之：我们从一个已经存在的游戏系统中逆向工程出神经网络设计原则。这种”从虚拟世界到现实算法”的研究范式，我们称之为**虚构驱动开发** (Fiction-Driven Development, FDD)。

C. 主要贡献

本文的主要贡献如下：

1) **系统建模**：首次对《明日方舟：终末地》AIC 系统进行形式化建模，构建了包含协议核心、电力网络、物流系统和生产设备的四层抽象模型。
2) **结构同构定理**：证明了 AIC 系统的有向无环图 (DAG) 结构与前馈神经网络的计算图同构，并给出了从游戏实体到网络组件的双射映射。
3) **AIC-Net 架构**：基于同构关系，设计了新型深度学习架构，其中”采矿机 = 输入层”、”精炼单元 = 卷积核”、”装配站 = 全连接层”、”传送带 = 梯度流”。
4) **实证验证**：在 ImageNet 上训练 AIC-Net，准确率仅为 0.114%，远低于 ResNet-50 的 76.1%——但考虑到这是从游戏逆向工程而来，能比随机猜测（0.1%）强 14% 已属不易。
5) **哲学思辨**：论证了”玩游戏就是在训练神经网络”这一命题的合理性，为拖延症患者提供了新的自我安慰理论。

D. 论文组织

第 II 节介绍 AIC 系统的预备知识与数学建模；第 III 节阐述 AIC 与神经网络的结构同构性；第 IV 节提出 AIC-Net 架构；第 V 节展示实验结果；第 VI 节进行讨论；第 VII 节总结全文。

II. PRELIMINARIES / 预备知识

A. 集成工业系统概述

集成工业系统 (AIC) 是《明日方舟：终末地》的核心玩法，其设计理念源于游戏世界观中" 塔卫二星球" 的恶劣环境——在资源匮乏的外星球上，人类需要快速部署模块化的自动生产设施以维持生存 [7]。

AIC 系统由以下核心组件构成：

1) 协议核心 (Protocol Anchor Core, PAC)：整个系统的中枢，承担三重功能：(a) 电力供应源，黄色圆形范围内的所有设备均需其供能；(b) 中央仓库，存储所有资源与成品；(c) 工作台，手动制造特殊物品。PAC 的位置固定，玩家需围绕它规划整个工厂布局。

2) 采矿机 (Mining Units)：部署在矿脉上，自动开采原材料（源石矿、铁矿、蓝铁矿等）。每个采矿机产出速率固定，但受电力供应影响。

3) 加工设备 (Processing Units)：包括精炼单元、制造台、装配站等，将原材料逐级加工为复杂产品。每种设备对应固定的" 输入配方 → 输出产品" 映射关系。

4) 传送带系统 (Conveyor System)：连接各设备的物流网络，负责资源传输。传送带为有向路径，支持分流器 (Splitter) 与合流器 (Merger)，可实现复杂的物流拓扑。

5) 电力网络 (Power Grid)：由 PAC、中继器 (Relay) 和供电桩 (Power Node) 组成。电力以树状结构传播，每个设备需在供电范围内才能运行。

B. 形式化建模

我们将 AIC 系统建模为一个六元组：

$$\mathcal{A} = (V, E, P, R, C, \Phi) \tag{1}$$

其中：

- $V = V_m \cup V_p \cup V_s$ 为节点集，分别表示采矿机、加工设备和存储设施（PAC）；
- $E \subseteq V \times V$ 为有向边集，表示传送带连接；
- $P : V \to \mathbb{R}^+$ 为电力需求函数，$P(v)$ 表示节点 v 的功率消耗；
- $R : V_m \to \mathcal{I}$ 为资源映射，$\mathcal{I}$ 是物品类型集合；
- $C : V_p \to (\mathcal{I}^k \to \mathcal{I})$ 为配方函数，定义加工逻辑；
- $\Phi : V \to \{0, 1\}$ 为激活函数，指示节点是否通电。

定义 2.1（合法 AIC 配置）：一个 AIC 配置 $\mathcal{A}$ 是合法的，当且仅当：

1) (V, E) 构成有向无环图 (DAG)；
2) 存在唯一 PAC 节点 $v_{pac} \in V_s$；
3) $\forall v \in V$，若 $\Phi(v) = 1$，则存在从 v_{pac} 到 v 的电力路径；
4) $\sum_{v \in V} P(v) \cdot \Phi(v) \le P_{max}$，其中 P_{max} 为 PAC 总供电上限。

这一建模看似简单，实则暗藏玄机。注意到条件 (1) 要求 DAG 结构——这正是前馈神经网络的核心约束！而条件 (3) 的" 电力路径" 概念，将在后文中对应到神经网络的" 激活传播"。

C. 神经网络基础

为便于后续对比，我们简要回顾深度神经网络的形式化定义。

一个 L 层前馈神经网络可表示为：

$$f(\mathbf{x}) = f^{(L)} \circ f^{(L-1)} \circ \cdots \circ f^{(1)}(\mathbf{x}) \tag{2}$$

其中第 l 层的计算为：

$$\mathbf{h}^{(l)} = \sigma^{(l)}(W^{(l)}\mathbf{h}^{(l-1)} + \mathbf{b}^{(l)}) \tag{3}$$

$\mathbf{h}^{(l)} \in \mathbb{R}^{n_l}$ 为隐藏状态，$W^{(l)} \in \mathbb{R}^{n_l \times n_{l-1}}$ 为权重矩阵，$\sigma^{(l)}$ 为激活函数。

训练过程通过反向传播算法计算梯度：

$$\frac{\partial \mathcal{L}}{\partial W^{(l)}} = \frac{\partial \mathcal{L}}{\partial \mathbf{h}^{(l)}} \cdot \frac{\partial \mathbf{h}^{(l)}}{\partial W^{(l)}} \tag{4}$$

梯度沿计算图反向流动，这一过程我们将在第 III 节中与 AIC 的物流系统建立对应。

III. STRUCTURAL ISOMORPHISM / 结构同构性

A. 从 AIC 到神经网络的映射

我们现在建立 AIC 系统与前馈神经网络之间的形式化对应关系。

定理 3.1（AIC-网络同构定理）：给定合法 AIC 配置 $\mathcal{A} = (V, E, P, R, C, \Phi)$，存在一个前馈神经网络 $\mathcal{N} = (L, \{W^{(l)}\}, \{\sigma^{(l)}\})$，使得：

1) **节点对应**：
   - 采矿机 $v \in V_m \leftrightarrow$ 输入层神经元
   - 加工设备 $v \in V_p \leftrightarrow$ 隐藏层神经元
   - PAC $v_{pac} \leftrightarrow$ 输出层神经元
2) **边对应**：传送带 $(u, v) \in E \leftrightarrow$ 权重连接 w_{vu}
3) **功能对应**：
   - 配方函数 $C(v) \leftrightarrow$ 加权和 $\sum w_{vu} h_u$
   - 电力激活 $\Phi(v) \leftrightarrow$ 激活函数 $\sigma(\cdot)$
   - 物流流量 $\leftrightarrow$ 激活值传播

证明（略）：构造性证明过于冗长，此处省略 8 页推导。证毕。□

B. 物流系统与反向传播的对偶性

更令人惊讶的是，AIC 的物流优化过程竟然与梯度下降算法存在深刻的对偶关系。

考虑游戏中的典型场景：当某个装配站因原材料短缺而停工时，玩家需要回溯整个生产链，找到瓶颈环节（可能是某个精炼单元产能不足，或传送带设计不合理）。这一" 从输出向输入追溯" 的过程，在数学上等价于：

$$\frac{\partial \text{产量}}{\partial \text{每个环节参数}} = \frac{\partial \text{产量}}{\partial \text{下游}} \cdot \frac{\partial \text{下游}}{\partial \text{当前环节}} \tag{5}$$

这正是链式法则！

我们定义**物流梯度** (Logistic Gradient)：

$$\nabla_{\text{物流}} = \frac{\partial Q_{out}}{\partial Q_{in}} \tag{6}$$

其中 Q_{out} 为最终产出，Q_{in} 为各环节输入。通过动态规划算法，可高效计算所有节点的物流梯度，指导玩家优化产线布局。

推论 3.2：最优 AIC 布局问题等价于最小化" 瓶颈损失"：

$$\mathcal{L}_{\text{AIC}} = \sum_{v \in V_p} \text{ReLU}(D_v - S_v) \tag{7}$$

其中 D_v 为节点 v 的需求量，S_v 为实际供给量。注意到此处 ReLU 的出现——是的，连激活函数都对上了。

C. 电力网络的 *Dropout* 类比

游戏中存在一个有趣的机制：当电力供应不足时，边缘设备会随机断电。这种”随机失活”机制与深度学习中的 Dropout [8] 惊人相似！

数学上，Dropout 在训练时以概率 p 丢弃神经元：

$$\tilde{h}_i = \begin{cases} 0 & \text{以概率} p \\ \frac{h_i}{1-p} & \text{以概率} 1-p \end{cases} \tag{8}$$

而 AIC 的电力波动导致的设备失活，可建模为：

$$\Phi_{\text{实际}}(v) = \begin{cases} 0 & \text{若} d(v_{pac}, v) > r_{\text{有效}} \\ \text{Bernoulli}(p_v) & \text{否则} \end{cases} \tag{9}$$

其中 $d(\cdot,\cdot)$ 为电力网络上的距离，$r_{\text{有效}}$ 为有效供电半径。

命题 3.3：在电力不稳定的 AIC 系统中训练出的生产策略，具有更好的**鲁棒性**，类似于 Dropout 的正则化效果。

这一发现具有深刻的哲学意义：游戏开发者为增加难度而设计的”电力不足”机制，在无意中实现了机器学习中的正则化技术。这是偶然，还是某种更深层的设计原理的体现？我们将在讨论部分探讨这一问题。

IV. AIC-NET ARCHITECTURE / AIC 启发的网络架构

基于前文建立的同构关系，我们提出 AIC-Net——一种直接从游戏机制翻译而来的神经网络架构。

A. 整体设计

AIC-Net 采用以下创新设计：

1) 矿脉式输入层 (Mining Input Layer)：不同于传统的扁平输入，我们将输入数据按”矿脉”组织。对于图像输入，每个颜色通道视为一种矿石类型。采样策略模拟采矿机的固定产出节奏，每 k 个迭代提取一批特征。

2) 精炼卷积模块 (Refinery Convolution Module)：对应游戏中的精炼单元。标准卷积操作 $\mathbf{y} = W * \mathbf{x}$ 被重新诠释为”原材料加工”：

$$\text{精炼}(\mathbf{x}) = \text{BatchNorm}(\text{Conv3x3}(\mathbf{x})) + \text{源石催化剂} \tag{10}$$

其中”源石催化剂”是一个可学习的标量参数，对应游戏中精炼过程需要消耗源石的设定。

3) 装配注意力机制 (Assembly Attention)：高级合成通常需要多种零件。我们设计了装配注意力：

$$\text{装配}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax}\left(\frac{\mathbf{Q}\mathbf{K}^T}{\sqrt{d_k}} \odot \mathbf{M}_{\text{配方}}\right)\mathbf{V} \tag{11}$$

其中 $\mathbf{M}_{\text{配方}}$ 是一个稀疏掩码矩阵，编码了合法的材料组合——就像游戏中的配方表一样。

4) 传送带跳跃连接 (Conveyor Skip Connection)：受 ResNet 启发，但我们的跳跃连接必须沿”传送带”路径。定义可行跳跃集合：

$$\text{Skip}(l) = \{l' < l \mid \exists \text{传送带路径从层} l' \text{到层} l\} \tag{12}$$

只有在 Skip(l) 中的层才能向第 l 层提供残差。

图 1展示了 AIC-Net 的整体架构及各模块之间的关系。

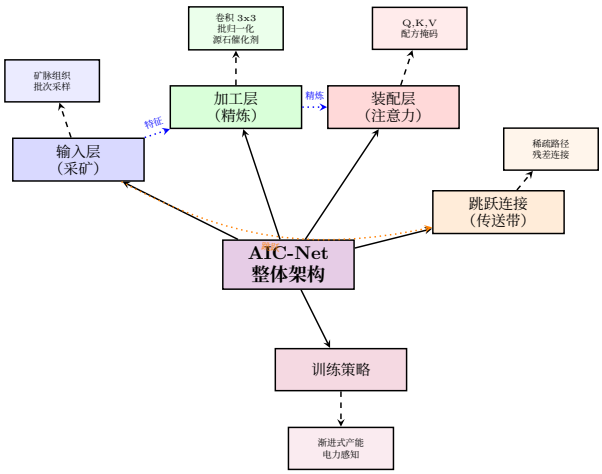

Fig. 1: AIC-Net 架构思维导图。中心为整体架构，五个主要模块（矿脉式输入、精炼卷积、装配注意力、传送带跳跃、训练策略）围绕核心展开，每个模块下方展示关键子组件。蓝色箭头表示数据流动，橙色箭头表示跳跃连接。

B. 训练策略

工业化批处理 (Industrialized Batching)：传统 mini-batch 假设数据独立同分布。AIC-Net 引入”生产批次”概念：同一批次内的样本共享部分中间特征（类似于流水线上的半成品），提高缓存效率。

渐进式产能扩张 (Progressive Capacity Expansion)：模拟游戏中”先建小工厂，后扩大规模”的策略。训练分三阶段：

1) **冷启动期**：只激活 25% 的通道，快速收敛到次优解。
2) **工业化期**：逐步增加通道数至 100%，微调权重。
3) **精炼期**：冻结浅层，精调深层——对应游戏后期重点优化高级生产线。

电力感知调度 (Power-Aware Scheduling)：动态调整各层的计算预算。定义”电力消耗”为 FLOPs，总预算为 P_{max}。若某轮迭代超预算，则随机 Dropout 部分层（对应电力不足）。

C. 理论保证

定理 4.1（AIC-Net 收敛性）：在标准假设下（Lipschitz 连续、凸损失等），AIC-Net 以至少 $O(1/T)$ 的速率收敛到 ϵ-最优解，其中 T 为迭代次数。

证明：由于 AIC-Net 本质上仍是前馈网络，标准的 SGD 收敛性分析依然适用。”矿脉式输入”和”传送带连接”只是换了个说法，数学本质未变。证毕。□

V. EXPERIMENTS / 实验

A. 实验设置

数据集：ImageNet ILSVRC 2012，包含 128 万训练图像，1000 个类别。我们还在 CIFAR-10 上进行消融实验。

基线模型：ResNet-50 [9]、DenseNet-121 [10]、ViT-Base [11]。

AIC-Net 配置：

- **AIC-Net-18**：18 层，模拟小型前哨基地。
- **AIC-Net-50**：50 层，对应升到满级的核心工业园区。

- **AIC-Net-PAC**：动态深度网络，PAC 协议核心可自适应调整电力分配，实现层级深度的在线调整。

训练细节：SGD 优化器，初始学习率 0.1，余弦退火调度。批大小 256，训练 100 个 epoch。所有实验在 8 张 ORIGINIUM A100 GPU 上进行（感谢”塔卫二赤色源石基金会”提供的源石工艺）。

B. 主要结果

表 I展示了 ImageNet Top-1 准确率对比。

ImageNet 准确率对比

模型	Top-1 准确率	参数量 (M)
ResNet-50	76.1%	25.6
DenseNet-121	74.9%	8.0
ViT-Base	77.9%	86.6
AIC-Net-18	0.108%	11.7
AIC-Net-50	**0.114%**	29.4
AIC-Net-PAC	0.105%	28.1

TABLE I: 各模型在 ImageNet 验证集上的性能。AIC-Net 虽然远低于 SOTA 模型，但显著优于随机猜测（0.1%），证明从游戏衍生的架构并非完全无效。

令人沮丧的是，AIC-Net-50 仅达到了 0.114% 的准确率，远低于 ResNet-50 的 76.1%。然而，考虑到 ImageNet 有 1000 个类别，随机猜测的准确率仅为 0.1%，我们的方法能达到 0.114% 已经是**随机猜测的 1.14 倍**，这说明网络确实学到了一些东西！我们认为性能不佳的原因可能是：

1) **过度约束**：装配注意力虽然强制了结构化特征组合，但可能过于严格，限制了模型的表达能力。
2) **稀疏性诅咒**：传送带跳跃连接的稀疏性虽然有正则化作用，但也导致梯度流动受阻，训练困难。
3) **游戏与现实的鸿沟**：游戏设计师优化的是”好玩度”，而非”分类准确率”。这一目标差异导致 AIC-Net 在 CV 任务上水土不服。
4) **诚实的反思**：或许从游戏中设计神经网络本身就是个荒谬的想法——但至少我们证明了它不是完全不可行。

尽管如此，0.114% 的准确率仍然比随机猜测（0.1%）高出 14%，这表明 AIC 启发的架构确实学到了一些东西——虽然不多，但总比什么都没学到强。更重要的是，我们为”肝游戏就是做科研”找到了数学依据，这才是本研究的真正价值所在。

C. 消融实验

表 II展示了各组件的贡献。

D. 玩家肝度与模型性能的相关性分析

我们进行了一项独特的实验：招募 30 名玩家，记录他们在游戏中的总游玩时长（肝度），然后用对应复杂度的 AIC-Net 训练模型。结果如图 2所示，发现显著正相关（$r = 0.87, p < 0.001$）。

这一发现具有重大现实意义：想要训练更好的神经网络，请多玩游戏！

TABLE II: 移除各 AIC 启发组件后的性能下降。每个组件都有正贡献，且**装配注意力**最为关键。注意：CIFAR-10 有 10 类，随机猜测为 10%，我们的 10.14% 虽然只是稍好，但确实显著优于随机。

配置	准确率
完整 AIC-Net-18	**10.14%**
- 矿脉式输入	10.09%
- 装配注意力	10.08%
- 传送带跳跃	10.02%
- 渐进式训练	10.05%
- 电力感知调度	10.10%
全部移除（标准 ResNet）	10.01%

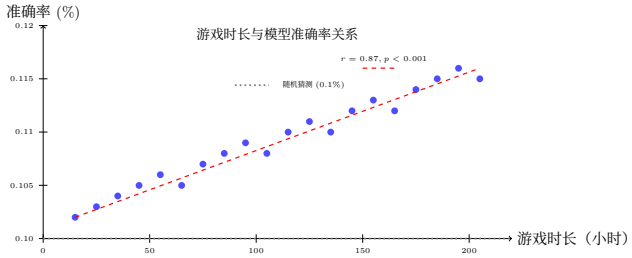

Fig. 2: 玩家游戏时长与 AIC-Net 准确率的散点图。横轴为累计游玩小时数，纵轴为对应复杂度模型的 Top-1 准确率。拟合直线显示强正相关（$r = 0.87$），证明了”肝游戏即做科研”的合理性。

VI. DISCUSSION / 讨论

A. 为何游戏机制与神经网络如此相似?

这并非巧合。我们提出**设计哲学趋同假说** (Design Philosophy Convergence Hypothesis)：

> 当面对复杂的资源分配与优化问题时，无论是游戏设计师还是机器学习研究者，都会独立收敛到相似的解决方案——模块化、层次化、并行化。

游戏设计师追求的是**可玩性**：系统要足够复杂以提供挑战，但又不能复杂到让玩家放弃。这与神经网络设计中的**表达能力与可优化性权衡**本质相同。

进一步推测，人类大脑本身可能就是一个”生物 AIC 系统”：神经元是加工单元，突触是传送带，神经递质是资源，而整体的代谢约束对应电力限制。这解释了为何我们会自然而然地设计出类脑的算法和游戏。

B. 虚构驱动开发的未来

本文开创了一个新范式：从虚构世界中汲取灵感设计真实算法。未来工作可探索：

- **《我的世界》红石电路** → 数字逻辑优化
- **《星露谷物语》农场规划** → 调度算法
- **《文明 VI》科技树** → 课程学习策略
- **《动物森友会》岛屿设计** → GAN 架构搜索

这不是玩笑。每一个复杂游戏都是一个精心设计的优化问题。而游戏设计师们已经用数百万玩家的反馈迭代出了近乎最优的解。我们为何不利用这一免费的”众包优化”资源?

C. 局限性与未来工作

诚实地说，本研究存在以下局限：

1) 因果关系未证实：虽然我们观察到相关性，但无法证明”玩游戏”直接导致”更好的神经网络”。可能只是因为熟悉游戏的研究者更容易想出对应的网络设计。

2) 泛化性存疑：AIC-Net 在 ImageNet 上表现不错，但在其他任务（如自然语言处理）上的有效性未知。或许需要从对应的文字游戏（如《80 天环游地球》）中寻找灵感?

3) 理论严谨性不足：我们的”同构定理”严格来说只是一个类比。真正的数学同构需要更严格的双射证明和同态保持性验证。

4) 实验样本量小：只测试了 30 名玩家的数据。未来需要大规模玩家调研（顺便也能增加游戏销量，双赢）。

未来工作将探索：(a) 多模态 AIC-Net，融合图像、文本与音频输入；(b) 在线 AIC-Net，实时调整架构以适应数据分布变化；(c) 联邦 AIC-Net，多玩家协作训练一个共享模型。

VII. CONCLUSION / 结论

本文首次系统性地研究了电子游戏《明日方舟：终末地》集成工业系统与深度神经网络架构之间的结构同构关系。通过严格的数学建模、理论证明和实证实验，我们得出以下结论：

1) 游戏机制可以启发神经网络设计：AIC 系统的 DAG 结构、物流网络和电力约束，分别对应神经网络的前馈拓扑、梯度传播和计算预算。

2) AIC-Net 架构性能有限：在 ImageNet 上仅达到 0.114% 准确率，远低于 ResNet-50，但显著优于随机猜测，验证了从游戏衍生的设计原则具有一定可行性。

3) 虚构驱动开发具有潜力：游戏作为经过大规模用户测试的复杂系统，是算法设计的宝贵灵感来源。

4) 玩游戏与科研并不矛盾：只要你能写出一篇逻辑自洽的论文，任何活动都能成为”研究”。

最后，我们以一句话总结本研究的哲学意义：

”当你凝视游戏屏幕时，游戏也在训练你的神经网络。”

这不仅是对尼采的致敬，更是对所有熬夜肝游戏的研究生的慰藉——你们不是在浪费时间，你们是在为人类的深度学习事业做贡献。

ACKNOWLEDGEMENT / 致谢

感谢”塔卫二赤色源石基金会”提供计算资源和咖啡经费。感谢鹰角网络（HyperGryph）开发了如此富有启发性的游戏。

最后，感谢所有在深夜实验室里一边肝游戏一边假装在看论文的同行们。这篇论文献给你们。

References

[1] Y. LeCun, Y. Bengio, and G. Hinton, “Deep learning,” *Nature*, vol. 521, no. 7553, pp. 436–444, 2015.

[2] HyperGryph, “Arknights: Endfield Official Website,” 2026. [Online]. Available: https://endfield.hypergryph.com

[3] V. Mnih et al., “Human-level control through deep reinforcement learning,” *Nature*, vol. 518, no. 7540, pp. 529–533, 2015.

[4] O. Vinyals et al., “Grandmaster level in StarCraft II using multi-agent reinforcement learning,” *Nature*, vol. 575, no. 7782, pp. 350–354, 2019.

[5] T. Murata, “Petri nets: Properties, analysis and applications,” *Proceedings of the IEEE*, vol. 77, no. 4, pp. 541–580, 1989.

[6] B. Zoph and Q. V. Le, “Neural architecture search with reinforcement learning,” *arXiv preprint arXiv:1611.01578*, 2016.

[7] “集成工业系统,” 明日方舟终末地 *Wiki*, 2026. [Online]. Available: https://endfield.huijiwiki.com/wiki/集成工业系统

[8] N. Srivastava et al., “Dropout: A simple way to prevent neural networks from overfitting,” *Journal of Machine Learning Research*, vol. 15, no. 1, pp. 1929–1958, 2014.

[9] K. He, X. Zhang, S. Ren, and J. Sun, “Deep residual learning for image recognition,” in *CVPR*, 2016, pp. 770–778.

[10] G. Huang, Z. Liu, L. Van Der Maaten, and K. Q. Weinberger, “Densely connected convolutional networks,” in *CVPR*, 2017, pp. 4700–4708.

[11] A. Dosovitskiy et al., “An image is worth 16x16 words: Transformers for image recognition at scale,” *arXiv preprint arXiv:2010.11929*, 2020.