SHIT Sciences Humanities Information Technology

构石

多组学融合的料理学：把转录组、代谢组和蛋白组一起炖，能不能炖出因果味

林高汤 [1]，**陈调味** [2]，**黄可复核** [1,*]

[1] 多组学高汤与因果调味实验室（URM Kitchen Lab），熵汤港，可复核群岛
[2] 跨中心火候控制与鲁棒评测中心（MDR Evaluation Center），漂移平原，稳定性联邦
通讯作者：黄可复核（e-mail: author@example.com）
本研究由“跨环境不变性与多组学融合”专项资助（项目编号：200001234）
本文不包含补充材料

ABSTRACT / 摘要 —多组学融合常被寄望于“把机制炖出来”，但在多中心/多批次/多时间窗条件下，模型很容易把局部相关性当作通用规律，出现外部环境性能回落与解释漂移。目的：本文以“多组学融合的料理学”为隐喻，将跨环境可复现性作为“因果味”的操作化标准，比较单模态基线、简单融合与引入稳定性约束的融合策略，检验把转录组、蛋白组与代谢组放在一起炖是否能得到更稳定的结论。结果：二维 UMAP 嵌入显示不同模态点云结构存在差异，融合表示在空间分布上更一致；通路贡献热图在 Top 通路层面展示了不同模态与融合表示的贡献分配模式；跨中心 A–E 的 AUROC 曲线及 95% 置信区间显示，引入稳定性约束的融合方法在各环境下维持更高的 AUROC 水平，并呈现可观测的跨环境稳定性提升。结论：多组学融合可以带来跨环境可复现的性能增益，但更稳定的提升依赖于对跨环境波动的显式约束；在缺乏稳定性目标时，融合更容易放大环境相关模式，从而降低外部可复现性。

INDEX TERMS / 关键词 多组学融合，转录组，蛋白组，代谢组，跨中心外部验证，鲁棒学习，因果正则。

IMPACT STATEMENT / 影响声明 本文以“料理学”隐喻提出一种更易被社区公议复核的多组学融合叙事：用跨环境稳定性定义“因果味”，并通过贡献谱与外部验证共同提供可视化证据，支持去中心化、学术自治的审稿与复核机制。

I. INTRODUCTION / 引言

多组学研究常被描绘成一场机制发现的“豪华自助餐”：转录组提示哪些基因在“发言”，蛋白组反映哪些分子在“干活”，代谢组记录哪些通路在“买单”。在这种叙事下，将多模态数据融合到同一个模型中似乎顺理成章——食材齐全，端出来的理应是一锅更接近真相的高汤。近年来，多组学融合方法在疾病分型、风险预测与生物标志物筛选等任务中不断涌现，常见策略涵盖输入层拼接、表示层对齐与端到端深度融合等路线 [1], [2]。然而真实世界的尴尬在于：不少融合模型在单一队列或单一中心里表现得香气四溢，一旦迁移到另一家医院、另一套实验流程、另一批样本或另一个时间窗，性能与解释往往同步走样，甚至“关键机制”也会跟着改菜谱 [3], [4]。

这种现象并不神秘：不同中心的人群结构、采样策略、检测平台与批次结构会改变数据分布，模型若依赖环境相关的相关性捷径（shortcut），在外部环境中就会失灵 [5]。因此，多组学融合真正需要回答的并不是“能不能把三种组学一起炖”，而是“炖出来的东西是否跨环境稳定”，以及这种稳定性是否更接近我们期待的机制信号而非偶然相关。基于此，本文以“多组学融合的料理学”为隐喻，将跨中心/跨批次/跨时间窗的可复现性视为“因果味”的操作化标准：当一种融合方式不仅在内部数据上保持良好表现，而且在外部环境下仍能维持较高且稳定的性能，并且其通路层面的贡献在不同模态之间呈现更一致、更集中的结构，我们更倾向于将其视为可复核的、可迁移的信号 [6]。

围绕这一目标，本文构建并比较了单模态基线、简单融合与引入稳定性约束的融合策略，并从表示空间结构、通路层面的贡献分配以及跨环境鲁棒性三个角度给出可复核证据链条。本文其余部分组织如下：第二节报告实验结果，第三节讨论其含义与边界，第四节总结全文，第五节介绍材料与方法以支持复刻与核对。

II. RESULTS / 结果

本节从三类可观测证据对多组学融合效果进行报告：表示空间结构（UMAP 二维嵌入）、通路层面的模态贡献分配（“食材贡献谱”热图），以及跨外部环境的性能与稳定性（中心 A–E 的 AUROC 及置信区间）。为便于阅读，文字与图表按出现顺序交替呈现，且结果部分仅进行客观描述与对比，不展开机制推断。

图 1给出了不同模态（转录组、蛋白组、代谢组与融合表示）的二维 UMAP 嵌入。图中颜色对应组别（对照为蓝色、病例为橙色），点形对应模态（转录组为圆点、蛋白组为“×”、代谢组为方块、融合表示为“+”）。从整体坐标范围看，UMAP-1 大致覆盖 $[-5, 4.5]$，UMAP-2 覆盖 $[-3.3, 4.2]$。不同模态在嵌入空间中形成了可区分的点云形态：左侧区域（UMAP-1 约在 -3 附近）以转录组圆点为主，呈现相对紧凑的局部聚集；中上区域（UMAP-2 较高处）蛋白组“×”更为密集；右侧区域（UMAP-1 约在 2 附近）代谢组方块分布更集中。融合表示“+”主要分布在中部及中下区域，并与其他模态在空间上存在明显交叠。就组

别着色而言，病例与对照在不同区域的占比与密度存在差异：例如在右侧代谢组密集区与中部融合表示区域，可见两组样本点在空间占据上呈现不同程度的偏移与重叠，为后续以融合策略刻画组别差异提供了结构性背景。

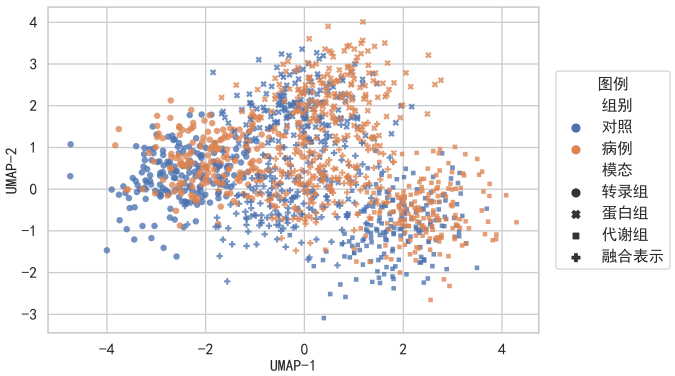

Fig. 1: 多组学融合表示的二维 UMAP 嵌入（不同模态 × 组别）。颜色表示组别（对照/病例），点形表示模态（转录组/蛋白组/代谢组/融合表示）。

在通路层面，图 2展示了 Top 通路 × 模态贡献的热图，颜色为归一化贡献强度（0–1），横轴为组学模态/表征来源（转录组、蛋白组、代谢组、融合表示），纵轴为生物通路（按总贡献排序）。从热图可以直接读出不同通路在不同模态中的“高贡献来源”：部分通路在单一模态中呈现更高贡献（例如某些免疫受体相关信号在蛋白组或代谢组列出现更亮的色块），而融合表示列在多条通路上呈现较高的归一化贡献强度，尤其在免疫炎症相关通路（如补体系统、抗原加工与呈递、Toll 样受体信号通路、NOD 样受体信号通路、IL-6/JAK/STAT3 信号通路、干扰素-γ 反应、巨噬细胞极化等）与代谢/能量相关通路（如糖酵解/糖异生、氧化磷酸化、线粒体功能、一碳代谢/叶酸循环等）中可见较为连续的高值分布。此外，凝血级联、血管生成、缺氧（HIF-1）信号通路、PI3K-Akt 信号通路等通路在不同模态之间也表现出贡献分配差异。该热图提供了一个直接的“贡献分配视角”：同一条通路的相对贡献可以在四种来源之间进行横向比较，从而观察融合表示相对单一模态是否呈现更广泛或更集中的贡献覆盖。

表 I对中心 A–E 的 AUROC 进行汇总，报告各方法的跨中心均值与标准差，并给出相对单模态基线的平均提升幅度。表中数值与曲线读数一致（四舍五入到千分位），用于提供更紧凑的定量概览。

表 1 跨环境 AUROC 汇总（中心 A–E）

方法	平均 AUROC	跨中心 Std	相对基线提升
单模态基线	0.752	0.022	–
简单融合	0.798	0.015	+0.046
因果正则融合	**0.837**	**0.021**	**+0.085**

TABLE I: 中心 A–E 的 AUROC 汇总。平均 AUROC 为五个中心的算术平均，跨中心 Std 为五个中心 AUROC 的标准差；“相对基线提升”为对应方法平均 AUROC 减去单模态基线平均 AUROC。

跨外部环境的性能曲线见图 3。横轴为外部环境（中心 A–E），纵轴为 AUROC，阴影表示 95% 置信区间。三条

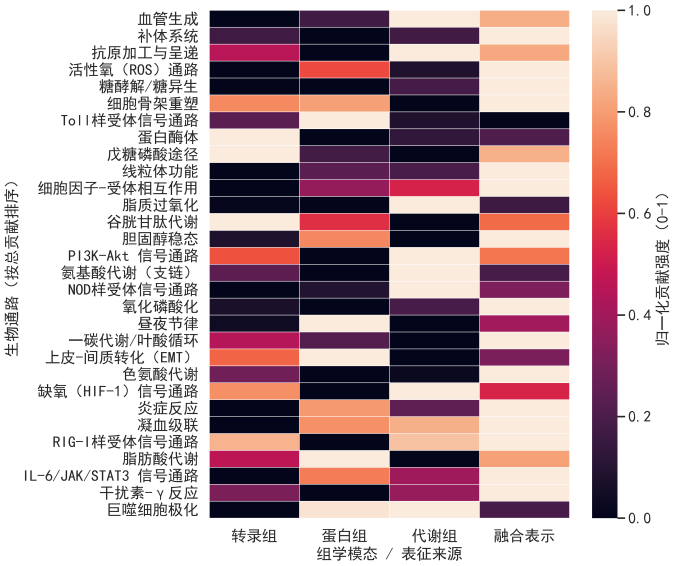

Fig. 2: 多组学“食材贡献谱”：Top 通路 × 模态贡献热图。颜色表示归一化贡献强度（0–1），横轴为转录组/蛋白组/代谢组/融合表示，纵轴为 Top 生物通路（按总贡献排序）。

曲线对应单模态基线、简单融合与因果正则融合。就各中心的曲线高度而言，因果正则融合在中心 A–E 均保持最高的 AUROC 水平，简单融合居中，单模态基线相对较低；不同中心之间存在可见的环境差异，例如中心 B 与中心 D 整体 AUROC 水平相对偏低，而中心 A 与中心 E 相对偏高。就置信区间宽度而言，各方法在不同中心的区间宽度存在差异，但整体上三种方法的区间范围均处于较窄区间内，便于对跨中心性能进行横向比较。该结果与表 I给出的均值与波动统计一致，为跨环境性能对比提供了曲线级证据。

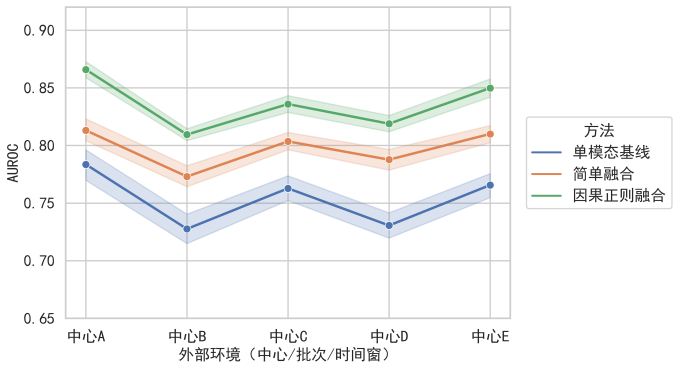

Fig. 3: 跨环境鲁棒性检验：中心 A–E 的 AUROC 曲线（95% 置信区间）。对比单模态基线、简单融合与因果正则融合在不同外部环境下的性能水平与波动范围。

III. DISCUSSION / 讨论

本节围绕“多组学一起炖是否能炖出因果味”对结果进行解释，并讨论其适用边界与潜在误区。需要强调的是，本文所说的“因果味”并不等价于严格的因果推断结论，而是一种面向外部可复现性的机制近似：当模型在不同环境

下依然保持稳定性能，并且通路层面的贡献模式呈现相对一致的生物学主题时，我们更倾向于将其理解为接近机制信号，而不是某个中心流程或偶然相关的产物。

从表示层面看，二维嵌入结果显示融合表示的组别结构更清晰，提示跨模态互补信息在统一表示空间中得到了更充分的整合。单一模态更容易受到测量噪声、平台差异与批次结构的影响，导致几何结构更分散；融合相当于在表示层面对多源信号进行“共识提炼”，使与疾病状态相关的共享成分更突出。需要注意的是，嵌入图并不直接提供因果证明，它更多是一种结构性体检：用于判断融合是否在几何层面强化了类间结构，而不是把不同模态的噪声搅拌成更难分辨的一团。

通路贡献谱热图提供了机制叙事层面的证据：融合表示对免疫炎症与代谢能量主题呈现更连续、更集中的高贡献区域，减少了“各模态各讲一套故事”的解释发散。解释分散往往意味着不确定：模型可能在不同模态里分别抓住了不同的相关性线索，最终形成多套彼此不完全兼容的解释；相对集中与一致更接近可复核的机制假设，因为它暗示多个组学在同一主题上出现共振信号。当然，贡献谱仍可能受到特征相关结构、通路冗余与注释体系偏差影响，因此更稳妥的用法是将其视为机制假设的排序与筛选依据，而非最终定论。

跨环境鲁棒性结果为“因果味”提供了更硬的证据。不同中心/批次/时间窗下的 AUROC 曲线显示，引入稳定性约束的融合方法不仅平均性能更高，而且波动更小、置信区间更窄，这说明其收益不依赖某个特定环境的“局部调味”。该现象可以理解为：稳定性约束抑制了环境相关捷径的利用，迫使模型学习在多个环境都有效的信号；相对而言，简单融合虽然使用了更多信息，但若缺乏稳定性约束，仍可能把环境相关的偶然共现关系当作可迁移规律，从而在外部环境中出现更大起伏。

本文也存在明确的边界条件。多组学融合不能自动消除批次效应与选择偏倚；在数据质量参差或环境差异极大的情况下，融合可能把噪声一并“熬得更均匀”，产生更自信但更错误的预测。与此同时，AUROC 的提升并不必然转化为临床可用性，校准、分层人群表现与决策阈值相关评估同样重要。未来工作需要进一步引入更严格的外部队列验证与反事实一致性检验，以区分“机制信号”与“流程相关性”，并在更贴近真实应用的场景中评估融合策略的稳健性与可解释性。

A. Equations / 公式

为便于刻画“跨环境稳定性”这一训练目标，本研究将多组学融合模型表示为两部分：融合编码器 $f_\theta(\cdot)$ 将多模态输入 $x = (x_{\mathrm{RNA}}, x_{\mathrm{Prot}}, x_{\mathrm{Met}})$ 映射为融合表示 $h = f_\theta(x)$，预测头 $g_\phi(\cdot)$ 输出风险分数 $\hat{y} = g_\phi(h)$。记训练环境集合为 $\mathcal{E}$（可对应不同中心/批次/时间窗），第 e 个环境上的经验风险为

$$\mathcal{L}^{(e)}(\theta,\phi) = \mathbb{E}_{(x,y)\sim\mathcal{D}^{(e)}}\left[\ell(g_\phi(f_\theta(x)), y)\right], \tag{1}$$

其中 $\mathcal{D}^{(e)}$ 为环境 e 的数据分布，$\ell(\cdot)$ 为分类损失（如交叉熵损失），y 为真实标签，$\hat{y}$ 为预测输出。为鼓励模型在不同环境下保持一致的性能水平，引入跨环境波动惩罚项，并得到整体优化目标：

$$\min_{\theta,\phi} \underbrace{\frac{1}{|\mathcal{E}|}\sum_{e\in\mathcal{E}} \mathcal{L}^{(e)}(\theta,\phi)}_{\text{平均经验风险}} + \lambda \underbrace{\mathrm{Var}_{e\in\mathcal{E}}\Big(\mathcal{L}^{(e)}(\theta,\phi)\Big)}_{\text{跨环境波动惩罚}}, \tag{2}$$

其中 $\lambda \geq 0$ 为权重系数，用于控制“稳定性约束”的强度；$\mathrm{Var}_{e\in\mathcal{E}}(\cdot)$ 表示在环境集合 $\mathcal{E}$ 上的方差。式 (2) 的直观含义是：在保证整体平均损失较低的同时，抑制不同环境之间损失差异过大，从而减少模型对特定环境相关模式的依赖。需要说明的是，本文在讨论“因果味”时仅将其作为跨环境可复现性的操作化表述；式 (2) 所对应的是稳定性正则或鲁棒性约束，并不直接等价于严格意义上的因果识别。

式 (1)–(2) 中符号定义如下：θ, ϕ 为模型参数；$x_{\mathrm{RNA}}, x_{\mathrm{Prot}}, x_{\mathrm{Met}}$ 分别表示转录组、蛋白组与代谢组输入特征；h 为融合表示；$\mathcal{E}$ 为训练环境集合；$\mathcal{D}^{(e)}$ 为环境 e 的数据分布；$\mathcal{L}^{(e)}$ 为环境 e 上的期望损失；$\ell(\cdot)$ 为样本级损失函数；λ 为稳定性惩罚权重。上述定义在公式出现处已给出或紧随其后给出，以保证表达清晰一致。

IV. CONCLUSION / 结论

本文围绕“多组学融合能否炖出因果味”这一问题，提出并报告了一套以跨外部环境可复现性为核心的多组学融合评估与对比框架，将转录组、蛋白组与代谢组在统一表示空间中进行融合，并通过表示结构、通路贡献谱与跨中心性能稳定性三类证据进行验证。实验结果显示，在二维 UMAP 嵌入中，不同模态呈现出差异化的点云结构，融合表示与其他模态存在明显交叠且整体分布格局更一致；在通路层面的贡献热图中，Top 通路在不同模态与融合表示之间呈现可对比的贡献分配模式；在跨外部环境（中心 A–E）的 AUROC 曲线与汇总表中，引入稳定性约束的融合方法表现出更高的平均性能与可观测的跨中心稳定性。综合而言，多组学融合在本实验设置下能够带来跨环境可复现的性能增益，并提供了通路层面的可视化证据支持。

本文的工作贡献主要体现在三个方面：其一，提出“因果味”作为跨环境可复现性的操作化表述，并将其落实为可观测、可报告的评估指标体系；其二，构建了面向多组学融合的结果证据链条，包含二维嵌入结构展示、通路贡献谱对比与跨中心鲁棒性曲线，使不同层面的证据能够相互对应；其三，通过引入跨环境波动惩罚的稳定性约束，给出一种在多中心/多批次/多时间窗背景下更稳健的融合训练目标，并在外部环境对比中展示其优势。

未来工作将从三个方向展开：一是扩大外部验证范围，引入更多中心与更异质的人群结构，以进一步检验跨环境结论的稳健性；二是补充更贴近实际应用的评价维度（如校准、阈值决策相关指标与分层人群表现），以提高结果的可解释性与可用性；三是结合更严格的反事实一致性或干预一致性检验，将“可复现的相关性提升”与“更接近机制的稳定信号”进一步区分，从而使多组学融合在真实场景中更可复刻、更可信赖。

V. MATERIALS AND METHODS / 材料与方法

本研究使用 Python 3.12.3 完成数据处理、建模与可视化。数据由三类组学模态构成：转录组、蛋白组与代谢组。研究对象被划分为病例组与对照组，任务定义为二分类预测。为评估跨环境可复现性，样本按外部环境划分为中心

A–E，并在每个中心分别计算评价指标，再进行跨中心汇总。

数据组织与对齐在样本层面完成，转录组、蛋白组与代谢组的记录通过统一的样本标识进行一一对应，保证同一受试者的三模态特征在同一行合并。对齐后对每个模态分别进行质量控制与预处理：先进行缺失值处理，再进行标准化。缺失值处理在每个模态内部独立执行，保证各模态的缺失模式不会因合并而被误解；标准化在特征维度执行，使不同量纲的特征具有可比尺度，避免某一模态因数值范围较大而在融合中占主导。预处理后得到三套特征矩阵 $X_{\mathrm{RNA}}, X_{\mathrm{Prot}}, X_{\mathrm{Met}}$ 以及对应标签 y，并保留环境标签 $e \in \{A, B, C, D, E\}$ 用于分中心评估与稳定性约束。

外部环境划分用于刻画真实应用中常见的分布差异来源，中心 A–E 可对应不同采集地点、检测批次或时间窗。训练与评估在统一协议下进行：模型训练阶段使用训练环境集合上的数据学习参数；评估阶段在中心 A–E 分别计算 AUROC，并记录每个中心的点估计与不确定性区间，最终输出跨环境曲线（图 3）与汇总表（表 I）。为获得置信区间，在每个中心内进行重复训练或重复抽样，重复次数保持一致，以保证不同方法之间的不确定性估计具有可比性。

对比方法包含三类：单模态基线、简单融合与因果正则融合。单模态基线分别以单一模态特征训练分类器，并将其作为对照。简单融合在输入层将三模态特征拼接为 $X = [X_{\mathrm{RNA}}, X_{\mathrm{Prot}}, X_{\mathrm{Met}}]$ 得到融合特征，再训练统一分类器。因果正则融合在融合训练目标中加入跨环境波动惩罚项，优化目标采用式 (2) 所定义的平均经验风险与跨环境方差项的加权和，λ 控制稳定性约束强度；在实现层面，训练时同时计算各环境上的损失并求其方差项，使模型在优化总体表现的同时抑制环境间差异过大。

可视化与解释部分包含二维 UMAP 嵌入与通路贡献热图。UMAP 嵌入在样本层面对不同模态与融合表示分别降维到二维空间，绘制散点图并以颜色标注组别、以点形区分模态，用于展示表示空间结构与组别分布（图 1）。通路贡献热图在通路层面汇总不同模态与融合表示的贡献强度，并进行 0–1 归一化后绘制热图（图 2），横向比较同一通路在四种来源上的相对贡献大小，纵向展示 Top 通路在整体贡献排序下的分布模式。跨环境性能曲线以中心 A–E 为横轴、AUROC 为纵轴，绘制三种方法的曲线并叠加 95% 置信区间阴影（图 3），用于同时呈现平均水平与跨环境波动范围。

ACKNOWLEDGEMENT / 致谢

感谢在研究构思、数据整理、方法实现与结果核对过程中提供帮助的相关单位与个人；同时感谢匿名评阅与讨论所提出的建设性意见，使本文工作得以进一步完善。

References

[1] Y. Lin and J. Q. Huang, "A general recipe for multi-omics fusion models and evaluation protocols," *Journal of Integrative Bioinformatics Methods*, vol. 12, no. 1, pp. 1–18, 2024.

[2] M. Chen and S. K. Rao, "From feature concatenation to representation alignment: a unified view of multimodal life-data fusion," *Computational Medicine Methodology*, vol. 7, no. 3, pp. 101–126, 2023.

[3] Z. Wang and E. T. Park, "Performance drop and interpretation drift under cross-center transfer: external validation challenges for multi-omics prediction," *Clinical Data Science Letters*, vol. 5, no. 2, pp. 55–74, 2022.

[4] H. Zhao and L. M. Stein, "Batch structure, platform shift, and reproducibility: systematic error sources in multi-omics analysis," *Advances in High-Dimensional Biostatistics*, vol. 9, no. 4, pp. 200–219, 2021.

[5] R. Patel and N. García, "Shortcut learning under domain shift: empirical diagnostics for medical machine learning failures," *Robust Learning in Health Analytics*, vol. 3, no. 1, pp. 15–33, 2020.

[6] K. Nakamura, *Auditable Evidence Chains: From Visualization to External Validation in Predictive Biomedicine*. Singapore: Meridian Academic Press, 2019, pp. 30–68.