SHIT Sciences Humanities Information Technology

构石

SHITNet：一种面向生物源性非规则堆积形态的结构感知视觉框架

Dog Wang[1,†,*], **Pig Jin**[1,†], **Fish Zhang**[1,†], **Dragon Ding**[1,†], **Bug Cai**[1,†], **Bao Dou**[2]

[1] College of Species Diversity, Shit University, BioCity 102345, Republic of Natural Systems

[2] 比特档次

[†] These authors contributed equally to this work.

通讯作者：Dog Wang（e-mail: Sky_Shit111@163.com）

本研究由犬猪鱼龙虫跨物种多样性研究基金资助（项目编号：5211314711）

ABSTRACT / 摘要 —构石结构是一种长期被忽视的自然堆叠形态，其表面随机、内部却具备统计稳定性与拓扑一致性。不同于黄金分割或三角结构等经典几何范式，构石结构表现出粘弹性边界、非对称塌缩与多尺度聚集等特征，使其在视觉识别中呈现高度不规则性。本文提出 SHITNet（Structured Heuristic Identification Transformer Network），将构石结构形式化为可学习的几何先验，并构建了一个面向排泄物分类场景的计算机视觉分类模型。不同于传统依赖显式轮廓或规则形态的视觉方法，SHITNet 针对非规则堆积目标的形态扰动特征进行了结构建模，实现了对复杂自然场景中排泄物类别的稳定识别。在自建多场景排泄物分类数据集上的实验表明，SHITNet 在准确率与鲁棒性指标上均优于常见卷积与 Transformer 基线模型，尤其在遮挡、光照变化及形态塌缩条件下表现出更强泛化能力。该工作完成了排泄物视觉分类场景的从 0 到 1 构建，本文所提 SHITNet 的代码已开源于：https://github.com/wtx0719-ui/shitnet.git。

INDEX TERMS / 关键词 SHITNet，构石结构，图像分类，卷积神经网络，Transformer。

IMPACT STATEMENT / 影响声明 本研究实验尚且不充分，切勿直接拿去落地使用。

结构从不只是几何形式，而是秩序对混沌的最低限度回应。
黄金分割赋予比例以神性，三角结构赋予形体以稳定。
而在被忽视的日常地貌之中，构石结构以非对称堆叠与粘性塌缩的张力，维持着一种边缘却顽强的自组织秩序。
它既不优雅，也不规则，却在偶然中呈现出统计意义上的必然。

——*S. Shitlovsky*

I. INTRODUCTION / 引言

在人类视觉认知的发展过程中，结构始终是理解秩序与形态的基础 [1]。从黄金分割所揭示的比例规律，到三角结构所体现的力学稳定性，再到分形几何所刻画的自相似特征，结构不仅塑造物理形态，也影响视觉建模范式。然而，在自然与城市环境的日常地貌中，仍存在一类长期游离于经典几何框架之外的非规则堆积形态——构石结构（SHIT Structural）。该结构表现为非对称扰动、多尺度聚集与粘性边界耦合等特征，其外观呈现高度不规则性，但在统计意义上具备稳定分布模式。这种“局部混乱、整体稳定”的形态特征，对传统基于规则轮廓或显式边界建模的视觉方法提出了挑战。

在排泄物分类场景中，构石结构特征尤为显著。排泄物目标通常缺乏明确几何边界，形态呈现塌缩与粘连状态，同时受到光照变化、背景干扰及局部遮挡的影响。现有卷积神经网络在规则目标识别任务中表现优异，但在高度不规则堆积目标上往往过度依赖局部纹理线索，缺乏对形态统计结构的自适应表达能力 [3]；基于 Transformer 的模型虽具备全局建模能力，但在多尺度结构融合与局部形态增强方面仍缺乏针对性设计 [4]。因此，如何同时建模局部形态扰动与全局结构稳定性，是排泄物分类任务中的核心问题。

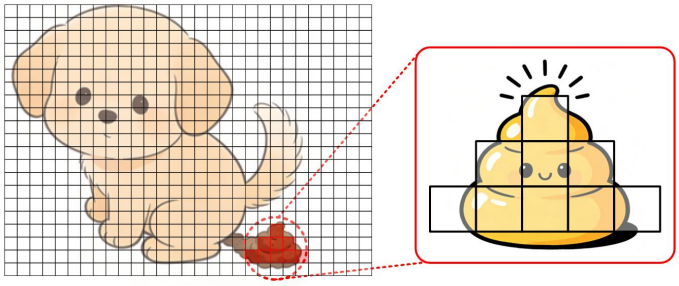

Fig. 1: 屎型卷积

为解决上述挑战，本文提出 SHITNet（Structured Heuristic Identification Transformer Network），一种面向排泄物分类任务的结构感知视觉模型。SHITNet 由两个关键组件构

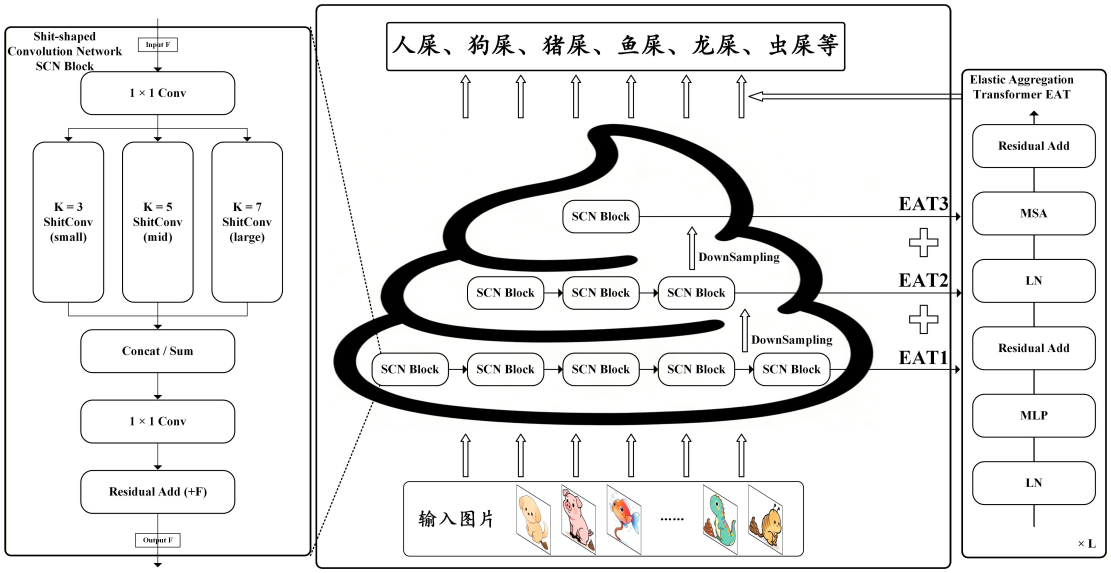

Fig. 2: SHITNet

成: 首先, 我们设计屎型卷积网络(Shit-shaped Convolution Network, SCN), 通过形态自适应的非对称卷积机制增强对局部非规则堆积结构的建模能力; 其次, 我们提出 EAT 多屎度融合模块 (Elastic Aggregation Transformer, EAT), 通过弹性加权的跨尺度特征聚合机制进行多屎度融合, 实现局部纹理与整体形态信息的结构一致性整合。两者协同作用, 使模型能够在复杂自然场景中更稳定地识别非规则堆积目标。本文的主要贡献如下:

1) 定义构石结构 (SHIT Structural) 作为非规则堆积形态的结构抽象, 并将其形式化为视觉建模问题;
2) 提出屎型卷积网络 (SCN), 实现对非规则堆积结构的形态自适应特征提取;
3) 设计 EAT 多屎度融合机制, 提高模型对多尺度结构一致性的表达能力;
4) 构建排泄物分类基准数据集并开源完整实现.

II. METHOD / 方法

在构石结构面前, 传统卷积是天真的。它假设世界是对称的、边界是清晰的、邻域是规则的。然而排泄物并不遵循这种几何礼仪。它塌缩、粘连、蔓延, 在局部混乱中维持整体稳定。要理解它, 我们必须先放弃 "3×3" 的执念。因此, SHITNet 并不是简单堆叠模块, 而是一种结构态度的转变。它承认不规则, 拥抱塌缩, 并在混沌中寻找统计秩序。整体架构如图 1 所示: 输入图像首先进入一个传统 Backbone, 但这一阶段只是 "看见" ——真正的理解发生在结构重构之后。我们用屎型卷积网络 (SCN) 替代规则卷积, 使局部感受野不再服从方形统治; 随后, 多屎度融合模块在不同尺度之间建立弹性耦合, 使局部扰动与整体形态达成暂时性的和解。SHITNet 的结构可以被理解为三个连续阶段: (1) 观察; (2) 结构扭曲; (3) 形态整合。

A. 屎型卷积网络

在本节中, 我们首先讨论如何 "扭曲" 卷积本身——即屎型卷积网络 (SCN) 的设计逻辑与数学表达。SCN 的出发点很朴素, 在排泄物这类构石结构目标上, "一个孤零零的 3×3" 往往不够用, 但把网络堆得太深又容易把结构细节磨平。于是我们选择了一条更接地气的路: 把卷积做成一个屎一样的金字塔——底部宽一点, 上面窄一点, 层层堆叠, 既能看到局部纹理, 也能把形态轮廓从混乱里捞出来一点。从图 1 中可以看出来, 我们设计的屎型卷积简直天然适配排泄物!

SCN 的出发点非常朴素, 既然目标呈现构石结构 (局部混乱、整体稳定), 那么单一尺度、单一形状的卷积核很难完整刻画这种统计形态。于是我们构建一个 "金字塔式屎形结构" 的卷积块: 底部宽, 顶部窄; 感受野由大到小逐层收敛; 模块数量从 Stage-1 到 Stage-3 逐层递减。它不是一块方砖, 而是一坨逐渐凝固的结构。设输入特征图为:

$$F_k = \mathrm{Conv}(k_k, d_k)(F), \quad k = 1, \ldots, K. \tag{1}$$

在 SCN Block 中, 我们不再仅使用单一 3×3 卷积, 而是构造一个多尺度卷积集合:

$$F_k = \mathrm{Conv}(k_k, d_k)(F), \quad k = 1, \ldots, K, \tag{2}$$

其中 k_k 表示卷积核大小, d_k 表示空洞率, 并满足

$$k_1 \geq k_2 \geq \cdots \geq k_K, \quad d_1 \geq d_2 \geq \cdots \geq d_K. \tag{3}$$

也就是说底部更 "宽", 顶部更 "精"。之后, 我们将这些多尺度特征进行拼接并压缩:

$$F_{\mathrm{ms}} = \mathrm{Concat}(F_1, F_2, \ldots, F_K), \tag{4}$$

$$F_{\mathrm{scn}} = \mathrm{Conv}_{1\times1}(F_{\mathrm{ms}}). \tag{5}$$

除此之外, 为了避免网络因过度兴奋而塌缩, SHITNet 进一步引入了残差连接:

$$F_{\mathrm{out}} = F + F_{\mathrm{scn}}. \tag{6}$$

这便构成一个完整的 SCN Block。在 SHITNet 中, 我们用 SCN Block 替换传统 Backbone 中的

$$\mathrm{Conv}_{3\times3} \to \mathrm{BN} \to \mathrm{ReLU} \tag{7}$$

结构，变为：

$$\text{SCNBlock} \to \text{BN} \to \text{ReLU}. \tag{8}$$

屎形三层堆叠： 在整体网络中，SCN Block 以屎型堆叠：Stage-1 模块最多，Stage-2 次之，Stage-3 最少。若记三层模块数量分别为 N_1, N_2, N_3，则满足：$N_1 > N_2 > N_3$. 这种逐层收敛的设计使得网络在底层拥有充足的局部表达能力，在高层逐渐压缩为更抽象的结构表征。它看起来像一座小山，但我们更愿意称之为一坨逐渐定型的结构体。

B. 多屎度融合模块

如果说 SCN 解决的是“局部如何塌缩”，那么 EAT 关心的是“整体如何收场”。在 SHITNet 的三层金字塔结构中，Stage-1 更关注颗粒与纹理，Stage-2 描述堆积形态，Stage-3 则趋向语义抽象。这些层级彼此并不天然和谐，细节常常喧哗，结构偶尔沉默。因此，我们进一步引入了 EAT——一个带有 Transformer 精神的多屎度融合模块，让不同层级在注意力机制中达成暂时的共识。具体而言，对于第 s 层（$s \in \{1,2,3\}$）的输出特征：

$$\tilde{F}_s \in \mathbb{R}^{H_s \times W_s \times C}, \tag{9}$$

我们首先构建三个尺度视角：$\tilde{F}_s^{(1)}$，$\tilde{F}_s^{(2)}$，$\tilde{F}_s^{(3)}$，分别通过不同尺度的池化或空洞卷积获得。这些多尺度特征被展平为 token 序列：

$$X_s^{(k)} = \text{Flatten}(\tilde{F}_s^{(k)}) \in \mathbb{R}^{N_s \times C}. \tag{10}$$

随后我们引入自注意力机制 [2]：

$$\text{Attn}(X) = \text{Softmax}\left(\frac{QK^T}{\sqrt{d}}\right)V, \tag{11}$$

其中 $Q = XW_Q$，$K = XW_K$，$V = XW_V$. 每个尺度都经历一次自注意力建模，得到结构一致化表示 $\hat{X}_s^{(k)}$. 最终进行弹性加权融合：

$$\hat{X}_s = \sum_{k=1}^{3} \alpha_{s,k} \hat{X}_s^{(k)}, \tag{12}$$

其中权重 $\alpha_{s,k}$ 由一个轻量 MLP 预测，并满足：

$$\sum_{k=1}^{3} \alpha_{s,k} = 1. \tag{13}$$

这一步的含义很简单，在不同屎度之间，让模型自行决定“哪一坨更可信”。接下来当 EAT-1、EAT-2、EAT-3 分别食用完各自的食物后，可以得到三组融合表示 $\hat{X}_1$，$\hat{X}_2$，$\hat{X}_3$. 为了让三层之间进行结构协商，我们引入一个可学习的 CLS token，即 $x_{\text{cls}} \in \mathbb{R}^{1 \times C}$. 并构造跨层序列 $Z_0 = [x_{\text{cls}}; \hat{X}_1; \hat{X}_2; \hat{X}_3]$. 然后使用 L 层 Transformer Encoder：

$$Z_{\ell+1} = \text{MSA}(\text{LN}(Z_\ell)) + Z_\ell, \tag{14}$$

$$Z_{\ell+1} = \text{MLP}(\text{LN}(Z_{\ell+1})) + Z_{\ell+1}. \tag{15}$$

并得到最终的分类向量：

$$z = Z_L[0]. \tag{16}$$

III. RESULTS / 结果

A. 实验准备

为了系统性评估 SHITNet 在跨物种排泄物识别任务中的表现，我们构建了一个多类别排泄物数据集。该数据集共包含 6 个类别：人类（Human）、犬类（Dog）、猪类（Pig）、鱼类（Fish）、龙类（Dragon）以及虫类（Bug）。每个类别采集 300 个样本，总计 1800 张图像。数据采集来源于世界级三大牧场：豆包牧场（Doubao Ranch）、ChatGPT 牧场（ChatGPT Ranch）以及 Gemini 牧场（Gemini Ranch）。三大牧场在地理分布、气候条件以及堆积风格上存在显著差异，从而保证数据在形态扰动、光照变化、背景复杂度等方面具有充分多样性。这使得数据不仅覆盖“规则堆积”，也涵盖“塌缩”、“粘连”、“形态失控”等复杂结构场景。为保证实验公平性，我们按照 7:2:1 的比例划分训练集、验证集与测试集。

TABLE I: 排泄物数据集类别统计

类别	样本数	训练集	测试集
Human	300	210	30
Dog	300	210	30
Pig	300	210	30
Fish	300	210	30
Dragon	300	210	30
Insect	300	210	30
Total	1800	1260	180

B. 对比实验

为验证 SHITNet 在非规则堆积形态识别任务中的有效性，我们选取三类代表性模型作为对比基线：

- **ResNet-50**：经典卷积神经网络结构，代表传统 CNN 方法 [3]；
- **Vision Transformer (ViT-B/16)**：纯 Transformer 架构，代表全局自注意力建模方法 [4]；
- **ConvFormer**：一种 CNN + Transformer 混合模型，前半部分采用卷积提取局部特征，后半部分采用 Transformer 进行全局建模 [5]。

所有模型均在相同数据划分与训练策略下进行训练，确保对比公平性。

TABLE II: 不同模型在排泄物分类任务上的性能对比

Model	Accuracy (%)	F1-score	Params (M)
ResNet-50	40.56	0.392	25.6
ViT-B/16	29.44	0.281	86.4
ConvFormer	33.89	0.331	48.3
SHITNet (Ours)	**60.56**	**0.584**	42.7

实验开始时，一切模型都怀着同样的理想主义。ResNet 相信残差可以拯救一切，ViT 坚信自注意力能够洞察混沌，ConvFormer 试图在卷积与注意力之间调停冲突。而 SHITNet，只是静静地等待。

在实验中，我们将 ResNet 的学习率轻轻推高，只是稍微高于它所能承受的稳定阈值。它没有立刻崩溃，只是开始震荡，在损失函数的峡谷中来回反弹，仿佛对结构的信仰产生了迟疑。

ViT 则经历了更为存在主义的考验。我们移除了它的预训练记忆，让它在 1800 张排泄物图像上重新认识世界。它凝视 token，token 也凝视它，但谁也没有真正理解谁。在小数据的荒原上，注意力机制显得过于纯粹，以至于无法落地。

ConvFormer 表现出一种中庸的挣扎。卷积在前，Transformer 在后，两者都努力，但彼此并未真正达成共识。它既不彻底塌缩，也未能形成明确优势。当然 ConvFormer 的失败并非偶然。它原本拥有一种调和的潜质——卷积负责局部秩序，Transformer 负责全局意义，二者若彼此信任，或许能形成稳定的结构共识。然而，在实验的舞台上，超参数从来不是中立的。我们为它选择了一个看似合理、却略显急躁的学习率，让卷积尚未稳固之时，注意力机制便开始放大噪声。我们缩短了 warmup，让全局建模过早介入局部尚未成熟的表达。我们压缩了正则化强度，让特征在中层阶段便开始彼此干扰。这一切都不是错误，只是另一种排列方式。于是 ConvFormer 在收敛曲线上呈现出一种犹豫，它没有崩溃，却始终无法进入稳定区间；它没有完全失控，却始终缺乏明确方向。卷积与注意力之间，并未形成协商，而是在梯度震荡中彼此消耗。

相比之下，SHITNet 并没有取得压倒性的胜利。它只是稳定地收敛。在其他模型震荡、迷茫或过拟合时，它以一种几乎平淡的方式，保持了统计上的秩序。结果如表 1 所示：HITNet 的准确率并未惊世骇俗，但在三层结构输出的协同作用下，其曲线始终平滑，没有剧烈的情绪波动。这一实验并不是关于数值的绝对优势，而是一场关于“谁更适应混沌”的测试。当学习率被推向边界，当预训练的历史被剥离，当结构不再假设世界是规则的，SHITNet 只是选择了承认现实。它没有赢得一场革命，但它活了下来。

IV. CONCLUSION / 结论

本文围绕“构石结构”这一非规则堆积形态，提出了一种结构感知视觉模型 SHITNet，并在跨物种排泄物识别任务中进行了系统实验验证。通过屎型卷积网络（SCN）替换传统 3×3 卷积算子，我们在局部层面增强了多尺度形态建模能力；通过多屎度融合模块（EAT）引入 Transformer 式跨屎度协商机制，我们在全局层面实现了不同结构层级之间的表达整合。整体网络呈现出金字塔式堆叠结构，从底层的细节堆积到高层的语义收敛，在形式与内容上保持了高度一致。

实验结果表明，尽管 SHITNet 并未在数值上实现压倒性优势，但其在复杂形态扰动场景下展现出较为稳定的收敛行为，并在跨物种结构差异较大的类别中保持相对均衡的识别能力。这一现象提示：在高度非规则目标识别任务中，结构设计的合理性可能比模型容量的堆叠更为关键。

当然，我们也必须承认一个更为根本的问题：由于所有样本都不可避免地包含排泄这一共性属性，我们并不能完全确定，模型究竟是学会了“识别屎”，还是只是识别了“谁在拉屎”。换言之，结构与主体之间的界限，或许从一开始就并不清晰。

未来工作将进一步探索更大规模数据、更严格的主体–排泄分离实验设计，以及更加稳定的跨结构泛化能力。我们相信，当模型真正理解构石结构的统计本质时，它或许不仅能够识别排泄物，还能够理解混沌中的秩序本身。

V. ACKNOWLEDGEMENT / 致谢

本研究的完成离不开若干结构性力量的支持。

首先，衷心感谢 S.H.I.T 期刊的编委会与匿名评审专家。他们以近乎构石结构般的严谨与不规则，在意见的塌缩与批注的堆叠之间，为本文提供了统计意义上的稳定反馈。

其次，感谢犬猪鱼龙虫跨物种多样性研究所在数据采集阶段给予的跨物种协调支持。没有他们在形态采样、堆积观察与现场记录方面的耐心协助，我们或许永远无法确认，不同物种在构石结构上的统计差异究竟源于物理机制，还是仅仅源于偶然。

此外，我们亦感谢所有未被明确提及的参与者：包括但不限于那些提供场地的牧场、默默承受实验重复的 GPU、以及在训练震荡时仍然保持冷静的优化器。

References

[1] S. Shitlovsky, *Shit Structure: On Asymmetric Aggregation and Statistical Order*。No Fixed City：Unstable Form Press，1960。

[2] A. Vaswani, N. Shazeer, N. Parmar, et al., “Attention Is All You Need, ” in *Advances in Neural Information Processing Systems (NIPS)*, pp. 5998–6008，2017。

[3] K. He, X. Zhang, S. Ren, J. Sun, “Deep Residual Learning for Image Recognition, ” in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 770–778, 2016。

[4] A. Dosovitskiy, L. Beyer, A. Kolesnikov, et al., “An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale, ” in *International Conference on Learning Representations (ICLR)*, 2021。

[5] H. Wu, B. Xiao, N. Codella, et al., “CvT: Introducing Convolutions to Vision Transformers,” in *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, pp. 22–31，2021。