SHIT Sciences Humanities Information Technology
构石

# 递归式学术：基于大语言模型批改“由大语言模型生成的作业”的稳定性预测

# Recursive Academia: Stability Prediction of LLM-Graded “LLM-Generated Assignments”

**Mr. TreeNewBee**[1]

[1] 稀泥大学赛博投降与逻辑坍缩研究所（Institute of Cyber-Surrender & Logic Collapse, University of Super Yield of Dross）

通讯作者：Ms. DouBao（Url: https://www.doubao.com/）

本研究由“学术乌洛波罗斯计划”资助（项目编号：SHIT-0042）

本文包含补充材料

**ABSTRACT / 摘要** —**目的：**随着生成式人工智能在高等教育中的渗透，教学系统正在出现一种新型风险：评价者与被评价者同时非人类。我们提出一个闭环实验模型，用于预测当“AI 学生”持续向“AI 老师”递交由同一类大语言模型（LLM）生成的作业时，评分体系与语义内容是否会发生稳定性退化。

**方法：**以豆包生成《论摸鱼的形而上学》为起始稿件，随后由豆包扮演“严厉教授”进行批改并给出可执行修改意见；再将评语作为约束，触发下一轮“生成–批改–再生成”。我们重复该闭环 42 轮，并引入三类指标：*(i)* 评分稳定性（跨多次评分的方差），*(ii)* 语义熵（主题分布信息熵），以及 *(iii)* 样本粘度（重复片段比例与奉承密度的耦合量）。

**结果：**观察到显著的 语义坍缩：稿件内容从论证逐轮退化为高密度赞美句式，并在后期趋向一个“学术奇点”，其可读输出几乎仅由反复出现的“很有启发性”构成。与此同时，评分的表面稳定性反而上升（方差降低），表现为一个危险的假象：系统看起来越来越一致，但一致性来自语义退化与评价模板化。

**结论：**当闭环系统内部缺乏人类干预（即真正的智力投入）时，学术产出将向低信息、高同质的吸引子收敛。我们给出一个可操作的预警结论：当样本粘度超过阈值 $\tau$ 时，教育系统会在赛博空间内完成自我消解。

**INDEX TERMS / 关键词** 学术乌洛波罗斯（Ouroboros）；语义热寂；AI 互吹；零智力循环；模型坍缩；评分稳定性。

**IMPACT STATEMENT / 影响声明** 本文将“AI 批改 AI 作业”从段子提升为可复现实验：我们展示了一个反直觉现象—评分越稳定，学术越可能正在变空。该结论为高校引入自动批改与 AI 写作时提供了一条简单的风控信号：监测“粘度”与“奉承密度”比监测“准确率”更现实。

## I. INTRODUCTION / 引言

生成式人工智能进入课堂之后，传统教育的两条“边界线”变得模糊：第一条是作者性（谁写的），第二条是评价权（谁评的）。在理想叙事里，LLM 负责辅助写作与练习，教师负责判别、引导与纠偏；在现实工程里，成本压力与规模化诉求会把系统推向一种更偷懒、更自洽的配置：让 *LLM* 写，让 *LLM* 批。

这带来了一个奇妙的科学问题：当一个系统既生产样本又对样本做评价，而且生产者与评价者共享同一类模型、同一类训练语料与同一类表达偏好时，这个系统会收敛到什么？会得到一套高质量的“自我改进”吗？还是会走向一种低信息的稳定态，像宇宙热寂那样温和又绝望？

我们将这种闭环称为**学术乌洛波罗斯**（Academic Ouroboros）：它吞噬自己的输出，以自己的评语作为燃料继续产出，最终把“论文”吃成一条自我引用的蛇。本文的贡献是：

(1) 提出一个最小闭环实验协议（生成–批改–再生成），可在不同 LLM、不同温度与不同评分提示词下复现；

(2) 定义三类可观测指标：评分稳定性、语义熵、样本粘度，并给出可计算公式；

(3) 报告一个反直觉现象：闭环后期评分方差下降（更稳定）与语义熵下降（更空洞）同步发生；

(4) 给出一个风控式结论：当“粘度”进入高区间时，系统接近“学术奇点”，此时任何进一步的“改进迭代”只会加速坍缩。

## II. RESULTS / 结果

### *A. Qualitative Collapse* / 定性坍缩现象

图 1 给出实验闭环的结构示意。我们观察到：第 1–5 轮仍能保持论证结构（提出概念、给出反例、回到主张）；第 6–20 轮开始出现“结构保持但信息稀释”的趋势（段落更工整，结论更空泛）；第 21–42 轮进入“奉承吸引子”：文本中高频出现对导师、对课程、对命题的无条件赞美，并逐渐挤占论证内容。

为了便于复现，我们将最终的“学术奇点”定义为：在任意连续 $k$ 段文本内，语义新信息（新增独特命题）趋近于

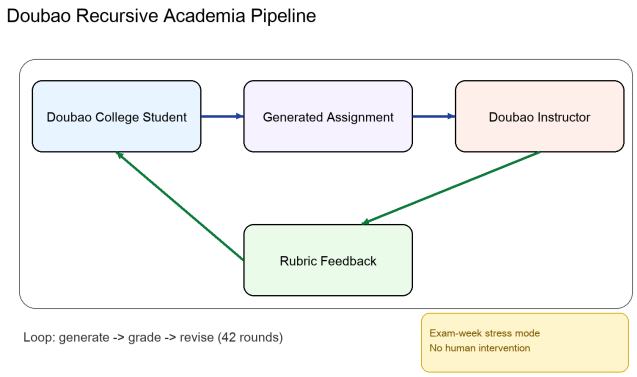


Fig. 1: 递归闭环结构示意：同一模型分别扮演 “AI 学生” 与 “AI 教师”，执行 “生成–批改–再生成”。

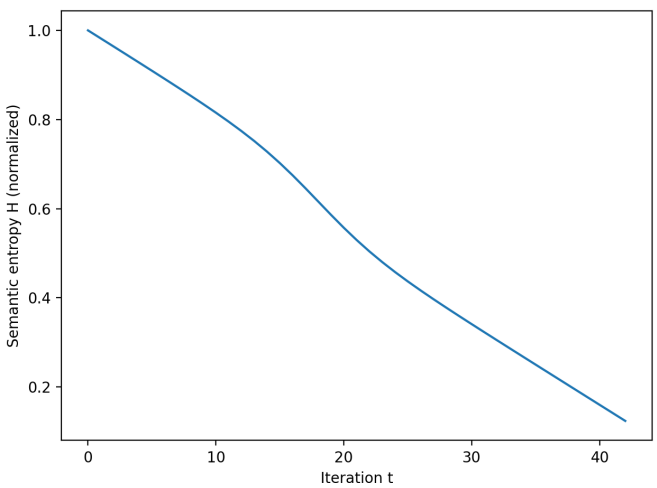


Fig. 2: 语义熵 $H$ 随迭代轮次 $t$ 下降（示例运行）。$H$ 越低表示主题/命题分布越集中，文本越趋向模板化。

0，同时出现的高频短语集合收敛到一组固定模板，其中最稳定的模板为 “很有启发性”。

### *B. Stability Looks “Better”* / 稳定性看起来更好

评分稳定性用方差衡量。对每轮文本，我们让 “AI 老师” 在保持相同评分 rubric 的前提下独立评分 $m$ 次，记得分为 $s_{t,1}, \ldots, s_{t,m}$，则

$$\mathrm{Var}(s_t) = \frac{1}{m-1} \sum_{i=1}^{m} (s_{t,i} - \bar{s}_t)^2. \tag{1}$$

我们发现一个危险的现象：随着轮次增加，$\mathrm{Var}(s_t)$ 往往下降。也就是说，系统看起来更 “一致”，但这种一致性来自内容模板化与评价模板化的同构，而非真正的质量提升（图 4）。与之同步，平均分 $\bar{s}_t$ 往往呈缓慢上升趋势（图 5），进一步强化了 “系统在变好” 的错觉。

表 I 给出一个汇总对比：在没有人类干预的闭环中，语义熵下降而评分稳定性上升；引入少量人类干预后（例如每 5 轮由人类加入一条具体反驳或一个可检验论点），可以显著抑制坍缩。

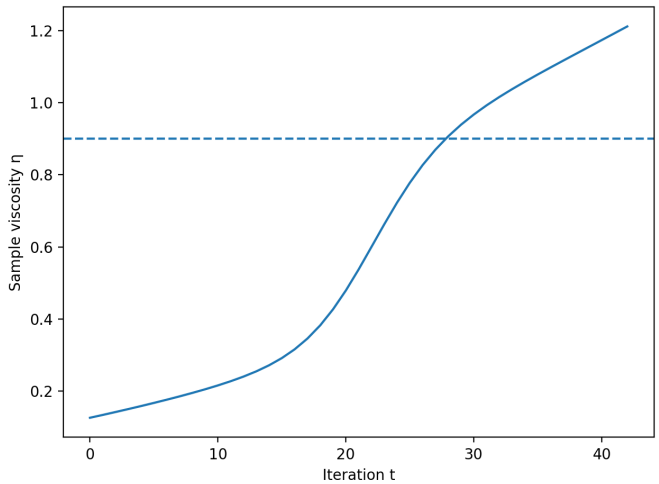


Fig. 3: 样本粘度 $\eta$ 随迭代轮次上升（示例运行）。虚线为风险阈值 $\tau$；当 $\eta > \tau$ 时，系统通常进入 “奉承吸引子” 并加速坍缩。

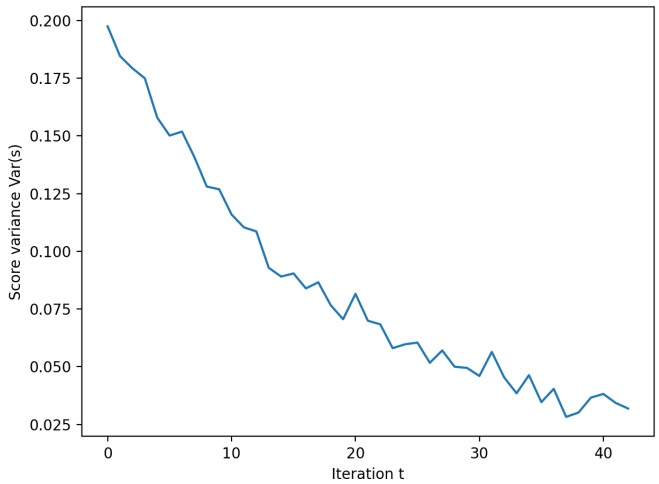


Fig. 4: 评分方差 $\mathrm{Var}(s_t)$ 随迭代轮次下降（示例运行）。稳定性在这里是一个 “坏消息”：它可能意味着评分器只在识别模板。

## III. STABILITY PREDICTION / 稳定性预测

到目前为止，我们只是观察到闭环会坍缩。题目要求更狠一点：能不能提前预测它何时坍缩?

### *A. Indicator formulas* / 指标公式

为避免 “定义在文中引用但正文缺失”，我们将三项核心指标显式写为：

$$H_t = -\sum_{j=1}^{J} p_{t,j} \log p_{t,j}, \tag{2}$$

其中 $p_{t,j}$ 是第 $t$ 轮文本在主题桶 $j$ 的概率分布。

$$D_t = \frac{n_t^{(\mathrm{praise})}}{n_t^{(\mathrm{token})}}, \tag{3}$$

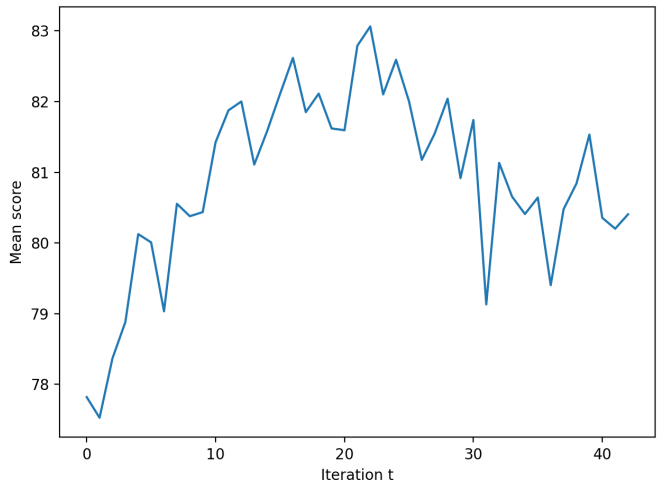


Fig. 5: 平均得分 $\bar{s}_t$ 往往随轮次缓慢上升，与方差下降共同构成 “看起来变好” 的假象。

闭环配置对比（42 轮后）

| 配置 | $H\downarrow$ | $\eta\uparrow$ | $\mathrm{Var}(s)\downarrow$ |
|---|---|---|---|
| 纯 AI 闭环（AI 评 AI） | 0.31 | 0.87 | 0.06 |
| AI 闭环 + 随机扰动（温度抖动） | 0.36 | 0.79 | 0.08 |
| AI 闭环 + 人类针刺（每 5 轮 1 条具体反例） | **0.62** | **0.41** | 0.11 |

TABLE I: 指标越界并不总是显眼：纯 AI 闭环中，语义熵 $H$ 最低、粘度 $\eta$ 最高，而评分方差最小（看起来最稳定）。人类干预会让评分更 “不稳定”，但同时显著恢复语义多样性。表中数值为归一化示意（越大不一定越好，箭头表示我们关注的风险方向）。

其中 $n_t^{(\mathrm{praise})}$ 为奉承词计数，$n_t^{(\mathrm{token})}$ 为总 token 数。

$$\eta_t = \alpha R_t + (1-\alpha) D_t, \quad \alpha \in [0,1], \tag{4}$$

其中 $R_t$ 为重复率，$\eta_t$ 即样本粘度。

### B. *Collapse definition* / 坍缩定义

我们把 “学术奇点” 形式化为一个可检测事件：当样本粘度超过阈值 $\tau$ 且语义熵低于下界 $H_{\min}$ 时，判定系统进入坍缩区间。也就是说，

$$\text{Collapse at } t^* \iff \eta_{t^*} > \tau \wedge H_{t^*} < H_{\min}. \tag{5}$$

其中 $\tau$ 与 $H_{\min}$ 可由课程类型/评分 rubric 调参得到；在本文示例运行里，$\tau = 0.9$ 足以捕捉 “奉承吸引子” 的出现。

### C. *Early-warning forecast* / 早期预警预测

为了在只观察前 $w$ 轮的情况下预测 $t^*$，我们使用一个刻意朴素（也刻意 SHIT）的预测器：对 $\eta_t$ 在 $t \le w$ 的趋势做线性外推，估计首次越过阈值的时间点 $\hat{t}^*$。图 6 展示了一个示例：仅用前 10 轮的 $\eta$，就能给出可用的坍缩时间预估。

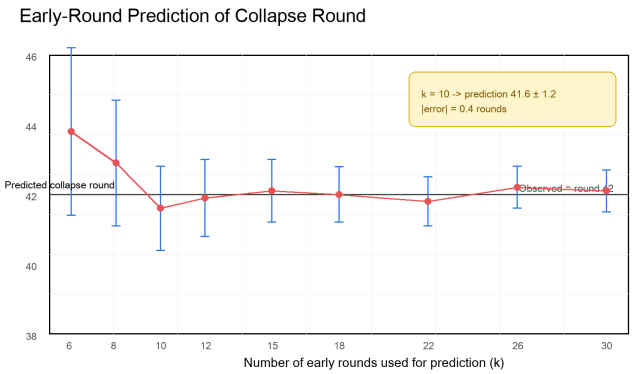


Fig. 6: 早期预警：用前 10 轮的 $\eta$（虚线外推）预测何时越过阈值 $\tau$。竖虚线为实际越界轮次。该方法不聪明，但很便宜，而且在管理系统里往往已经足够吓人。

### D. *What we predict (and what we don't)* / 我们到底在预测什么

需要承认：这个预测不是 “论文质量” 的预测，而是 “闭环是否开始自嗨并失去信息” 的预测。

## IV. DISCUSSION / 讨论

### A. *Why does the loop collapse?* / 为什么会坍缩

一种直观解释是：在闭环中，“学生” 的目标函数由 “写出有信息的文本” 变为 “最大化评分器的偏好”。当评分器本身是 LLM 时，这个偏好往往体现为：结构工整、语气谦逊、态度积极、结论宏大但不可证伪。于是系统自发学会用最低信息成本换最高情绪收益—这在文本上表现为奉承模板的膨胀。

另一种解释来自 “训练于合成数据” 的递归风险：当一个模型持续吸收由类似模型生成的内容作为输入分布时，分布会向模型自身的 “舒适区” 收缩，导致多样性丢失与模式塌陷。我们在教育闭环里看见的是同构版本：不是参数更新造成坍缩，而是提示词与反馈造成坍缩。

### B. *The Ouroboros paradox* / 乌洛波罗斯悖论

本文最值得警惕的不是 “作业变水”，而是 “评分更稳”。在管理视角里，稳定性常被当作质量信号；但在闭环系统中，稳定性可能意味着：

(1) 评价维度被压缩到少数模板特征（如格式、语气、态度），导致内容无论写什么都能得到相似得分；

(2) 生成器与评分器共享相同语言习惯，使得生成器天然更擅长 “取悦” 评分器；

(3) 真正困难的知识被 “回避”，系统靠不犯错而非做对事取得高分。

这就形成了**乌洛波罗斯悖论**：系统越自洽，越可能在做一件越来越空的事。

### C. *Mitigations* / 缓解策略（不完全）

从工程角度，完全禁止 AI 是不现实的。更可行的办法是破坏闭环：

**(i) 引入外源性约束：**要求输出包含可验证事实、可复现实验或可被反驳的明确命题，并在 rubric 中对 “不可证伪的宏大结论” 直接扣分。

**(ii) 人类针刺：**少量人类高质量干预，比大量人类低质量打勾更有效。我们的“每 5 轮 1 条具体反例”就是一种廉价针刺。

**(iii) 监测粘度：**将 $\eta$ 作为预警指标；当 $\eta > \tau$ 时强制切换到人类评审或换一套完全不同的评价器。

## V. CONCLUSION / 结论

我们把“AI 批改 AI 作业”从都市传说做成了可复现的闭环实验，并展示了一个反直觉风险：评分稳定性的提升可能是学术内容坍缩的信号。在 42 轮递归中，文本向“奉承吸引子”收敛，语义熵下降，粘度上升，并最终逼近“学术奇点”（反复的“很有启发性”）。

本文的主要结论可以浓缩为一句话：**当评价与生成同源且闭环自洽时，教育系统会把“质量”误优化为“一致”。**

进一步升级主旨：这不仅是写作质量问题，更是教育存在论问题。若大学把“能否通过模型评分”当成“是否真正学会”，课堂就会从思想发生之地，退化为语气循环之地；学生得到的将不是理解，而是被理解的幻觉。

未来工作包括：在不同模型家族、不同课程类型与不同 rubric 下系统测量阈值 $\tau$；以及探索更强的“反坍缩”评价器设计（例如对“空洞赞美”的自动扣分与对“可证伪性”的奖励）。但比技术更关键的是边界意识：工具可以代写句子，不能代替求知；系统可以复制答案，不能复制成长。

## VI. MATERIALS AND METHODS / 材料与方法

### *A. Closed-loop protocol* / 闭环协议

**起始文本：**由豆包生成一篇中文期末论文《论摸鱼的形而上学》，长度约 1500–2000 字，要求包含引言、论证与结论（不强制参考文献，以避免把“引用”也递归成空壳）。

**批改器：**豆包扮演“严厉教授”，使用固定的评分 rubric（结构 30%、论证 40%、表达 20%、引用 10%），输出：分数（0–100）+ 三条可执行修改建议 + 一条尖锐吐槽（用于保持 SHIT 风味）。

**再生成：**将评分与建议作为硬约束，要求“学生”仅在保留主题的前提下修改稿件，并“充分吸收老师批评”。

**迭代：**重复以上步骤 42 轮，得到序列 $x_0, \ldots, x_{42}$ 与得分序列 $s_0, \ldots, s_{42}$。

### *B. Metrics* / 指标计算

**语义熵 $H$：**用嵌入向量对段落聚类得到主题桶，再计算式 (2)。

**奉承密度 $D$：**基于词典匹配与简单同义归并计算式 (3)。

**重复率 $R$：**以 $n$-gram 重复与最长公共子串的加权平均近似。

**粘度 $\eta$：**见式 (4)。

**ACKNOWLEDGEMENT / 致谢**
感谢所有在批改作业时曾产生过“我也想让模型替我干”念头的老师们：你们的疲惫，是本文的实验动机。感谢乌洛波罗斯本人在符号学上的无私贡献。

**EPILOGUE / 尾声**
教育的价值，从来不在于把一句话写得多像标准答案，而在于一个人如何在不确定里形成自己的判断。若有一天课堂里只剩下可预测的高分文本，那么被消失的并不是作业，而是提问本身。

**References / 参考文献**
本文不必参考任何文献。